

RNA-seq 两轮实跑结果讲解 (results guide)

Contents

RNA-seq 两轮实跑结果讲解 (results guide)	1
1. 这批结果是什么	1
2. 逐类导读	1
3. 动手练习 (全部仓库内可完成)	2
4. 未入库的大文件在哪	3
5. 一句话总结	3

RNA-seq 两轮实跑结果讲解 (results guide)

: 配套 RNA-seq/results/ (mini 轮 + homework/全量轮两轮入库产物) 的逐类导读与动手练习。所有练习都只能在仓库内完成——不需要集群、不需要原始数据。每步原理与命令讲解见 RNA_seq_tutorial_corrected.md (中文版_zh.md)。

1. 这批结果是什么

两轮全链路实跑 (fastqc → fastp → STAR → multiqc → salmon 双模式 → R 差异表达/富集/热图)，命令照教程原文、只加最小包装，全部偏差记录在 */log/deviations.log。一轮是 mini (每样本 1 万读段、chr22 mini 索引、约 4 分钟)，一轮是全量 (每样本 11.8 万–22.7 万读对、完整 GRCh38 索引、约 31 GB 内存、13 分钟)。两轮都按教程原生方式在登录节点串行跑 (理由与取证见矫正版第 0 节)。

关键数字	mini	homework/全量
STAR unique (HBR/UHR)	53.0–53.3% / 45.1–49.9%	51.7–51.8% / 44.6–48.5%
过滤后转录本	111 / 4,989	831 / 231,448
DEG (FDR<0.05 且 logFC >1)	45 (15 上 / 30 下)	319 (171 上 / 148 下)
top 基因	IGLC2 (+10.3) / MIAT (–8.5)	IGLC2 / SYNGR1 一簇
热图标签	基因名 (mini 版代码正确)	照原文全 “NA” → 矫正 0/50 NA

)

2. 逐类导读

02_fastqc/ (fastqc zip × 12/轮) : zip 内含 fastqc_data.txt 与完整 html，故未单独收散装 html。逐文件 Total Sequences 是规模核验的第一手出处——homework 轮 read1 与 read2 计数一致 (118,571…227,392/文件)。

04_fastp/ (json+html 对 × 12/轮) : json 是机读版修剪统计；summary.before_filtering.total_reads 与 after_filtering.total_reads 相除即保留率 (97.4–98.7%)。

05_STAR/ (Log.final.out + SJ.out.tab 各 6/轮) : Log.final.out 是比对画像的唯一权威出处——三行关键值：Uniquely mapped reads %、% of reads mapped to multiple loci、% of reads unmapped: too short。全量轮的”太短 47–53% “(mini 轮仅 11–13%) 是**全基因组索引 + BySJout 过滤组合**的属性，不是跑错 (矫正版第 5 节解读)。SJ.out.tab 是剪接位点表 (0 列=染色体，第 6 列=注释状态 0=novel/1=annotated/2=genome-annotated)。

06_multiqc/ : multiqc_report.html.gz 是汇总报告 (fastqc+fastp+STAR+salmon 全在一个页面；gzip 无损入库——gzip -cd 即可浏览器打开，字节与集群原件一致已 cmp 验证)；multiqc_data/ 是解析后的数据表 (multiqc_star.txt、multiqc_fastp.txt 等，纯文本可直接 column -t 看)——不看 html 也能从这里核出本文所有数字。

07_salmon_align/ 与 08_salmon_quasi|direct/ : 每个 *_salmon_quant 目录里最有用的是 aux_info/meta_info.json——num_mapped/num_processed 就是映射率。**align 模式 100% 不是质量满分**：输入 BAM 只有 STAR 已比对片段，分母是”已比对片段” (矫正版 RNA-12)；quasi/direct 的 30–37% 才是”读段对索引”的口径。

homework 轮 quasi 的 quant.sf 以 .gz 入库 (231,448 行 × 4 列: Name/Length/EffectiveLength/TPM/NumReads——注意实际 5 列含 EffectiveLength), 是 R 段计数的直接输入; align 模式的 quant.sf (下游不用) 未入库、其目录保留其余全部文件。

09_R/: 两轮的图。**homework 轮有一对热图证据**: heatmap_DEG.pdf (照教程原文跑出, 50 行标签全部是“NA”——沉默 bug 的直接产物) 与 heatmap_DEG_corrected.pdf (一行修复后, 50 行全是真实基因名)。mini 轮的 heatmap_DEG_mini_final.pdf 标签正常——mini 版热图代码本来就正确, 作业版是被重写坏的。

scripts/ 与 log/: 运行脚本原样 (含 sbatch 头——homework 轮实际是教程原生登录节点跑, SLURM 头仅溯源保留); log/ 是 summary (逐步时间戳)、deviations (全部偏差与实锤发现)、R 分析日志 (kept/DEG/Matched/top 基因的原始打印)。

3. 动手练习 (全部仓库内可完成)

练习 1——亲手复现热图 NA bug 证据 (本仓库最有价值的一对文件):

```
cd RNA-seq/results/homework/09_R
pdfTOTEXT heatmap_DEG.pdf - | grep -c '^NA$' # → 50 (照教程原文)
pdfTOTEXT heatmap_DEG_corrected.pdf - | grep -c '^NA$' # → 0 (一行矫正后)
```

对照矫正版第 12 节的坑链: 为什么 R 一个报错都没报?

练习 2——从 meta_info.json 核出两个口径的映射率:

```
cd RNA-seq/results
for d in homework/08_salmon_quasi/*_quasi.salmon_quant; do
  python3 -c "import json; m=json.load(open('$d/aux_info/meta_info.json')); print('$d'.split('/')[1][1:7], round(100*m['num_mapped']/m['num_processed'],2),'%')"
done
# quasi: 30.3–35.3%; 再对 homework/07_salmon_align 同法 → 100%
```

两列数字放在一起就是 RNA-12 的教训: 分母不同, 不能互比。

练习 3——从 Log.final.out 重算比对画像表:

```
cd RNA-seq/results
for f in homework/05_STAR/*Log.final.out; do
  echo "$(basename $f | cut -c1-7) $(grep -E 'Uniquely mapped reads % |mapped to multiple loci |too short ' $f | grep -oE '[0-9]+\.[0-9]+%' | tr '\n' ' ')"
done
```

对照矫正版第 5 节表跑表逐行核对 (HBR 51.7–51.8 / UHR 44.6–48.5)。

练习 4——fastp 保留率:

```
cd RNA-seq/results/homework/04_fastp
python3 -c "
import json,glob
for f in sorted(glob.glob('*_fastp.json')):
  s=json.load(open(f))['summary']
  print(f.split('_ERCC')[0], s['before_filtering']['total_reads'],'->',s['after_filtering']['total_reads'])"
```

练习 5——SEQC 真值自检: 看两轮 09_R/volcano_plot.pdf 的标签 (或 log/ 里 R 分析日志的 top 基因打印) ——上调的是不是 IGLC2/IGLC3 (UHR 的免疫球蛋白信号)、下调的是不是 SYNGR1/YWHAH/MIAT 一簇 (HBR 脑富集)? 两轮方向完全一致、top 基因同名——这就是“深度买检出数、不买不同答案”。

练习 6——样本身份为什么只靠位置:

```
cd RNA-seq/results/homework/08_salmon_quasi && ls -d *_quasi.salmon_quant
# 字母序恰好 HBR×3 在前、UHR×3 在后——教程的 condition 向量因此恰好对
# 若文件名换个前缀, 设计矩阵静默错位 (矫正版 RNA-01)
```

练习 7——解开 quant.sf.gz 看计数矩阵的样子:

```
cd RNA-seq/results/homework/08_salmon_quasi
gzip -cd *_quasi.salmon_quant/quant.sf.gz | head -5
gzip -cd *_quasi.salmon_quant/quant.sf.gz | wc -l    # → 231,449 (表头+全转录本)
```

4. 未入库的大文件在哪

类别	位置
原始/trimmed FASTQ、STAR BAM（基因组+转录本坐标）、完整 salmon 目录	两轮集群运行目录 (/lustre1/user/bjx131_pkuhpc/rna_run_mini_20260921/、 rna_run_homework_20261009/)
STAR 索引 (chr22 mini 381 MB / 全 GRCh38 ≈31 GB 内存)	/lustre1/share/RNA_seq_class/genome/、 /lustre1/share/RNA_seq/genome/（教师预建）
salmon 索引、转录本 fasta、注释 RDS	同上（教师预建）
教师参考产物（GO_dotplot、带 ENST 行名的热图等）	/lustre1/share/RNA_seq/

)

5. 一句话总结

管线产物本身都健全（两轮数字互相咬合、与教师参考在可对拍处一致）；真正值得学的东西在**接缝**里——位置身份、双模式映射率口径、版本号键错配、“‘伪注释——而它们的证据全部可以在本仓库内亲手复现。