

RNA-seq 全流程教程 · 矫正增强版（中文版）

Contents

RNA-seq 全流程教程 · 矫正增强版（中文版）	1
0. 关于本版	1
1. 问题清单速览	2
2. 环境与数据	3
3. 数据获取与原始质控	4
4. 接头与质量修剪	5
5. 剪接比对（STAR）	5
6. 汇总质控（multiqc）	7
7. 定量 I：比对模式（salmon align）	7
8. 定量 II：选择性比对模式（salmon quasi / --validateMappings）	7
10. 差异表达、注释与火山图（glmLRT + volcano）	9
11. 富集分析（GO——以及永远跑不起来的 KEGG）	10
12. 热图——沉默的全 NA 坑	11
13. 双轮对比（mini vs homework/全量）	11
14. 检查清单、产物清单与总结	12
附录 A. 偏差日志（两轮，节选但忠实原文）	13
附录 B. 教师参考产物 vs 印刷版文档（取证，路径原文）	13
附录 C. 复现	14

RNA-seq 全流程教程 · 矫正增强版（中文版）

: 文档版本 1.0 · 2026-10-09 · 以 RNA_seq_tutorial_mini.html 与 RNA_seq_homework.html（课程原件）为底本复现，辅以两轮全链路实践（mini 轮 2026-09-21、homework/全量轮 2026-10-09），所有偏差逐条实证、记录并矫正。命令、路径、参数一律保持原文；关键数字与英文版（RNA_seq_tutorial_corrected.md）逐一对拍一致。

0. 关于本版

本版是 WES 矫正版路线图（WES/ref/WES_roadmap_corrected.md）的 RNA-seq 对应篇：课程原件的命令原文照录，再补上原件没有的东西——每一步的原理讲解、两轮实践的实测数字、带根因的坑位登记表，以及**实际执行并验证过的矫正**。

底本（课程原件，保持原样）：

文件	角色
RNA_seq_tutorial_mini.html	9 步 mini 管线（每样本 1 万条读段），课堂可执行路径
RNA_seq_homework.html	同一管线的全量版（全深度读段 + 完整 GRCh38 索引）
rna_seq.pdf	14 页理论课幻灯（RNA-seq 原理、STAR/Salmon 定位、R 基础）
RNA_seq_code_explanation.pdf	9 页逐行命令讲解

)

两轮复现（两轮均：命令原文、最小包装、偏差全记录）：

轮次	日期	数据	STAR 索引	运行位置	耗时
mini	2026-09-21	12 个 fastq × 10,000 reads (20 MB)	chr22 mini (381 MB)	登录节点，串行	~4 分钟

轮次	日期	数据	STAR 索引	运行位置	耗时
homework (全量)	2026-10-09	12 个 fastq, 11.8 万 -22.7 万 读对 (112 MB)	完整 GRCh38 (约 31 GB 内存)	登录节点, 串行	13 分钟

)

为什么在登录节点跑。 教程的原生模式就是登录节点交互式执行——两份 HTML 里没有任何 sbatch/srun/SLURM 字样，与集群相关的命令只有开头一句 ssh。教师自己的负载测试脚本 (02_simulate_30_students_pipeline.sh, 产物在 /lustre1/share/RNA_seq_class/loadtest/mini30_20260928_*) 模拟的就是 **30 个学生同时在登录节点跑这条管线**——这是课程设计预期登录节点运行的直接证据。mini 轮适逢全校性 SLURM 提交瘫痪 (所有 sbatch 报 Invalid account or account/partition combination; sacct 自 9/15 起零记录; 9/20 跑成功过的 WES 脚本原样重提同样被拒——集群侧重组所致, 已记入该轮偏差日志)。homework 轮按明确指令在登录节点跑——尽管开跑前探测时 SLURM 已恢复 (test-only 可在 cn-long 分配)。两次选择都记录在各自的 log/deviations.log。

“矫正”的含义 (与 WES 版同一纪律): 照印刷版命令原样跑、把踩到/预见的坑全部记录在案, 然后用真实产物执行并验证修复——修复的证据在本仓库里, 不是口头描述。本文所有数字均来自两轮实跑的测量值, 不是估计值。

每步的读法: 每个管线步骤都带同一组小节——原文 (印刷版命令原样)、原理 (工具与关键参数到底在做什么)、实跑 (两轮实测数字)、坑 (已实证, 带证据)、解读、调优、扩展 (这步熟练后往哪走)。

1. 问题清单速览

课程原件中已实证的坑。完整证据与矫正见各步骤小节; 两条最重要的 (RNA-07/09) 有专门章节。

编号	位置	症状 / 根因	矫正
RNA-01	R sample_info	样本身份 全程只靠位置 : condition 假定 list.files() 恰好返回 HBR×3 在前 (字母序运气), 文件未命名使 colnames = NULL, edgeR 造出 Sample1-6	显式命名样本; 建设计矩阵前先断言顺序
RNA-02	mini 单样本 salmon	演示单元格缺 --gcBias --seqBias, 批量脚本却带 → 演示与批量输出存在系统性校正差异	全部用批量脚本的参数
RNA-03	homework 单样本 salmon	align 模式演示单元格文件名拼接错乱 (UHR 样本名 + 粘贴来的 HBR_ERCC-Mix2... chr22 后缀) → 找不到文件	批量脚本是对的; 用批量
RNA-04	homework batch_salmon_quasi	for r1 in *read1.fastq.gz 只匹配 原始 读段——quasi 模式定量的是 未修剪 数据 (mini 的 direct 模式用的是 trimmed)	照原文跑并记录; 或把 glob 指向 *.read1.trimmed.fastq.gz
RNA-05	homework batch_STAR.sh	shebang 印成 !/bin/bash (丢了 #)	化妆性问题; 用 bash script.sh 跑
RNA-06	homework multiqc 单元格	占位路径 /lustre1/share/RNA_seq_student/yourfold	指向真实工作目录
RNA-07	合并版 “CODES” 单元格 (两份文档都有)	KEGG 块被 '...' 包住—— R 里这不是注释 : 整体解析成一个巨型字符串字面量	分步单元格用 # 注释是对的; 合并版单元格一律当非可执行文本

编号	位置	症状 / 根因	矫正
		(静默空操作), 块内一旦出现单引号就会提前闭串、剩余代码变成 活代码	
RNA-08	homework 合并版“CODES”单元格	仍在过滤“_direct” (mini 命名) -----homework 产物叫 _quasi → 找到 0 个文件, 下游崩	走分步路径 (grepl("quasi"))
RNA-09	homework 热图块	gene_map 用 带版本号 的 transcript_id 做键, 查询用的 rownames 却已剥版本号 → 全部落空 → 50 行标签全渲染成 “NA”, 静默无报错	map 键同样剥版本号 (一行修复); 已验证 0/50 NA
RNA-10	教师参考产物	教师 heatmap_DEG.pdf 的行标签是 带版本号的 ENST ID ——既不是基因名也不是印刷版代码会产出的全 NA: 参考跑用的是第三种代码变体	参考产物不能当这块的对照基准; 见附录 B
RNA-11	教师 class.R	salmon_files <- salmon_files[-2] 丢掉第 2 个样本——教师自己目录的清理动作, 不是方法	不要照抄; 与参考对拍时留意
RNA-12	解读坑	quasi/direct 模式映射率仅 30-37% (选择性比对偏保守); align 模式报 100% (输入 BAM 本来就是已比对片段)——两者分母不可比	只在同一模式内部比较映射率
RNA-13	两份文档	单样本演示 --runThreadN 1 vs 批量脚本 4——1 是 30 人课堂的负载决定, 不是技术上限	独跑可放开线程 (注意共享登录节点)
RNA-14	R 启动	本集群上 R 不先 export LC_ALL=C/LANG=C 会 段 错 误 (address (nil) ... Segmentation fault)	进 R 前导出两个变量 (教程自带此说明, 保留)
RNA-15	火山图	ggrepel: N unlabeled data points——信息性提示 (mini 9 条、全量 280 条), 只是去拥挤	良性; 想多标就调大 max.overlaps

)

2. 环境与数据

原文 (两份文档的设置单元格):

```
ssh .....
mkdir /lustre1/share/RNA_seq_student_2026_homework/{studentId}_{name}
cd /lustre1/share/RNA_seq_student_2026_homework/{studentId}_{name}
conda activate RNA-seq
```

原理。共享环境 (/lustre1/share/miniconda3/envs/RNA-seq) 带齐了管线所需全部工具, 由课程钉死版本: fastp 0.23.4、FastQC 0.12.1、STAR 2.7.11b、salmon 1.10.3、multiqc、samtools、gffread, 以及 R 4.4.0 (edgeR/limma/tximport/ggplot2/ggrepel/pheatmap/clusterProfiler/org.Hs.eg.db/biomaRt 全装)。用共享环境而不是每人自装, 是 30 人课堂能跑起来的前提, 也是教师负载测试所验证的对象。

数据是 SEQC——唯一带真值标签的 RNA-seq 数据集。六个双端文库：HBR ×3 (Human Brain Reference, 脑参考 RNA) 与 UHR ×3 (Universal Human Reference RNA, 通用参考 RNA)，各掺 ERCC 对照 (HBR 用 Mix2、UHR 用 Mix1)。这里的”差异表达”有已知答案：脑富集基因在 HBR 高；UHR 是多组织混样 (含免疫细胞 RNA)，免疫球蛋白转录本高。本版后面所有结果核验都靠这个真值 (第 10 节)。文件名里的 chr22/ErccTranscripts 标明 FASTQ 已被预筛到 chr22 (+ ERCC) 内容。

教师预建资源 (不要重建——原件把建索引单元格标了 Do NOT RUN)：

资源	路径	大小	谁用
chr22 mini STAR 索引	/lustre1/share/RNA_seq_class/genome/mini_ref_chr22/star_index	381 MB	mini 轮 STAR
chr22 mini salmon 索引	.../mini_ref_chr22/salmon_index	小	mini 轮 direct 模式
chr22 转录本 fasta	.../mini_ref_chr22/chr22.transcripts.fa	小	mini 轮 align 模式
完整 GRCh38 STAR 索引	/lustre1/share/RNA_seq/genome	SA 24.9 GB + Genome 3.2 GB + SAindex 1.6 GB (加载约 31 GB 内存)	homework 轮 STAR
完整转录本 fasta	/lustre1/share/RNA_seq/genome/GRCh38_no_alt_analysis_set_gencode.v36.transcripts.fa	368 MB	homework align 模式
完整 salmon 索引 (k31)	/lustre1/share/RNA_seq/genome/salmon_index	801 MB	homework quasi 模式
基因注释 RDS	/lustre1/share/RNA_seq_class/genome/gene_anno_gencode.v36.rds	—	R 注释 (transcript_id → gene_name)

)

数据规模 (两轮实测)：

轮次	文件	每样本读对	fastp 保留
mini	12 × 10,000 reads	10,000 reads (5,000 对)	— (轻度修剪)
homework	12 个 fastq.gz (112 MB)	HBR 118,571–144,826; UHR 162,373–227,392	97.4–98.7%

)

3. 数据获取与原始质控

原文 (homework; mini 形状一致)：

```
rsync --progress /lustre1/share/RNA_seq/RNA_seq_files/*.fastq.gz .
find . -name "*.fastq.gz" -exec fastqc {} -d . -o . \;
totalreads=$(unzip -c HBR_Rep1_ERCC-Mix2_Build37-ErccTranscripts-chr22.read2_fastqc.zip */fastqc_data.txt | grep 'Total Sequences' | cut -f 2)
echo "Total Sequences: $totalreads"
```

原理。用 rsync 而不是 cp：走 Lustre 有进度条、可断点续传。逐文件 FastQC 出标准模块组 (每碱基质量、接头痕迹、重复率、GC)；homework 那句 DO NOT UNZIP 一语双关——读段必须保持 gzipped (后面 STAR 要 --readFilesCommand zcat)，而 unzip -c 是不解压直接从 zip 里流式读 fastqc_data.txt。

实现。两轮各 12 个 fastqc zip。逐文件 Total Sequences 确认了上面规模表 (mini 每文件 10,000；homework read1 = read2 计数，每文件 118,571…227,392)。

坑。这步没有新增坑 (常见坑：在错误目录跑 fastqc 会静默什么都找不到；find -exec 是串行——这个量级无所谓)。

调优。 FastQC 有 `-t` 线程参数；12 个文件用不上。**扩展。** multiqc（第 6 节）会汇总这些报告；fastq_screen 可加污染筛查。

4. 接头与质量修剪

原文（批量单元格；单样本演示是同一条命令的单次形式）：

```
for file in *.read1.fastq.gz
do
    base=$(basename "$file" .read1.fastq.gz)
    read1_file="${base}.read1.fastq.gz"
    read2_file="${base}.read2.fastq.gz"
    output_read1="${base}.read1.trimmed.fastq.gz"
    output_read2="${base}.read2.trimmed.fastq.gz"
    json_report="${base}.fastp.json"
    html_report="${base}.fastp.html"
    fastp -i "$read1_file" -I "$read2_file" -o "$output_read1" -O "$output_read2" --
detect_adapter_for_pe -l 25 -j "$json_report" -h "$html_report"
done
```

原理。 `--detect_adapter_for_pe` 靠双端读段重叠区自动推断接头对——不需要预先知道接头序列。`-l 25` 在修剪后丢弃短于 25 bp 的读段（STAR 对超短输入会退化）。每样本的 JSON/HTML 一对，正是后面 multiqc 要吃的。

实跑（homework 轮，六个样本）：

样本	读入	读出	保留
HBR_Rep1	237,142	234,120	98.7%
HBR_Rep2	289,652	285,044	98.4%
HBR_Rep3	259,572	256,166	98.7%
UHR_Rep1	454,784	444,834	97.8%
UHR_Rep2	324,746	317,040	97.6%
UHR_Rep3	370,884	361,336	97.4%

)

解读。 保留率 97–99% 说明文库干净：接头少、质量高——与商品化参考 RNA 一致。UHR 修剪略多于 HBR（混样成分，短片段稍多）。

坑。 本步无新坑；注意 trimmed 文件名 (*.read1.trimmed.fastq.gz) 是 STAR 循环匹配的目标，而 homework quasi 模式循环匹配的是原始名（RNA-04）——两个 glob 编码了两种不同的预处理意图。

调优。 `--qualified_quality_phasing/--cut_front` 等参数存在，但 SEQC 文库都用不上。**扩展。** cutadapt/trim-galore 是等价替代；双端重叠检测若过度修剪，收紧 `--overlap_len`。

5. 剪接比对（STAR）

原文（homework 批量脚本；单样本演示除 `--runThreadN 1` 外一致）：

```
GENOMEDIR="/lustre1/share/RNA_seq/genome"
for file in *.read1.trimmed.fastq.gz
do
    base=$(basename "$file" .read1.trimmed.fastq.gz)
    read1_file="${base}.read1.trimmed.fastq.gz"
    read2_file="${base}.read2.trimmed.fastq.gz"
    output_prefix="${base}"
    STAR --runThreadN 4 \
        --genomeDir $GENOMEDIR \
        --readFilesIn "$read1_file" "$read2_file" \
        --outFileNamePrefix "$output_prefix" \
        --readFilesCommand zcat \
```

```
--outSAMtype BAM Unsorted \
--outFilterType BySJout \
--alignSJoverhangMin 8 \
--outFilterMultimapNmax 20 \
--alignSJDBoverhangMin 1 --outFilterMismatchNmax 999 \
--outFilterMismatchNoverReadLmax 0.04 \
--alignIntronMin 20 \
--alignIntronMax 1000000 \
--alignMatesGapMax 1000000 \
--quantMode TranscriptomeSAM \
--outSAMattributes NH HI AS NM MD
```

done

原理（起作用的参数）。STAR 是剪接感知的：先精确 k-mer 播种（100 bp 读段默认 50），再延伸，并对照索引内置的剪接位点库给内含子的比对打分。--outFilterType BySJout：内含子的比对，其剪接位点必须有至少一条其他读段（或注释 SJ 库）支持才保留——过滤垃圾内含子的主力。--alignSJoverhangMin 8：新 junction 两侧各需 ≥8 bp 悬挂。--outFilterMultimapNmax 20：最多 20 个位点（免疫球蛋白与重复区是真的多比对）。--outFilterMismatchNmax 999 加 --outFilterMismatchNoverReadLmax 0.04：合并起来把错配上限定在读段长度的 4%。内含子 20…1,000,000 与 mates-gap 1 Mb 是 GENCODE 兼容包络。--quantMode TranscriptomeSAM 是**本步的承重选择**：额外产出 <prefix>Aligned.toTranscriptome.out.bam（坐标换算到转录本空间）——正是 salmon align 模式（第 7 节）要吃的输入。--outSAMattributes NH HI AS NM MD 输出多比对层级与错配标签，下游工具要。

实跑（unique / multi / 太短，逐样本）：

轮次	样本	Unique %	多位点 %	太短 %
mini	HBR_Rep1	53.25	0.68	12.48
mini	HBR_Rep2	53.03	0.68	11.98
mini	HBR_Rep3	53.33	0.48	12.90
mini	UHR_Rep1	46.76	2.02	11.86
mini	UHR_Rep2	49.94	2.08	11.49
mini	UHR_Rep3	45.06	1.90	12.87
homework	HBR_Rep1	51.82	1.09	47.08
homework	HBR_Rep2	51.70	1.11	47.19
homework	HBR_Rep3	51.77	1.06	47.17
homework	UHR_Rep1	45.30	2.77	51.92
homework	UHR_Rep2	48.47	3.02	48.50
homework	UHR_Rep3	44.56	2.77	52.66

)

解读。三个信号，全部跨轮跨深度稳定：(1) **HBR 比 UHR 高约 5 个点**——脑参考是单组织 RNA，免疫球蛋白/重复转录本少；UHR 混样含 IG 基因，天然多比对（UHR 多位点 1.9–3.0% vs HBR 0.5–1.1%）。(2) **1 万条读段的 mini 与 10 万+ 对的全量轮 unique 率几乎相同**（HBR 53.0–53.3 vs 51.7–51.8；UHR 45.1–49.9 vs 44.6–48.5）——比对画像由读段性质决定，与深度无关。(3) homework 轮 ~47–53% 的“unmapped: too short”（mini 同一批读段仅 11–13%，差别在索引）是**全基因组索引 + BySJout 组合**在预筛文库上的属性：最优全基因组比对低于过滤阈值的读段被记成“太短”。mini 的 chr22 索引复现的是课程自己的数字；全量索引用覆盖换严格度。记录即可不必慌：进入定量的 unique 比对部分是一致的。

坑。RNA-05（印刷版批量脚本 shebang 丢了 #——化妆性）。RNA-13（线程 1 vs 4——课堂负载设计；我们 homework 轮用 4 并加内存守卫：每次 STAR 调用前等待 MemAvailable ≥ 37 GB，因为加载全量索引要 ~31 GB 且登录节点共享）。mini 索引只要 ~0.4 GB——那轮不需要守卫。

调优。节点空闲时上调 `--runThreadN`；`--twopassMode Basic` 提升新 junction 灵敏度（约 2 倍耗时）；后面要跑基因组坐标工具的话 `--outSAMtype BAM SortedByCoordinate` 可省一次 `samtools sort`。

扩展。`samtools sort/index + flagstat` 做 BAM QC；RSEQC（`infer_experiment`、`inner_distance`）查链特异性与插入分布；`--quantMode GeneCounts` 在转录本 BAM 之外顺手出一份原始计数矩阵。

6. 汇总质控 (multiqc)

原文 (homework 单元格；mini 用真实工作目录)：

```
multiqc /lustrel/share/RNA_seq_student/yourfold
```

原理。multiqc 扫一遍目录树，认出它认识的工具产物（`fastqc zip`、`fastp JSON/HTML`、`STAR Log.final.out`、`salmon quant.sf` 等），合并成一份按样本分列的报告——一眼看全 12 个 fastq 与 6 个样本的最快方式。

跑。`multiqc "$PWD" -o multiqc_report`（RNA-06：印刷路径是占位符——yourfold 字面就是“你的目录”）。两轮都产出了汇总报告；本文引用的 STAR 与 fastp 数字都可在其中交叉核对。

坑。RNA-06（占位路径）。另注意：multiqc 只汇报指定路径下找到的东西——指错目录会“成功”地产出空报告而不是报错。

调优。`-f` 重建、`--cl` 把命令行嵌进报告、写个 `multiqc_config.yaml` 钉死教学用的模块顺序。**扩展。**`--pdf` 导出；管线中点（STAR 后）与终点各跑一次得到前后对照视图。

7. 定量 I：比对模式 (salmon align)

原文 (homework 批量单元格——正确版；单样本单元格的拼接错乱文件名见 RNA-03)：

```
TRANSCRIPTOME="/lustrel/share/RNA_seq/genome/GRCh38_no_alt_analysis_set_gencode.v36.transcripts.fa"
for bam_file in $(ls Aligned.toTranscriptome.out.bam); do
    sample_name=$(basename "$bam_file" Aligned.toTranscriptome.out.bam)
    salmon quant -t "$TRANSCRIPTOME" --libType A -a "$bam_file" -o "${sample_name}"
    _align.salmon_quant --gcBias --seqBias
    echo "Processed: $sample_name"
done
```

原理。这是基于比对的定量：读段落落在哪已由 STAR 决定；salmon 的 align 模式（`-a`）吃转录本坐标 BAM，把多比对读段按 EM 做分数分配，估计每条转录本的丰度。`--gcBias --seqBias` 从比对本身估计并校正序列内容与 GC 偏好。`-t` 是 BAM 里转录本名所指的转录本 fasta；`--libType A` 让 salmon 自己推文库类型。

跑。两轮各六样本，全部 **100.0% 片段” mapped”**——这不是质量数字：输入 BAM 里只有 STAR 已比对的片段，分母是“已比对片段”而非“文库读段”（RNA-12）。

坑。RNA-03（单样本演示单元格的文件名是 UHR/HBR 粘贴混排——照抄就在找不到文件处报错）。RNA-02（mini 单样本单元格缺 `--gcBias --seqBias`、批量带——一个样本用演示命令、其余用批量脚本，会造成跨样本的系统性校正差异）。

解读。align 模式继承 STAR 的全部决定（junction 过滤、多比对上限、“太短”丢弃）。它的计数是“STAR 眼中的转录本组”；quasi 模式（第 8 节）是 salmon 自己的、更保守的视角——两种都跑的意义就在这个对照。

调优。`-p` 线程；怀疑位置衰减加 `--posBias`。**扩展。**RSEM 是同类 BAM 的经典替代；`--numBootstraps` 加不确定性重采样，`tximport` 可接。

8. 定量 II：选择性比对模式 (salmon quasi / --validateMappings)

原文 (homework 批量单元格)：

```
INDEX="/lustrel/share/RNA_seq/genome/salmon_index"
for r1 in $(ls read1.fastq.gz); do
    base=$(basename "$r1" .read1.fastq.gz)
    r2="${base}.read2.fastq.gz"
    salmon quant -i $INDEX \
        -l A \
```

```

-1 "$r1" \
-2 "$r2" \
--validateMappings \
--gcBias --seqBias \
-p 8 \
-o "${base}_quasi.salmon_quant"
echo "Processed: $base"
done

```

原理。 quasi 模式把原始读段直接对到转录本索引（没有基因组、无需发现 junction）。--validateMappings (salmon ≥1.0 的默认引擎) 用选择性比对验证候选映射——由比对分数阈值决定取舍而非纯 k-mer 命中，所以映射率读起来比 STAR 低：没有好比对的读段被丢弃而不是硬塞。

实验（映射率，取自各目录 aux_info/meta_info.json 的 num_mapped / num_processed）：

轮次	模式	HBR_Rep1	HBR_Rep2	HBR_Rep3	UHR_Rep1	UHR_Rep2	UHR_Rep3
mini	direct (trimmed 读段)	36.5%	36.5%	36.4%	33.8%	31.2%	32.2%
homework	quasi (原始读段，照原文)	35.2%	35.3%	35.1%	32.6%	30.3%	32.0%

)

坑。 RNA-04 是重点：for r1 in *read1.fastq.gz 只匹配原始文件 (*.read1.trimmed.fastq.gz 结尾不同)，所以 homework 的 quasi 模式定量的是未修剪读段，而 mini 的 direct 模式定量的是 trimmed——我们照原文跑了并记录（接头片段短，映射率几乎不动，但两份文档的预处理故事不一致）。另有 RNA-12：这里的 30–37% 对 align 模式的 100% 是分母不同，不是质量崩塌。

解读。 ~1/3 的映射率由两个独立因素决定：读段被预筛到 chr22+ERCC 内容而索引是 231,448 条转录本的全 GENCODE v36 (salmon 丢弃无处可比的读段)，加上选择性比对的分数阈值。比率跨轮惊人稳定（HBR 35.1–36.5%、UHR 30.3–33.8%）——还是文库性质，两个深度都可复现。

调优。 -p 8 是 homework 批量单元格印的数——在共享登录节点上这已经是实打实的线程预算。**扩展。** --numBootstraps 100 配 tximport 的 countsFromAbundance 得到带自助方差的定量；--seqBias 与片段长度分布有交互——QC 时看输出里的 fldLen.png。## 9. 读入定量结果并过滤 (tximport → edgeR)

原文（R 单元格，分步路径）：

```

salmon_files <- list.files(pattern = "quant\\.sf$", full.names = TRUE, recursive = TRUE)
salmon_files <- salmon_files[grepl("quasi", salmon_files)] # homework; mini 过滤 "_direct"
txi <- tximport(salmon_files, type = "salmon", txOut = TRUE)
dge <- DGEList(counts = txi$counts)
counts_threshold <- 10
samples_threshold <- 2
keep <- rowSums(dge$counts >= counts_threshold) >= samples_threshold
dge_filtered <- dge[keep, ]
sample_info <- data.frame(
  sample = colnames(dge_filtered),
  condition = factor(c(rep("HBR", 3), rep("UHR", 3))) # change based on samples
)
design <- model.matrix(~condition, data = sample_info)

```

原理。 tximport 把各样本的 quant.sf (Name、Length、TPM、NumReads) 收进一个矩阵；txOut = TRUE 保持转录本层级的行（全量索引 231,448 行）。过滤 (≥10 counts 且 ≥2 样本) 删掉稀疏到没法建模的行——在本文库规模下那是几乎全部，这是数据集构造使然（chr22+ERCC 来源的读段对全转录本索引）。

实验（建设计矩阵之前该查的东西——RNA-01）：

检查	mini	homework
索引内转录本数	4,989 (chr22 mini)	231,448 (全 GENCODE v36)
过滤后保留	111	831
colnames(txi\$counts)	NULL → Sample1--6	NULL → Sample1-6
救了场的那点运气	HBR×3 在前 (字母序)	HBR×3 在前 (字母序)

)

坑。RNA-01 是结构性问题，共三环：(1) list.files() 返回字母序，而印刷版 condition 向量写死 HBR 在前——**只靠文件名的字母序运气**才对；(2) 文件未命名传入，colnames 是 NULL，edgeR 造出 Sample1-6——样本身份从此纯靠位置；(3) 下游（设计矩阵、对比、热图 sample_info 行名）没有任何东西能拦住一次错位。一行修复：给 salmon_files 命名，再由名字构造 condition。两轮的检查输出如上——顺序两次都成立，是记录而非假设。RNA-14：进 R 前 export LC_ALL=C; export LANG=C（教程自带此说明）。

解读。111/4,989 与 831/231,448 看似存活率不同，实为同一现象在两种索引广度下：两轮都只有 ~2% 的行过关。深度决定多少转录本过 10 counts (111 → 831)，索引决定分母。

调优。随深度上调 counts_threshold (10 是本教学规模；全转录本研究常用 ≥10-20 的 CPM 类门槛)。**扩展。**txOut = FALSE 配 tx2gene 表在建 edgeR 前聚合到基因层级（更常见的生产路径）；DESeq2 配 tximport 是即插即用的替代；rtracklayer/biomaRt（教程已加载）可重建注释。

10. 差异表达、注释与火山图 (glmLRT + volcano)

原文 (R 单元格)：

```
dge_filtered <- estimateDisp(dge_filtered, design)
fit <- glmFit(dge_filtered, design)
results <- glmLRT(fit)
results_table <- topTags(results, n = Inf)$table
results_table$regulate <- ifelse(results_table$FDR < 0.05 & results_table$logFC > 1, "up-regulated",
                                ifelse(results_table$FDR < 0.05 & results_table$logFC < -1,
                                "down-regulated", "not sig"))
gene_anno <- readRDS("/lustre1/share/RNA_seq_class/genome/gene_anno_gencode.v36.rds")
rownames_nover <- sub("\\..*$", "", rownames(results_table))
anno_transcript_nover <- sub("\\..*$", "", gene_anno$transcript_id)
match_index <- match(rownames_nover, anno_transcript_nover)
results_table$gene_name <- gene_anno$gene_name[match_index]
results_table$label <- ifelse(results_table$regulate != "not sig", results_table$gene_name,
NA_character_)
```

原理。edgeR 的广义线性模型路径：estimateDisp 估计负二项离散度，glmFit 拟合，glmLRT 对最后一个模型项做似然比检验（这里是 conditionUHR）。regulate 规则是合取：FDR<0.05 且 |logFC|>1——统计显著与效应量一起卡，这也是火山图虚线画在 ±1 与 -log10(0.05) 的原因。注释块把 GENCODE 版本后缀剥掉 (ENST00000615943.1 → ENST00000615943)，**两侧都剥**再做 match()——注意这正是热图块忘掉的那条纪律（第 12 节）。

实跑：

	mini	homework (全量)
up-regulated	15	171
down-regulated	30	148
not sig	66	512
Matched (gene_name)	111 / 111	831 / 831
top up (按 FDR)	IGLC2 (logFC ≈ +10.3, FDR ≈ 1e-145)、IGLC3、XBP1、MYH9	IGLC2、IGLC3、...

	mini	homework (全量)
top down	MIAT (≈ -8.5)、YWHAH、MAPK8IP2、ACO2、SYNGR1、SEPTIN3、CBX7	SYNGR1、SEPTIN3、YWHAH、RPL3、CBX6、...

)

解读——SEQC 真值核验。每个方向都与已知答案一致：**UHR 上调**：免疫球蛋白 lambda 链 IGLC2/IGLC3 (UHR 混样含免疫细胞 RNA) ——教科书级；**HBR 高 (即 UHR 下调)**：MIAT、YWHAH、MAPK8IP2、ACO2、SYNGR1、SEPTIN3——脑富集转录本。两个深度下 top 基因是同一条转录本 (IGLC2, $|\log FC| > 10$, FDR $\sim 1e-145$) ——信号在 1 万读段时已饱和；深度买到的是**更多**被检出的基因 (45 $\rightarrow$ 319)，不是不同答案。这正是 mini/homework 配对的核心课程点。

坑。RNA-15 (ggrepel: 9 / 280 unlabeled——去拥挤提示，良性)。glmLRT 收拟合对象；多传参数会改变被检验项 (mini 轮收割时踩过并当场纠正——教程原文 glmLRT(fit) 才是对的)。

调优。topTags(n = Inf) 再按 logFC 排序，能看见被 FDR 排序遮住的大效应基因。**扩展。**decideTests 跨对比做 Venn；topTags 默认 BH 校正就是这里的 FDR。

11. 富集分析 (GO——以及永远跑不起来的 KEGG)

原文 (分步单元格——可执行路径)：

```
gene_list <- results_table$gene_name[results_table$regulate == "up-regulated"]
gene_list <- gene_list[!(is.na(gene_list) | gene_list == "")]
#KEGG analysis
#entrez_ids <- mapIds(...)
#kegg_enrich <- enrichKEGG(...)
#go analysis
go_enrich <- enrichGO(gene = gene_list, OrgDb = org.Hs.eg.db, keyType = "SYMBOL",
                      ont = "ALL", pvalueCutoff = 1, qvalueCutoff = 1)
go_dotplot <- dotplot(go_enrich, showCategory = 10, title = "GO Enrichment")
ggsave("GO_dotplot_up_regulate.pdf", plot = go_dotplot, width = 7, height = 5)
```

原理。富集问的是：上调基因集相对背景在注释条目上是否过度代表。keyType = "SYMBOL" 直接喂基因符号 (免手工转 ID)；ont = "ALL" 合并 BP+MF+CC；pvalueCutoff = 1 关掉展示侧阈值，让 top-10 按真实显著性排序。

实跑。mini 15 个上调基因 / homework 171 个。homework top GO 条目 (p.adjust 0.0075–0.0088)：viral RNA genome replication、single-stranded viral RNA replication via double-stranded DNA intermediate、glycosyl compound catabolic process、protein targeting to mitochondrion、DNA dealkylation、cytidine catabolic process、cytidine deamination、cytidine-to-uridine editing。教师参考 GO_dotplot.pdf 的 top 条目相同 (viral RNA genome replication、glycosyl compound catabolic process, p.adjust 0.0075) ——与参考交叉验证通过，不只是自治。

坑——RNA-07/08，都在合并版“CODES”单元格上。分步单元格用 # 注释掉 KEGG (正确)。合并版单元格却把整个 KEGG 块包进 ‘...’。R 里 ‘...’ **不是**注释：它解析成空串 ‘’ 加一个开串符 ‘，于是整块变成一个巨型字符串字面量，被 R 求值后自动打印——它碰巧表现得像个块注释，什么都不做。失效模式是潜伏的：块内一旦出现单引号就会提前闭串，剩余代码全部变成活代码。一律把 ‘...’ 块当非可执行文本。RNA-08：homework 的合并版单元格还在过滤 “_direct” (mini 命名)——homework 产物叫 _quasi，它找到零个文件、死在 tximport；分步路径 (grep1(“quasi”)) 才是可执行的。

解读。cytidine deamination / cytidine-to-uridine editing 一簇不是噪声：表达免疫球蛋白的细胞靠 AID/APOBEC 驱动的胞嘧啶脱氨做亲和成熟——GO 读出的正是火山图上同一个 IG 信号。viral RNA genome replication 一类条目是上调集里 IG/ERV 区基因的注释侧效应 (教师参考同样显示，可对照读)。

调优。enrichKEGG 需要 ENTREZ ID (被注释的块里做了转换) 且要访问 KEGG REST 网络——这就是它常被课堂略过的原因。**扩展。**compareCluster 跨上调/下调/并集比较；GSEA (gseGO) 吃整个排序表，用的信息比 top 集多。

12. 热图——沉默的全 NA 坑

原文 (homework 热图块, 逐字):

```
logCPM_scaled <- cpm(dge_filtered, log = TRUE, prior.count = 1)
rownames(logCPM_scaled) <- sub("\\..*$", "", rownames(logCPM_scaled))
degs <- results_table[results_table$FDR < 0.05 & abs(results_table$logFC) > 1, ]
top50 <- head(rownames(degs[order(degs$FDR), ]), 50)
top50_clean <- sub("\\..*$", "", top50)
logCPM_scaled_sub <- logCPM_scaled[top50_clean, ]
gene_map <- setNames(gene_anno$gene_name, gene_anno$transcript_id)
rownames(logCPM_scaled_sub) <- gene_map[rownames(logCPM_scaled_sub)]
rownames(sample_info) <- colnames(logCPM_scaled)
pdf("heatmap_DEG.pdf", width = 10, height = 8)
pheatmap(logCPM_scaled_sub, cluster_rows = TRUE, cluster_cols = TRUE,
          show_rownames = TRUE, annotation_col = sample_info,
          main = "Heatmap of Differentially Expressed Genes")
dev.off()
```

坑链, 一环一环。第 2 行把 rownames 剥掉版本号 (ENST00000390323.5 → ENST00000390323); 第 6 行建 gene_map 用的是带版本的键 (setNames(gene_anno\$gene_name, gene_anno\$transcript_id)——没剥); 第 7 行拿剥过号的 rownames 查带号的 map → 全部落空; 把全 NA 向量赋给 rownames 在 R 里合法; pheatmap 照样渲染——五十行全标 “NA”, 无报错无警告。我们实跑产出的 heatmap_DEG.pdf 用 pdftotext 抽出来正好 50 个 NA。这与第 10 节注释块是同一类版本号错配——那块两侧都剥所以对——mini 版的热图块也是对的 (一个 clean_id() 帮手同时作用于数据行与注释 ID, 外加 make.unique() 和 labels_row =)。

一行矫正 (已执行并验证):

```
gene_map <- setNames(gene_anno$gene_name, sub("\\..*$", "", gene_anno$transcript_id))
```

矫正后运行 (heatmap_DEG_corrected.pdf): 0/50 NA, 行标签是 IGLC2、IGLC3、MCM5、SERPIND1、LIF、...——真实的 top DEG 基因。

坑。RNA-09 (上述)。RNA-10: 教师参考 heatmap_DEG.pdf 的行标签是带版本的 ENST ID——既非基因名 (mini 风格) 也非全 NA (印刷版 homework 风格): 参考跑用的是又一种代码变体, 不能当这块的对拍基准 (附录 B)。homework 块还丢了 mini 版的 scale = "row"——行是裸 logCPM, 高表达基因会把 scale = "row" 才能显示的图案在视觉上淹没。

解读。热图在这条管线里的任务是给 DEG 结论做可视化断言: 样本按条件聚 (HBR/UHR 列分开)、top 基因分成两个方向块。这个坑只弄坏了标签——数字、聚类、注释条一直是对的, 而这恰恰是它能一路存活进印刷讲义的原因。

调优。scale = "row" (逐行 z 分)、cutree_rows 强制块结构、两个条件之间 gaps_col = 3。扩展。注释多时换 ComplexHeatmap; 50 个标签挤时调字号。

13. 双轮对比 (mini vs homework/全量)

	mini (2026-09-21)	homework/全量 (2026-10-09)
每样本读段	10,000	118,571–227,392 对
STAR 索引	chr22 mini, 381 MB	全 GRCh38, 约 31 GB 内存
STAR unique (HBR / UHR)	53.0–53.3% / 45.1–49.9%	51.7–51.8% / 44.6–48.5%
STAR 太短	11.5–12.9%	47.1–52.7% (全量索引 + BySJout 严格度)
salmon align 模式	100% (已比对片段分母)	100% (同)
salmon direct/quasi	31.2–36.5% (trimmed)	30.3–35.3% (原始读段, 照原文)
索引内转录本	4,989	231,448
过滤后保留 (≥10 counts 且 ≥2 样本)	111 (2.2%)	831 (0.36%)

	mini (2026-09-21)	homework/全量 (2026-10-09)
DEG (FDR<0.05 且 logFC >1)	45 (15 上 / 30 下)	319 (171 上 / 148 下)
两个方向的 top 基因	IGLC2 (+10.3) / MIAT (-8.5)	IGLC2 / SYNGR1 一簇
注释 Matched	111/111	831/831
GO top 条目	(集小)	viral RNA genome replication 等, 与教师参考一致
热图标签	基因名 (正确块)	照原文全 “NA” → 矫正后 0/50 NA
墙钟时间	~4 分钟	13 分钟
跑在哪	登录节点, 串行	登录节点, 串行 (STAR 带内存守卫)

)

什么在缩放、什么不在。 墙钟 4 → 13 分钟 (索引加载主导; 全量索引是 mini 的 ~80 倍)。DEG 数 45 → 319 (深度买到检出)。**答案没动:** 映射率画像、top 基因、方向全部随深度不变——这正是先跑 mini 的意义所在。两轮之间唯一翻转的东西来自**文档**而不是数据: mini 的热图块注释正确, homework 的不正确。

14. 检查清单、产物清单与总结

检查清单 (附两轮实测答案):

#	检查项	mini	全量
ck1	建矩阵前样本顺序 (HBR×3 在前?)	成立	成立
ck2	colnames(txi\$counts) NULL → Sample1-6 (位置身份)	是	是
ck3	STAR unique 落在 44-54% 区间, HBR 高于 UHR	45.1-53.3%	44.6-51.8%
ck4	多位点低, UHR > HBR (IG 成分)	0.5-2.1%	1.1-3.0%
ck5	quasi 映射 30-37%、align 100% (分母不同——别互比)	31.2-36.5%	30.3-35.3%
ck6	两种索引广度下保留率 ~2% 与 ~0.4%	111/4,989	831/231,448
ck7	DEG 方向符合 SEQC 真值 (UHR 中 IGL 上调、脑基因下调)	是	是
ck8	两个深度 top 基因一致	IGLC2	IGLC2
ck9	注释块打出 Matched: n/n	111/111	831/831
ck10	GO top 条目对教师参考	—	一致 (viral RNA genome replication, p.adjust ~0.008)
ck11	热图标签是基因名不是 “NA”	是 (正确的块)	矫正后 0/50 NA (照原文 50/50 NA)
ck12	进 R 前 LC_ALL=C/LANG=C 已导出	是	是
ck13	ggrepel “unlabeled” 警告记录为良性	9	280

)

产物清单: 两轮的分析产物都在仓库 RNA-seq/results/ 下 (只放分析产物——无原始读段、无 BAM): fastqc/fastp 报告、各 6 份 STAR Log.final.out、multiqc 报告、全部 24 份定量的 quant.sf、R 分析日志、homework

轮四张 PDF (火山 / GO / 照原文热图, 全 NA / 矫正热图, 0 NA) 加 mini 轮三张 PDF, 以及两轮完整的 summary + deviations 日志与运行脚本。重型中间产物 (BAM、原始/trimmed FASTQ、完整 salmon 目录) 留在集群运行目录 (/lustre1/user/bjx131_pkuhpc/rna_run_mini_20260921/、/lustre1/user/bjx131_pkuhpc/rna_run_homework_20261009/)。

总结。管线本身是健全的; 坑全在管外围手写接缝上——样本身份只靠位置与字母序运气、两个 salmon 模式的映射率分母不可比、quasi 循环悄悄定量了原始读段、热图注释重写静默渲染出 50 行无标签。每一条都在真实运行中复现, 每个修复都执行并验证过。SEQC 数据集全程尽到了职责: 生物学答案 (IGLC2 上调、脑基因下调) 在两个深度下稳定, 且在参考可对拍处与教师参考一致——而如附录 B 所示, “参考可对拍”这件事本身也是需要核验的, 不是想当然。

附录 A. 偏差日志 (两轮, 节选但忠实原文)

完整日志: RNA-seq/results/mini/log/ 与 RNA-seq/results/homework/log/ (summary + deviations + R 分析)。

mini 轮 (2026-09-21) ——节选:

DEVIATION: workdir = own run dir (tutorial: classroom share dir); no writes to the classroom share
DEVIATION: tutorial-native interactive mode: serial single-process run on the login node –
campus-wide SLURM submission outage (all sbatch rejected; sacct empty since 9/15; the WES
scripts that ran successfully on 9/20 also rejected → cluster-side, not ours)
DEVIATION: SLURM env-var guard + deviation logging added to the teacher's load-test script shape
DEVIATION: single consolidated runner script (tutorial assumes interactive typing)
FINDING: sample order fragility holds (list.files alphabetical, HBRx3 first, condition correct)
FINDING: tximport unnamed files → colnames NULL → edgeR Sample1-6 (positional dependence)
FINDING: KEGG block is a doc bug (step-by-step cells comment it with #; consolidated wraps in ''')
FINDING: ggrepel 9 unlabeled benign

homework 轮 (2026-10-09) ——节选:

DEVIATION: workdir = own run dir (tutorial: /lustre1/share/RNA_seq_student_2026_homework/{id})
DEVIATION: tutorial-native interactive mode on the login node, per user directive 2026-10-09 –
SLURM had RECOVERED by probe time (test-only alloc OK on cn-long) but the tutorial's own
design is direct interactive execution; recorded, not used this round
DEVIATION: restart guards (skip steps whose outputs exist); STAR memory guard (wait for
MemAvailable ≥ 37 GB before each invocation – index ~31 GB on a shared login node)
DEVIATION: STAR --runThreadN 4 per the homework batch script (single-sample demo cell says 1)
DEVIATION: multiqc: doc cell has placeholder path; used \$PWD like the mini version
DEVIATION: salmon quasi mode runs on RAW reads (glob *read1.fastq.gz matches only untrimmed) –
inconsistent with mini's direct mode on trimmed; run AS WRITTEN, recorded
DEVIATION: R step-by-step path used (grep("quasi")); consolidated CODES cell still filters
"_direct" (mini naming) AND wraps KEGG in ''' (invalid R) – unusable for homework outputs
FINDING: heatmap row labels ALL "NA" (gene_map keyed by versioned transcript_id, looked up
with version-stripped rownames) – silent; correction pass heatmap_DEG_corrected.pdf: 0/50 NA
FINDING: quasi mapping rate 30–35% on raw reads (mini direct ~32%, consistent)
FINDING: teacher reference heatmap rows are versioned ENST IDs – teacher's actual run used a
third code variant; third teacher-vs-doc deviation (cf. class.R salmon_files[-2], the
mangled single-sample salmon filename)
RESULT: GO dotplot top categories match teacher reference (viral RNA genome replication,
glycosyl compound catabolic process; p.adjust 0.0075 vs 0.0082–0.0088) – cross-validated

附录 B. 教师参考产物 vs 印刷版文档 (取证, 路径原文)

教师自己的运行在 /lustre1/share/RNA_seq/ 留下了产物。与印刷版文档相对, 三处独立偏离:

1. **参考热图是第三种变体。** /lustre1/share/RNA_seq/heatmap_DEG.pdf 的行标签是带版本号的 ENST ID (如 ENST00000407418.8)。印刷版 homework 块产出的是全 “NA” (RNA-09, 已复现); mini 块产出基因名。参考两者都不是——它那份代码保留了带版本号的 ENST 行名、从未改名。
2. **class.R 丢了一个样本。** salmon_files <- salmon_files[-2]——tximport 前删掉第 2 个定量目录。与教师自己运行区里重复目录的清理一致 (共享目录里同时有 UHR_Rep3...chr22Aligned...bam 和双名 UHR_Rep3...chr22_ERCC-Mix2...chr22Aligned...bam), 而与印刷版文档里的任何方法都对不上。

3. **拼接错乱的单样本 salmon 单元格真被跑过。** 上面的双名 BAM 正是 homework 单样本 align 单元格 (RNA-03, UHR 名 + 粘贴的 HBR_ERCC-Mix2...chr22 后缀) 会产出的文件名——参考区里留着这个 bug 自己的输出文件名。

参考可对拍的地方与我们的结果一致: G0_dotplot.pdf 的 top 条目与 p.adjust 和我们吻合 (附录 A 的 RESULT)。WES 版的教训原文重演: 参考产物是**某人实际命令**的证据, 不是印刷版命令正确的证明——只在代码路径已知处与它对拍。

附录 C. 复现

两轮的运行脚本与 R 脚本原样存放在 RNA-seq/results/mini/scripts/ 与 RNA-seq/results/homework/scripts/, 旁边是完整日志。homework 运行脚本在自己的头注释里写明了它的包装偏差 (SLURM 头仅为溯源保留——该轮按教程原生方式在登录节点跑)。复跑 mini 轮约 4 分钟、只需共享环境; 复跑 homework 轮串行约 13 分钟、每次 STAR 调用需 ~31 GB 空闲内存。