scVelo 分析结果讲解

Contents

scVelo 分析结果讲解 1
1. 怎么读这个目录 1
2. 01_preprocess：对象本身与占比 1
3. 02_velocity：场 2
4. 03_phase_portraits：相位图 2
5. 04_gene_dynamics：速率基因与每基因动力学 2
6. 05_cellcycle：细胞周期 2
7. 06_corrected：矫正链做了什么 2
8. 07_figure_comparison：和教师的 11 张图对拍 3
9. 练习 3

scVelo 分析结果讲解

本文件导读 `scRNA-seq-scVelo/results/` 下的全部产物，并给出可以亲手复现的练习。配套的矫正增强版文档在 `ref/scVelo_analysis_corrected.md`（英文）与 `ref/scVelo_analysis_corrected_zh.md`（中文）。

1. 怎么读这个目录

```
results/
├── 01_preprocess/           步骤 1: 占比面板 + 每群细胞数 + 输入对象自身的审计表
├── 02_velocity/             步骤 2-3: stream/箭头面板、每细胞速率、速率图统计
├── 03_phase_portraits/      步骤 4: Cpe/Gnao1/Ins2/Adk 面板、Cpe 群面板、Hells/Top2a 面板
├── 04_gene_dynamics/        步骤 5: 两张 top5 面板 + 排名表 + 每基因动力学
├── 05_cellcycle/            步骤 6: 细胞周期渐变面板 + 相位 marker 面板 + 分数表
├── 06_corrected/            矫正链：13 张矫正面板 + 17 张表（dynamical 拟合、隐时间、
│                            参数敏感性、两模型排名并置、运行摘要）
├── 07_figure_comparison/    与课程随附 11 张参考 PNG 的机器可读对拍（原样版 / 矫正版）
├── 09_run_logs/             三次运行的控制台记录（原样、矫正、两次审计）
└── scripts/                 重新生成以上全部内容的五个脚本
```

约定：

- `01_–05_` 目录里的图**原样跑**产出，文件名就是教材单元编号（`02_velocity_embedding_stream.png` 对应第 63 单元）。它们与课程随附的 11 张参考图一一对应，可以直接 `diff` 眼睛。
- `06_corrected/` 里带 `corrected_` 前缀的是**矫正链**产出；不带前缀的 `sensitivity_*`、`rank_velocity_genes_*`、`latent_time_*` 是同一链条落下的表。
- 每个 `09_run_logs/*_console.txt` 里，`[describe]` 段打印对象形状与非零数，`[state]` 段打印该步骤 结束后的关键量，`[VELO-nn]` 段是问题清单对应位置的现场取证。
- 表格一律 UTF-8 CSV，索引列优先；`proportions_by_cluster.csv` 有两个口径列，**不要**混用（见 §2）。

2. 01_preprocess：对象本身与占比

`01_proportions.png` 是教材第 50 单元那张饼图/柱图。柱高取自 `obs['initial_size_*']`，也就是过滤**之前** 的文库大小：Ductal 12.3%、Ngn3-low 12.4%、Ngn3-high 15.0%、Pre-endocrine 20.5%、Beta 20.7%、 Alpha 19.5%、Delta 19.3%、Epsilon 17.9%，整体 16.3%。

`proportions_by_cluster.csv` 把两套口径并排放：`unspliced_fraction_initial_size`（图上的）与 `unspliced_fraction_current_layers`（模型实际看到的）。后者整体 23.0%，逐群 19.9–25.3%。差 3–9 个 百分点，不是误差，是两个问题：前者说的是”文库里有大多比例是内含子”，后者说的是”速率模型手上有多少 unspliced 信号”。

`obs_cell_metadata.csv`（3,696 行）与 `var_gene_annotation.csv`（2,000 行）是**速率计算所用对象**的 逐细胞/逐基因元数据，包含 `velocity_gamma`（逐基因稳态斜率）、`velocity_r2`、`spearmans_score`、`fit_*` 等。`cluster_cell_counts.csv` 是八群的规模（916 / 642 / 592 / 591 / 481 / 262 / 142 / 70）。

3. 02_velocity：场

02_velocity_embedding_stream.png 与 03_velocity_embedding.png 是全课的主图：前者是核平滑后的流线，后者是逐细胞箭头。11_velocity_embedding_stream_repeat.png 与前者**逐字节相同**（同 md5）——教材第 84 单元重复了第 63 单元的调用，这是问题清单里的 VELO-10，保留它是为了让读者自己验证。

velocity_per_cell.csv（3,696 行）给每个细胞的速率模长 velocity_norm、所在群、以及 velocity_confidence；velocity_summary_by_cluster.csv 是逐群的模长中位数与置信度中位数。 velocity_graph_aswritten.csv 记录速率图的非零数（593,854）、密度（4.3%）与 k（30）—— 图本身是 3,696 × 3,696 的稀疏矩阵，不入库。

top_abs_velocity_genes_by_cluster.csv 是按”速率绝对值均值”排的每群前若干基因，与教材的 rank_velocity_genes（按速率–表达相关排）不是同一个量，放在一起可以看出两种排法的差别。

4. 03_phase_portraits：相位图

三张面板，对应教材第 69、71、83 单元：04_phaseportrait_markers.png（Cpe/Gnao1/Ins2/Adk）、 05_cpe_groups_velocity.png（Cpe 按群+速率）、10_phaseportrait_hells_top2a.png（Hells/Top2a）。

phase_portrait_gene_stats.csv 逐基因记录相位图的关键量：spliced_max、unspliced_max、细胞点云的 相关系数、以及稳态斜率 velocity_gamma。读法：Ins2 的 spliced 上到 120、点云近乎一条直线，说明成熟 转录本主导、相位图信息最少；Cpe 有干净的环，是教材选它讲”速率方向”的原因。

5. 04_gene_dynamics：速率基因与每基因动力学

06_top5_ngn3_high_ep.png 与 07_top5_pre_endocrine.png 是教材第 75 单元的两张 top5 面板（各 5 个 基因的 UMAP+速率）。rank_velocity_genes_top50.csv 是每群前 50 名（列=群，行=名次），rank_velocity_genes_top5_summary.csv 是每群前五名的拼接字符串。

两个必须在正文里说清的事实：min_corr=.3 筛的是 var['spearmans_score'] 而**不是**排名相关性，而 真正的截断是 n_genes=100（默认值）。实测：阈值 0.1/0.3/0.5/0.7 分别留下 1,861/1,469/973/430 个 合格基因，而 Ductal 与 Beta 的可见 top-3 一模一样——阈值在 0.9 之前从未生效。

gene_kinetics_scores.csv（2,000 行）是逐基因的 velocity_gamma（中位 0.343、IQR [0.090, 0.966]）、velocity_r2（中位 0.052）、velocity_qreg_ratio、spearmans_score。中位 r^2 只有 5%，是所有“速率基因”结论该被如何看待的前提。

6. 05_cellcycle：细胞周期

08_cellcycle_gradients.png 是教材第 79 单元的 S/G2M 渐变图（**唯一**与参考图对不上的那张，结构相关 0.589），09_phase_marker_genes.png 是第 81 单元的相位 marker 面板。

cellcycle_scores_per_cell.csv 是**重算**后的分数（教材的 score_genes_cell_cycle 覆盖了数据自带的 那一对）；cellcycle_summary_by_cluster.csv 是逐群的相位计数（G1 2,537 / S 878 / G2M 281）与均值； phase_marker_gene_ranking.csv 与 phase_marker_top5.csv 是逐群的 S/G2M marker 排名（S：Mcm6、Hells、Tyms、Pola1、Uhrf1；G2M：Hn1、Top2a、Kif23、Ckap2l、Kif2c）。

7. 06_corrected：矫正链做了什么

13 张图里，corrected_01–corrected_03、06–08、10 与教材同位置的面板同源（用来对拍），corrected_04/05 是相位图的两种画法（稳态 / 只画 dynamical 拟合），corrected_09 用数据自带分数 重画了细胞周期，corrected_11 用 dynamical 拟合重画了 Hells/Top2a，corrected_12/13 是教材从来 没画过的两张（隐时间+置信度、以隐时间上色的 stream）。

关键表：

文件	内容	值得注意的数字
run_summary_corrected.csv	矫正对象自检	3,696 × 2,000，X 非零 1,740,903，Ms 非零合计 5,778,956.5

文件	内容	值得注意的数字
latent_time_summary_by_cluster.csv	逐群隐时间	Ductal 0.157 → Ngn3-high 0.465 → Beta 0.774
latent_time_and_confidence_per_cell.csv	每细胞隐时间+两版置信度	两模型置信度相关仅 0.207
rank_velocity_genes_top5_dynamical.csv	dynamical 排名	与 stochastic 的 top-20 Jaccard 0.132
sensitivity_graph_and_hvg.csv	六条完整流水线	1000 HVG → Jaccard 0.50；k=15 → 0.58；重算 PCA → 0.78
sensitivity_min_corr.csv	min_corr 扫描	0.1→1,861 个合格、0.9→27 个
sensitivity_n_genes_cap.csv	n_genes 上限	10/50/100/300 就是表格行数
cellcycle_scores_original_vs_recomputed.csv	两版周期分数	Pearson 0.964 / 0.973
proportions_by_cluster_corrected.csv	两套占比口径	16.3% vs 23.0%

corrected_summary.json 是整条链条的机器可读摘要（版本、耗时 4.72 min、各项统计）。

8. 07_figure_comparison：和教师的 11 张图对拍

figure_comparison_aswritten.tsv 与 figure_comparison_corrected.tsv 各 11/13 行，列包括画布尺寸、 长宽比、结构相关 struct_corr、墨迹 IoU ink_iou、色彩分布。

原样跑：十张 0.972–0.993，第八张（细胞周期）0.589。矫正链：十张可比面板 0.904–0.986，细胞周期仍是 0.579。差异的原因不在数据：那张参考图与我们的画布（1205 × 648）和图例文字完全一致，但标记云内部配色 不同，且参考图集里存在三种 dpi（80 / 96 / 64），说明那 11 张是多次会话拼接的。

9. 练习

练习 1（10 分钟，口径）。打开 proportions_by_cluster.csv，用 unspliced_sum/(spliced_sum+unspliced_sum) 自己算一遍逐群占比，然后与 01_proportions.png 上的柱高比较。差多少？哪一列对应图上的数？再看 scv.pl.proportions 的签名里 use_raw 默认值。

练习 2（15 分钟，模型）。用 corrected_adata.h5ad（或重跑脚本）分别取 adata.var['velocity_gamma'] 与 adata.var['fit_gamma']，画散点并算 Spearman。为什么两者秩相关是 负的（−0.45）？提示：稳态模型把 β 归一为 1，dynamical 学的是独立 β。

练习 3（10 分钟，隐时间）。 用 latent_time_and_confidence_per_cell.csv 的 latent_time 列按群画箱线图。Beta 的中位数比 Alpha 早（0.742 vs 0.758），但均值更晚（0.774 vs 0.758）。画出两者的分布，解释为什么”全局隐时间排出单一顺序” 在这里会失真。

练习 4（20 分钟，参数）。 把 scVelo_audit_run.py 的 run_variant 复制出来，把 n_top_genes 设成 500，跑一遍，比较 top-20 Jaccard 与速率基因数。趋势与 sensitivity_graph_and_hvg.csv 里的 1,000 那一行 一致吗？

练习 5（15 分钟，图的含义）。用 corrected_04/corrected_05 两张相位图对照：哪些基因的 dynamical 拟合曲线明显偏离稳态线？结合 phase_portrait_gene_stats_corrected.csv 里的 velocity_gamma，说说偏离 大的基因有什么共同点。

练习 6（10 分钟，细胞周期）。用 cellcycle_scores_original_vs_recomputed.csv 算两版的绝对差， 找出差最大的 20 个细胞，看它们在 clusters 里属于哪群。为什么差异集中在某些群？

练习 7（20 分钟，对拍）。打开 figure_comparison_aswritten.tsv，找出 ref_px 与 ours_px 比值 正好 0.8 与 1.2 的行。把 scv.settings.set_figure_params(dpi=64) 打开，重画其中任意一张，验证画布 变成与参考一致——然后解释为什么”画布一致”并不等于”分析一致”。

练习 8（30 分钟，往下走）。 用 `corrected_adata.h5ad` 跑 `ref/scVelo_analysis_corrected.md` 附录 B 的 三行 CellRank，得到每个细胞的命运概率，并与隐时间对照：内分泌终末群的命运概率是否与它们的隐时间排序 一致？哪一群最不一致？