单细胞 RNA-seq（PBMC 3k）· 矫正增强版（中文版）

Contents

单细胞 RNA-seq（PBMC 3k）· 矫正增强版 1
0. 关于本版 1
1. 问题清单速览 2
2. 环境与数据 4
3. 原样运行：教材实际产出了什么 6
4. Part 1 —— 载入数据 8
5. Part 2 —— 质量控制 8
6. Part 3 —— 高变基因 11
7. Part 4 —— 标准化与 PCA 13
8. Part 5 —— 聚类与 UMAP 18
9. Part 6 —— 注释与差异表达 19
10. Part 7 —— 去批次整合 27
11. Part 8 —— scanpy 29
12. 两套工具链对账 32
13. 修正版 33
14. 教材范围之外的参考图 34
15. 复现本模块 35
16. 文件清单 35

单细胞 RNA-seq（PBMC 3k）· 矫正增强版

第五节课 · scRNA-seq 分析 教材来源：Single Cell RNA-seq Analyze Tutorial，秦博文、曾泽贤，北京大学生命科学中心 / 定量生物学中心 / 前沿交叉学科研究院（本目录下 `scRNA_seq_analyze_totorial_2026.html`）。

---

0. 关于本版

本文件是第五节课教材的矫正增强版，沿用本仓库 WES、RNA-seq、RNA-seq-application、TBCR-analysis 四个模块的既定流程：

1. 教材先**按原样执行**——每个代码单元逐字照抄，按教材顺序，不做优化、不在运行中修错；
2. 所有遇到或预见的问题**只记录不修改**（清单见 §1，具体解释放在对应 Part）；
3. 随后**另跑一份修正版**，让每条修正的影响可被测量而不是被断言（§13）；
4. 文档、脚本、日志、图、表一并入库。

本模块与前四节课有两处不同。

第一次同一份数据上有两套工具链。 Part 1-7 是 R/Seurat，Part 8 是 Python/scanpy，都从同一个 `matrix.mtx` 出发。教材从不交代两侧的关系，而它们确实不一致：R 侧保留 32,738 个基因、得到 9 个群，Python 侧保留 13,714 个基因、得到 8 个群。§12 把这一差异逐细胞量化。

第一次教材在两门语言里都跑不到结尾。 少一行 `library()` 让 R 的差异表达单元崩掉，多一个逗号让整个 Python 单元崩掉——合起来就是 25 张图里的 7 张，以及两个交付对象全部丢失（§3）。

本版相对原教材增加的内容：

- 完整的一次运行：逐单元耗时、警告、以及准确的报错原文（§3）；
- 二十条已验证的坑（`SC-01` … `SC-20`），每条给出修正代码，重要处给出实测影响；
- 每张重生成的图与课程随附 28 张参考 PNG 的逐图像素级比对（§3.4，`results/08_figure_comparison/`）；
- 两套工具链的对账：所谓”9 群 vs 8 群”到底是什么（§12）；

· 一份修正版，原样复现了全部数字，并补出教材只留在内存里的对象与表格（§13）。

全文统一四档严重度：**致命**（原样代码根本产不出结果）、**改变结果**（能跑，但标签/数字不可信）、**稳健性**（这里能跑，别处会崩）、**代码卫生**（风格、命名、结果不落盘）。

---

1. 问题清单速览

编号	Part	问题	严重度	修正
SC-01	4	`ScaleData(features = rownames(seurat_obj))` 对全部 32,738 个基因做 scale，而正文写的是"用选出的特征"（2,000 个 HVG）。这不是错误：`DoHeatmap()` 从 `scale.data` 取基因，只 scale HVG 会让任意 marker 热图直接报错。代价是：对象 0.73 GB、耗时 4.2 s，而 13,714 基因版是 0.35 GB / 2.2 s。	稳健性	保留，但写明理由；内存敏感时 scale `unique(c(VariableFeatures, 需要的 marker))`。
SC-02	6	cluster → 细胞类型的映射在教材里**写了两份且互相矛盾**：cell 39 的表说 cluster 1 = CD14+ Mono、cluster 2 = Memory CD4 T；cell 43 的 `new.cluster.ids` 说 cluster 1 = Memory CD4 T、cluster 2 = CD14+ Mono。本次运行里向量对、表错（cluster 1 是 CCR7/LEF1/NOSIP 即 CD4，cluster 2 是 S100A8/FCN1/CD14 即单核）。而 Louvain 编号并不稳定：§13.2 里仅 30 个 HVG 的扰动，就让同一个固定向量标错 957 个细胞（36%）。	改变结果	由 marker 反推标签、断言群数、输出审计表。
SC-03	6	`seurat_obj.markers %>% group_by(cluster) %>% dplyr::filter(avg_log2FC > 1)` 是一条**值被丢弃的管道**；随后 `top10` 用 `slice_max(avg_log2FC)` 取自**未过滤**的表，完全不看 `p_val_adj`。过滤从未生效。	改变结果	先赋值过滤结果、同时卡 `p_val_adj < 0.05`，再 `slice_max()`。
SC-04	6	`naive_cd4_genes`、`memory_vs_naive_genes` 算完再也不使用；火山图纵轴 `-log10(p_val_adj)`，当 `p_val_adj` 下溢为 0 时是 `Inf`（本数据未触发——最小 1.24e-115——但测试精度再少一位就会触发）；两个 DEG 表都不落盘。	稳健性	用 `pmax(p_val_adj, .Machine$double.xmin)`；导出两张表；真正用上基因列表。
SC-05	7	`data_pbmc_multi <- load("pbmc_stim.RData")` 拿到的是被载入对象的**名字**，不是对象；`ctrl.sparse`/`stim.sparse` 被倒进全局环境，再用 `get()` 取回。放进函数或 knit 文档里会静默泄漏或直接失败。	稳健性	`load(..., envir = e)` 载入私有环境。
SC-06	7	Part 7 直接把**未过滤的原始矩阵**送去整合——没有 `percent.mt`、没有 `nFeature` 阈值，与 Part 2 完全脱节；`RunHarmony()` 之后只画一张 UMAP，不做 `FindNeighbors()`/`FindClusters()`，去批次效果从未被量化。	改变结果	两侧都做 QC（13,019 → 12,932、12,875 → 12,779），并用量化指标替代肉眼判断（§10）。
SC-07	4	`PCHeatmap()` 是已废弃别名（Seurat 5.1.0 里仍在、且不报警告）；`ElbowPlot()` 默认画 20 个 PC，而下游全部用 `dims = 1:10`。	稳健性	换 `DimHeatmap(dims = 1:6)`；显式 `ndims = 20` 并说明为何取 10。
SC-08	3	`p <- p + plot2` 中 `plot2` 本身是基于 `p` 的完整 ggplot，结果是**两联图**（左 `p`、右 `plot2`），而不是"同一个图上叠了一层"。随附的参考图 `VariableFeaturePlot.png` 就带着这个痕迹：左右两半是同一张散点、标注不同。	代码卫生	`p <- LabelPoints(plot = p, points = top_features, repel = TRUE)`，单联。
SC-09	8	`sc.pl.pca_variance_ratio(adata, log=True,,save="scanpy_PCA_ratio.png")` 的双逗号是 `SyntaxError`。Python 以整单元格	致命	去掉一个逗号。

编号	Part	问题	严重度	修正
		编译，于是该单元里**什么都没有执行**：不只是比值图，连 `sc.tl.pca()`、`sc.pp.neighbors()`、`sc.tl.umap()` 全都没跑。后续单元连锁失败于 `KeyError: 'No "neighbors" in .uns'`。		
SC-10	2, 8	两侧用不同阈值过滤同一批 2,700 个细胞（`nFeature_RNA < 2500` VS `n_genes_by_counts < 2000`），于是分别描述 2,638 与 2,635 个细胞、9 与 8 个群。正文与代码都没提这个不一致。	改变结果	统一阈值；§12 显示 Python 侧改用 2,500 恰好得到 2,638 个细胞。
SC-11	8	`sc.pp.scale(adata, max_value = 10)` 在 cell 64 末尾调一次、cell 67 开头又调一次。第二次是对已截断数据的重复截断（本数据上是空操作，但一旦 `max_value` 不同就会静默改变数值）。	代码卫生	只保留一次。
SC-12	8	`rename_categories("leiden", new_cluster_names)` 要求每个类别正好一个名字，数量不符就抛难以理解的错误；8 个名字对 9 个类别时整单元崩掉。更关键的是这些名字是**位置式**的——按类别顺序而非 marker 证据分配——而且**是错的**：名叫 `CD8 T` 的群有 78.1% 是 Seurat 的 Naive CD4 T（CD8A 0.14、CD8B 0.24、IL7R 1.61），名叫 `NK` 的群是 61.8% CD8 T 加 33.3% NK。	改变结果	校验类别数，并由 `rank_genes_groups` 结果反推映射（§11.4）。
SC-13	6, 8	两侧算完 marker 都不落盘；scanpy 的 `save=` 是”函数名 + 字符串”拼接，于是产生 `highest_expr_genesscanpy_highest_expr_genes.png`、`violinscanpy_violin_plot_QC.png`、`umapscanpy_final_umap.png`。课程随附的图之所以要改名，正是这个原因。	代码卫生	导出 `markers_all_clusters.csv`、`clusterN_markers.csv`、`cluster_label_audit*.csv`。
SC-14	1, 8	`genes.tsv` 有 95 个重复行、涉及 91 个 symbol（32,738 行、32,643 个唯一名，`7SK` 出现 4 次），另有 21 个 symbol 含 `_`。Seurat 把 `_` 改写成 `-`（“Feature names cannot have underscores, replacing with dashes”），scanpy 的 `var_names_make_unique()` 把重复项改成 `ACE` → `ACE-1`。两侧基因名双向不一致。	稳健性	记录两份映射；跨工具关联用 `gene_ids`。
SC-15	1	数据目录是**旧版 Cell Ranger 1.1.0 结构**：`barcodes.tsv`、`genes.tsv`、`matrix.mtx`，没有 `features.tsv`、没有 `.gz`。`Read10X()` 与 `read_10x_mtx()` 都能读，但任何期待 `features.tsv.gz` 的新工具都读不了。	稳健性	本模块无需处理，记录在案。
SC-16	6	调用了 `geom_text_repel()`，却从未 `library(ggrepel)`（只载入了 Seurat、dplyr、ggplot2）。整个 DEG 单元以 `could not find function "geom_text_repel"` 崩溃——**连带最后一行 `saveRDS(seurat_obj, "pbmc3k_final.rds")` 也不执行**。	致命	Part 1 加 `library(ggrepel)`。
SC-17	1	`CreateSeuratObject()` 用默认 `min.cells = 0`，保留全部 32,738 个基因（其中 19,024 个 QC 后全零），而 scanpy 的 `filter_genes(min_cells = 3)` 只留 13,714 个。这不是无害差异：2,000 个 HVG 里有 30 个变化，Louvain 解随之移动（模块度 0.8584 vs 0.8728，群大小差 ±5%），教材那两份硬编码注释表也不再自洽（§13.2）。	改变结果	显式声明基因全集，不要静默改动。

编号	Part	问题	严重度	修正
SC-18	7	Part 7 的两张 UMAP **不可跨运行复现**：同一输入、同一代码跑两次，结构相关只有 0.5631（`UMAP_without_harmony`）与 0.5676（`UMAP_with_harmony`），与”对参考图的相关”（0.5664、0.5689）同量级。uwot 是多线程的，`RunUMAP()` 没有线程无关的随机种子。	稳健性	比对群体结构或嵌入矩阵，永不比像素；需要逐位可复现就设 `n.threads = 1`。
SC-19	6	随附参考图 `Marker_Heatmap.png` 是 3,000 × 6,000 px，即 300 dpi 下 10 × 20 英寸；而教材 `ggsave(..., width = 10, height = 10)` 只会得到 3,000 × 3,000。参考图不是教材代码产出的。	代码卫生	无需处理，记录课程材料内部不一致。
SC-20	7	`RunHarmony(merged_seurat, group.by.vars = "orig.ident")` 省略了 `dims`，于是对 `RunPCA()` 得到的全部 50 个 PC 做整合（默认 `npcs = 50`）；而随后的 `RunUMAP(reduction = "harmony", dims = 1:10)` 只用前 10 个 harmony 分量。去批次与可视化跑在不同维度上。	稳健性	显式 `dims = 1:10`（或 `1:20`），并让 UMAP 使用同一组。

另有两点不是代码 bug，但必须记录：

- 教材的 HTML 里从未出现随机种子，而整个模块处处随机（Louvain、UMAP、harmony）；
- 本目录下 28 张参考 PNG 是教师 2025 年的输出，其中 13 张与 2024 版逐字节相同；另有 3 张（`UMAP_noPCA.png`、`UMAP_three_stages.png`、`immune_markers.png`）不是教材里任何代码产出的（§14）。

---

2. 环境与数据

2.1 环境

本模块不新建环境。教师共享环境里两套工具链都在：

```
source /lustre1/share/miniconda3/etc/profile.d/conda.sh
conda activate /lustre1/share/miniconda3/envs/scRNA_seq
```

组件	版本	备注
R	4.4.1	
Seurat	5.1.0	SeuratObject 5.0.2；v5 分层对象
harmony	1.2.1	
ggrepel	0.9.6	装了，但教材从未载入（SC-16）
dplyr / ggplot2 / patchwork	1.1.4 / 3.5.1 / 1.3.0	
Matrix / uwot / leiden / igraph	1.7.1 / 0.2.2 / 0.4.3.1 / 2.1.1	
FNN / RANN	1.1.4.1 / 2.6.2	仅供矫正版的混合度指标使用
presto	**缺失**	缺它 `FindAllMarkers()` 退回慢速 Wilcoxon 路径：一个单元 330 s
Python	3.12.7	
scanpy / anndata	1.10.3 / 0.10.9	
leidenalg / igraph	0.11.6	
numpy / pandas / seaborn	2.0.2 / 2.2.3 / 0.13.2	
Pillow	11.0.0	供图像比对脚本使用

本模块在登录节点串行运行，与第 3、4、5 节课一致：总数据量 2,700 个细胞（Part 7 为 25,894 个），峰值内存约 4 GB，最长的单个单元是 `FindAllMarkers()` 的 5.5 分钟。没有比对步骤、不涉及调度器，故未加 `sbatch` 包装——与 RNA-seq、TBCR 两个模块记录的理由相同。

2.2 输入数据

路径	内容
`/lustre1/share/scRNA_seq/hg19/`	`barcodes.tsv`（2,700）、`genes.tsv`（32,738）、`matrix.mtx`（2,286,884 个非零），Cell Ranger 1.1.0 / hg19
`/lustre1/share/qinbowen/pbmc_stim.RData`	`ctrl.sparse`（35,635 × 13,019）、`stim.sparse`（35,635 × 12,875），稀疏 `dgCMatrix`
`/lustre1/share/scRNA_seq_student/qinbowen_2025/`	教师输出，仅作比对参照

矩阵是标准 10x PBMC 3k：2,700 个细胞，中位 817 个基因、2,197 个 UMI，线粒体占比中位 2.03%。`genes.tsv` 有 95 个重复 symbol、21 个含 _ 的 symbol（SC-14）。

2.3 运行目录

```
/lustre1/user/bjx131_pkuhpc/scrna_run_20261026/
├── hg19/                       计数矩阵副本（按教材 cell 7 的 rsync 指令）
├── pbmc_stim.RData             刺激组数据副本
├── rr/                         R 原样版（图直接写在该目录）
├── rr_fixed/                   R 矫正版（MIN_CELLS = 0）
├── rr_mincells3/               R 矫正版、基因全集对齐 scanpy（§13.2）
├── py/  py_asis/               Python 原样版
├── py_fixed/                   Python 矫正版（N_GENES_MAX = 2000，教材原值）
├── py_align2500/               Python 矫正版、阈值对齐 Seurat（§12.3）
├── logs/                       每次运行一份日志 + 一份逐单元状态表
└── scripts/                    单元文件 + 驱动器 + 分析脚本
```

教材的每个代码单元都按 HTML 中的原始编号抽出（R 为 11、13、16…，Python 为 54、55、57…），交给两个小驱动器执行：

- `scripts/run_cells.R`：在**同一个常驻 R 会话**里逐单元求值，逐单元捕获错误、警告、消息，记录耗时，并在单元结束后记录各对象状态；
- `scripts/run_cells.py`：同一思路，Python 常驻命名空间。

两个驱动器精确复刻 notebook 语义：报错的单元被记录，下一个单元继续执行；不自动修正、不重试、不重排。这正是把”教材有 bug”变成”25 张图里只有 18 张存在，另外 7 张死在这些单元”的关键。

2.4 仓库内的产物布局

```
scRNA-seq/
├── scRNA_seq_analyze_totorial_2026.html   课程材料（未改动）
├── scRNA_seq_lecture_2026.pdf             课程幻灯片（未改动）
├── *.png                                  28 张参考图（未改动）
├── ref/                                   本文档、中文版、结果导读
└── results/
    ├── 01_qc/                  质控图 + qc_summary.csv + qc_rederivation_rawmatrix.csv
    ├── 02_hvg_pca/             高变基因与 PCA 图（两侧、两版）
    ├── 03_clustering/          UMAP 图 + cluster_sizes.csv
    ├── 04_annotation/          marker/注释图、marker 表、审计表与对账表
    ├── 05_deg/                 火山图 + DEG 表 + scanpy 排名/点图
    ├── 06_integration/         harmony 图 + integration_metrics.csv + 分样本群占比表
    ├── 07_objects/             pbmc3k.h5ad + pbmc3k_obs.csv
    ├── 08_figure_comparison/   三张比对表 + 书面比对报告
    ├── 09_run_logs/            六次运行的逐单元日志与状态表
    └── scripts/                重新生成以上全部内容的脚本
```

`pbmc3k_final.rds` **不入库**：Seurat 为全部 32,738 个基因保留稠密 `scale.data`，文件 331 MiB。Part 6 里那行 `saveRDS()` 即可重建。

---

3. 原样运行：教材实际产出了什么

3.1 R 侧（Part 1-7）

单元	步骤	秒	结果
11	`Read10X` + `CreateSeuratObject`	7.2	32,738 × 2,700；警告：特征名 _ → -
13	线粒体 QC + 小提琴图	1.9	2,700 → 2,638 个细胞
16	`NormalizeData`	0.8	
18	`FindVariableFeatures`（vst，2,000）	4.2	警告：零离散度取 log-10
21	`ScaleData`（全部 32,738 基因）	5.8	对象 0.73 GB
23	`RunPCA` + 4 张图	8.7	50 个 PC
27	`FindNeighbors(1:10)` + `FindClusters(0.5)`	1.3	9 个社区，模块度 0.8584
29	`RunUMAP(1:10)`	6.7	65 条消息（uwot 进度）
33	9 个 marker 的 `FeaturePlot`	3.0	
36	`FindAllMarkers(only.pos)` + 热图	**330.3**	11,986 行；无 presto
39	注释表（仅注释）	0.0	
40	12 个 marker 的 `FeaturePlot`	4.3	
43	`RenameIdents` + 带注释 UMAP	0.6	9 个标签
46	DEG + 火山图 + `saveRDS`	11.3	**报错：`could not find function "geom_text_repel"`**
48	merge + 未去批次 UMAP	63.1	35,635 × 25,894
51	harmony + UMAP	60.1	50 维 harmony 嵌入

合计 509 s，其中 `FindAllMarkers()` 占 65%。cell 46 在崩溃前已经算完两次 `FindMarkers()`（724 行与 650 行），所以 DEG 数字留在日志里，但火山图与 `pbmc3k_final.rds` 都没有。cell 51 的 harmony 嵌入是 50 维（SC-20）：`RunHarmony()` 默认用 `pca` 的全部主成分，而合并对象经 `RunPCA()` 得到 50 个。

3.2 Python 侧（Part 8）

单元	步骤	秒	结果
54	import	0.0	
55	`read_10x_mtx` + `var_names_make_unique`	0.5	2,700 × 32,738
57	`highest_expr_genes`	0.8	出图
59	`filter_cells(200)` + `filter_genes(3)` + QC 小提琴图	1.1	过滤基因后 2,700 × 13,714
61	两张散点 + 阈值 + normalize + log1p	0.4	2,635 个细胞
64	HVG + 取子集 + scale	0.9	1,833 个 HVG

单元	步骤	秒	结果
67	PCA + 比值图 + neighbors + UMAP	0.0	**SyntaxError（SC-09）——该单元一行未执行**
70	leiden + UMAP + rank_genes_groups	0.0	`KeyError: 'No "neighbors" in .uns'`
72	dotplot	0.0	`ValueError: groupby has to be a valid observation`
75	改名 + 终版 UMAP + 写 h5ad	0.0	`ValueError: leiden is neither in .obs nor in .var`

合计 3.8 s、5 张图。没有 `pbmc3k.h5ad`。

3.3 结论

	产出	缺失
Seurat 图	14 张里的 13 张	`Naive_Memory_CD4_DEG.png`
scanpy 图	11 张里的 5 张	PCA、PCA 比值、markers、rank、rank 小提琴、dotplot、终版 UMAP
对象	2 个里的 0 个	`pbmc3k_final.rds`、`pbmc3k.h5ad`

25 张图里的 18 张、2 个对象里的 0 个。修正版（§13）产出 25/25，外加教材本想画却从未画出的比值图，以及两个对象。

3.4 与 28 张参考图的逐图像素比对

每张重生成的图都比对了像素尺寸、着色数量与 64 × 64 归一化结构相关（`results/08_figure_comparison/compare_aswritten_vs_reference.tsv`）。

图	像素（我们 / 参考）	相关度
`PCA_heatmap_ALL.png`	3000×3000 / 3000×3000	**1.0000**
`violin_mt.png`	3000×1500 / 3000×1500	0.9982
`marker_Features_2.png`	6000×3000 / 6000×3000	0.9965
`marker_Features.png`	3000×3000 / 3000×3000	0.9957
`UMAP_with_harmony.png`	3000×1500 / 3000×1500	0.9953
`UMAP_without_harmony.png`	3000×1500 / 3000×1500	0.9941
`UMAP.png`	3000×1500 / 3000×1500	0.9914
`cell annotations.png`	3000×1500 / 3000×1500	0.9898
`PCA_dimplot.png`	3000×1500 / 3000×1500	0.9875
`PCA_VizDimLoadings.png`	3000×1500 / 3000×1500	0.9775
`VariableFeaturePlot.png`	3000×1500 / 3000×1500	0.9751
`PCA.png`	3000×1500 / 3000×1500	0.9603
`Marker_Heatmap.png`	3000×**3000** / 3000×**6000**	0.7250
scanpy：highest-expr、HVG、2 张散点、QC 小提琴	尺寸完全一致	0.9992 - 1.0000

PC 热图上的 1.0000 不是巧合：同一份 PCA、每个主成分同样取 100 个平衡细胞、完全确定的绘图路径，PNG 逐字节级可复现。热图的 0.7250 纯粹是长宽比效应（SC-19）。Part 7 的两张 UMAP 是唯一”真实差异”，而这点差异落在跨运行噪声里（SC-18：我们自己两次运行之间是 0.5631，对参考图是 0.5664）。

---

4. Part 1 —— 载入数据

4.1 教材做了什么

`Read10X()` 把旧版 Cell Ranger 的三个文件读成 32,738 × 2,700 的稀疏矩阵，`CreateSeuratObject()` 包成对象。出现两条警告，两条都有信息量：

```
Feature names cannot have underscores ('_'), replacing with dashes ('-')
```

`genes.tsv` 里有 21 个 symbol 含 _（`RP11-442N24__B.1`、`Metazoa_SRP` 等）。Seurat 静默改写，此后用原符号查找必然失败。Python 侧则对重复项做相反的处理：95 行重复、涉及 91 个符号（32,738 行、32,643 个唯一名），`var_names_make_unique()` 把第二个 `ACE` 变成 `ACE-1`。因此跨工具链关联基因必须用 `gene_ids`，不能用 symbol。

```
Default search for "data" layer in "RNA" assay yielded no results; utilizing "counts" layer
instead.
```

这是 Seurat 5 的消息：`PercentageFeatureSet()` 要 `data` 层，但此刻还没 `NormalizeData()`。功能上无害。

4.2 实测

矩阵	32,738 个特征 × 2,700 个细胞，2,286,884 个非零
基因数 / UMI / 线粒体占比中位	817 / 2,197 / 2.03%
基因数范围	212 - 3,422
线粒体占比范围	0 - 22.6%

4.3 坑与调参

SC-14（符号改写、重复）与 SC-15（旧版布局、无 `features.tsv`）都在这一步。`Read10X()` 能读旧布局，`scanpy.read_10x_mtx()` 靠 `gex_only` 默认值也能读。

调参：`CreateSeuratObject(min.cells = 3)` 是把 R 的基因全集对齐 scanpy `filter_genes(min_cells = 3)` 的自然做法，但**不要随手改**——SC-17 量化了它的代价。

4.4 扩展

若数据来自 Cell Ranger 3+，用 `Read10X_h5()`；其它来源用 `ReadMtx()`；多模态数据要按 `features.tsv` 的类型列区分基因表达与其它特征。

---

5. Part 2 —— 质量控制

5.1 做什么、为什么

三条过滤，对应三种失败模式：基因数太少 = 空滴或死细胞；基因数太多 = 双细胞；线粒体占比高 = 应激或濒死细胞，胞质 mRNA 已外漏。

5.2 实测

规则	`nFeature_RNA > 200 & nFeature_RNA < 2500 & percent.mt < 5`
保留细胞	2,700 中的 **2,638**（97.7%）
因基因数过少丢弃	0
因基因数过多丢弃	5
因线粒体占比 ⩾ 5% 丢弃	57
质控后中位基因数 / UMI / 线粒体占比	820 / 2,214 / 2.01%（线粒体最高 4.99%）

scanpy 侧用 `n_genes < 2000` 保留 **2,635** 个细胞（SC-10）。在原始矩阵上按同样数字独立重算得到 2,634——差的这一个细胞，是线粒体占比在 scanpy 里按**过滤后**的 13,714 基因矩阵计算、而 Seurat 用全部 32,738 个特征，边界细胞的占比因此落在 5% 两侧。记录在 `results/01_qc/qc_rederivation_rawmatrix.csv`。

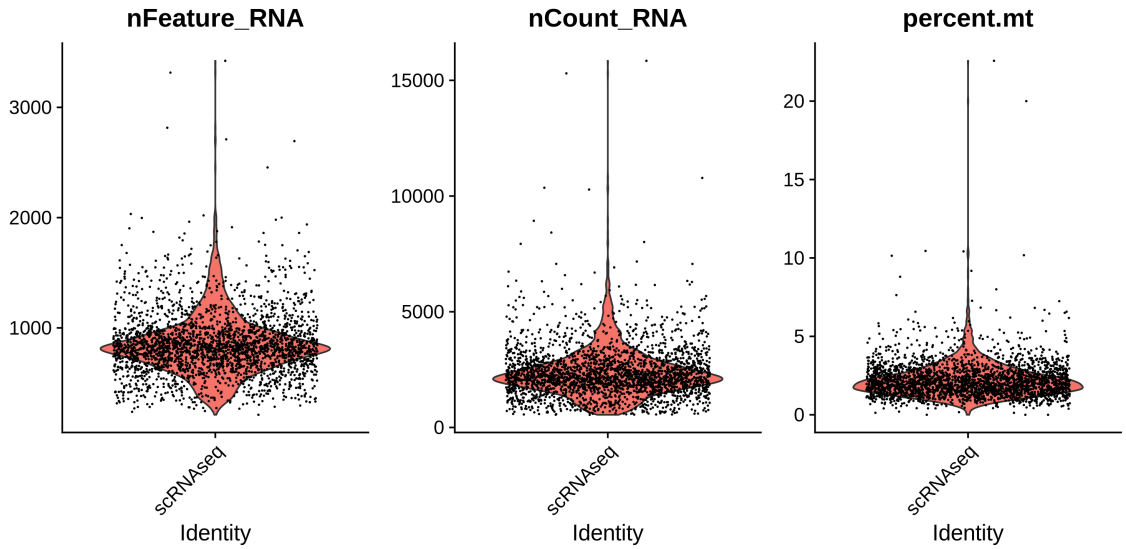


图 1 — Seurat 对全部 2,700 个细胞的质控分布：每细胞基因数、UMI 数、线粒体占比，以及教材的三条阈值。

对着规则 `nFeature_RNA > 200 & nFeature_RNA < 2500 & percent.mt < 5` 来读。基因数分布是 2016 年浅测序数据的典型形状——中位 817，左侧长尾从未触到 200（所以那一侧**一个**细胞都没丢），右侧有一层薄薄的肩（5 个细胞，也是这套流程唯一会当成双细胞删掉的东西）。线粒体占比整体压在 5% 以下，右侧小肩就是被删的 57 个细胞。高 UMI 处**没有**第二个峰，这正是”三个数字就够了、不必上双细胞检测器”的依据。

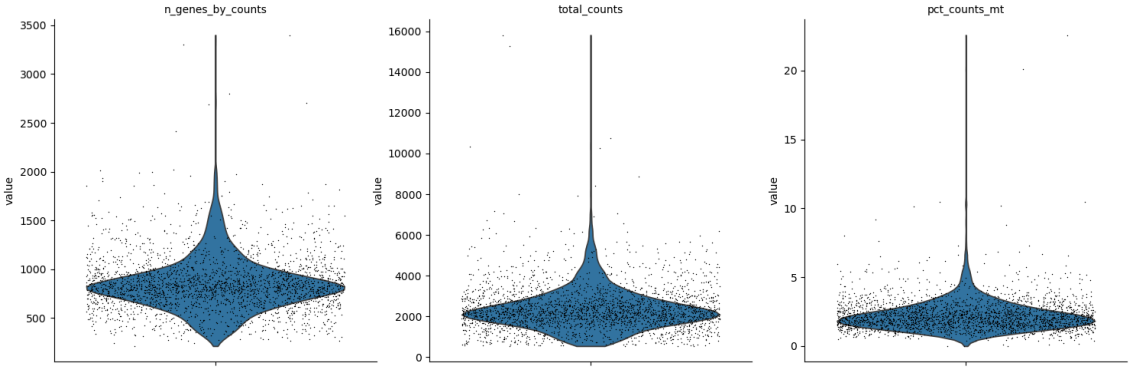


图 2 — scanpy 用 `calculate_qc_metrics` 算出的同样三个指标（在 `filter_cells(min_genes=200)` 与 `filter_genes(min_cells=3)` 之后）。

这张面板不是上面那张的复制品，而差异恰好是要点：它的分布是在**过滤后的 13,714 基因**矩阵上算的，Seurat 那张用的是全部 32,738 个特征。线粒体占比是个比值，去掉 19,024 个全零基因就改变了边界细胞的分母——这正是”同样写 `< 5%`、Seurat 留 2,638 而 scanpy 留 2,635”的那一个细胞的来源（SC-10）。

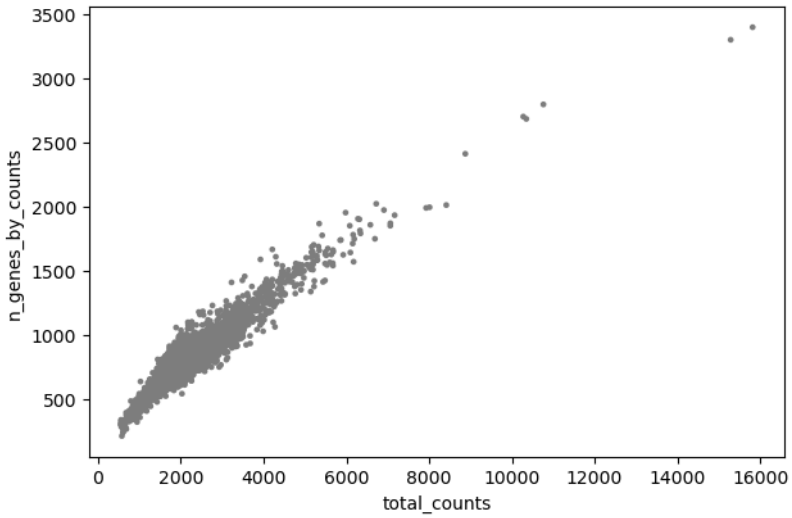


图 3 — 每个细胞的 `total_counts` 对 `n_genes_by_counts`。

这张图就是教材没点名的双细胞检验。主云几乎完全线性——每多一个 UMI 就按固定速率多拿基因——双细胞会落在线上方（同样的 UMI 数却拿到两个细胞的基因量）。这里主云紧致、上方没有分离出来的分支，所以”基因数上限 2,500”实际上是在代理双细胞过滤。

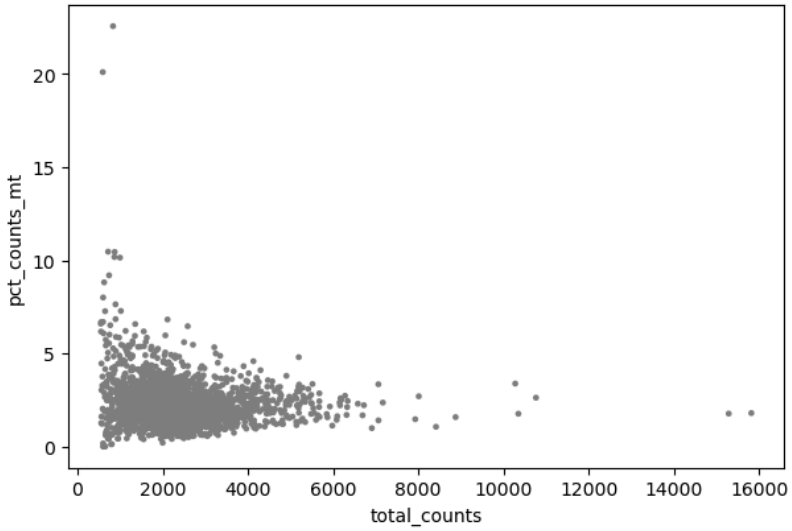


图 4 — `total_counts` 对 `pct_counts_mt`。

读法相反：濒死细胞丢掉胞质 mRNA，线粒体转录本仍留在尚完整的细胞器里，于是往左上漂。5% 那条竖线是穿过稀疏上云画的，而不是穿过某个空隙——这是对任何线粒体阈值诚实的描述：它是一条约定，不是物理边界。

5.3 坑

实质性的是阈值不一致（SC-10）：它就是 §12 里”9 群 vs 8 群”的源头。另需注意 `^MT-` 只匹配实际存在的 13 个基因；换成 `^MT\.`（MitoCarta 风格）或小鼠数据（`^mt-`）要改正则，而一旦不匹配，`PercentageFeatureSet()` 的表现会被误读成数据问题。

5.4 调参

`nFeature` 上限与数据本身强相关：PBMC 3k 是 2016 年的浅测序（中位 817 个基因），2,500 很宽松；现代 10x 数据中位常超 2,000，同样阈值会删掉大部分细胞。定阈值前先看 `nFeature` VS `nCount`、`nFeature` VS `mt%`（教材 cell 61 的两张散点正是为此）。

---

6. Part 3 —— 高变基因

`FindVariableFeatures(selection.method = "vst", nfeatures = 2,000)` 拟合”方差 ~ 平均表达”的 loess 曲线，按标准化残差排序；从 32,738 个特征里选出 2,000 个，出 `VariableFeaturePlot.png`。

两点说明：

- `log-10 transformation introduced infinite values` 是预期警告：`vst` 对离散度取 `log10`，零方差基因给出 `-Inf`，Seurat 会丢弃，消息仅为提示。
- `LabelPoints()` 标注方差最高的 20 个基因：PPBP、LYZ、S100A9、IGLL5、FTL、GNLY、PF4、FTH1、GNG11、S100A8、FCER1A、HLA-DRA、CD74、CLU、NKG7、CST3、GZMB、CCL4、C1QA、HLA-DPB1，全是白细胞 marker，这本身是”方法有效”的体检。

SC-08 在此：`p <- p + plot2` 画出的是**两联图**，参考图带着这个痕迹。`results/02_hvg_pca/` 两个版本都在：`VariableFeaturePlot.png`（原样、两联、对参考 0.9751）与 `VariableFeaturePlot_corrected.png`（修正、单联）。

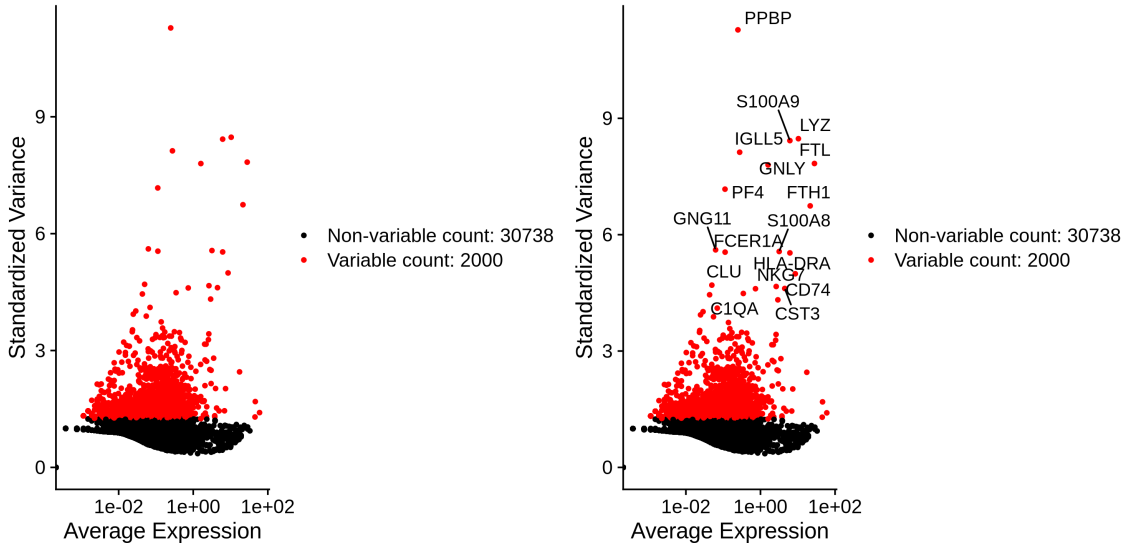


图 5 — 教材原文的 `VariableFeaturePlot.png`：两联图，因为 `p <- p + plot2` 把旧图和有标注的图并排打印了。

左右两半都是同一批 32,738 个基因、2,000 个 HVG 标红；左半没有基因名，右半标了二十个。这是全模块最干净的”代码能跑、产出看起来能用、但做的不是作者本意”的例子——而且下一张图会证明教师自己的参考图也带着同一个痕迹。

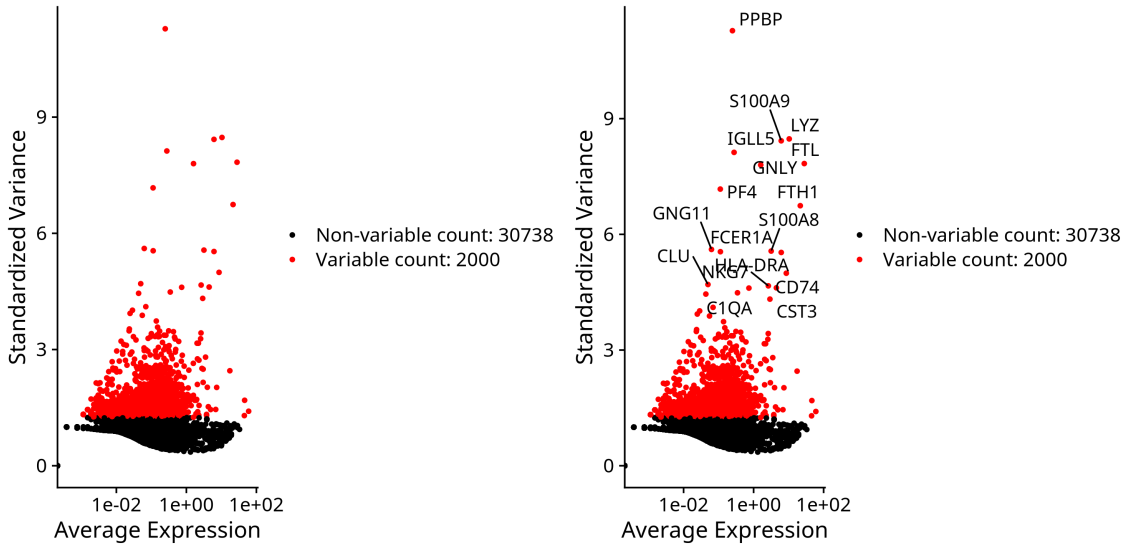


图 6 — 课程随附的参考 `VariableFeaturePlot.png`：同样的两联版式，也就是说这个痕迹被当作”预期产出”发了出去。

把它和图 5 并排看，才是判断”复现”的正确方式：我们的原样跑与之结构相关 0.9751（尺寸相同、点云相同、标注相同），因为两者是同一个两联 bug 的产物。反过来，一个学生”修好”这张图再与参考图对比，会得出”我的分析与老师不同”的错误结论。

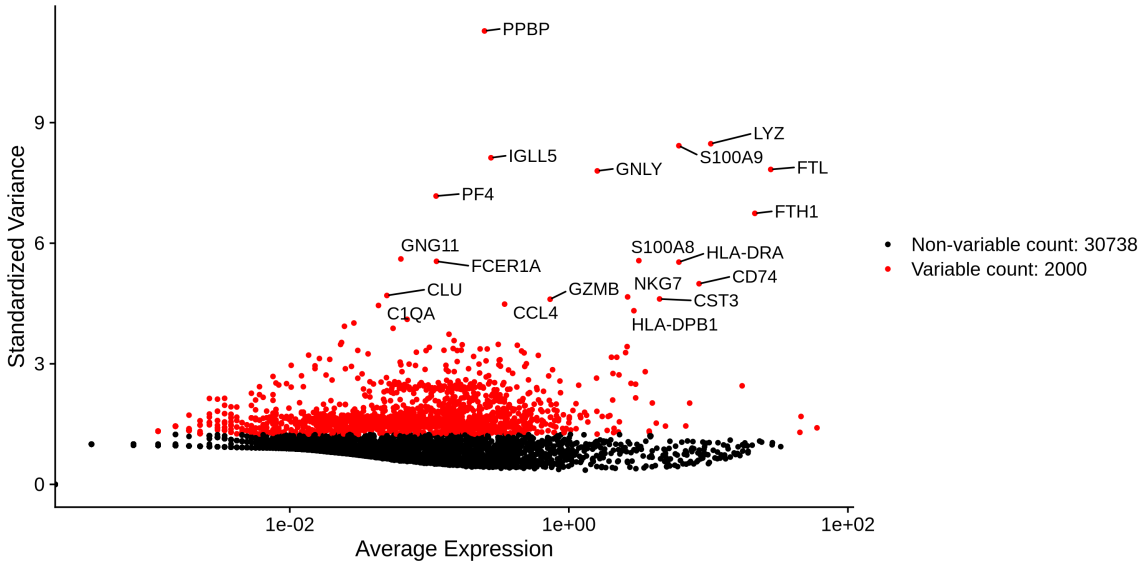


图 7 — 修正后的单联版（`VariableFeaturePlot_corrected.png`）。

修正版用 `LabelPoints(repel = TRUE)` 画一张散点并把二十个标注挂上去。它与参考图的相关度按构造掉到 0.0713：两张图是同一份数据的不同画面。标注本身是体检项——PPBP、LYZ、S100A9、IGLL5、FTL、GNLY、PF4、FTH1、GNG11、S100A8、FCER1A、HLA-DRA、CD74、CLU、NKG7、CST3、GZMB、CCL4、C1QA、HLA-DPB1 全是白细胞基因，说明 `vst` 在 PBMC 上选对了。

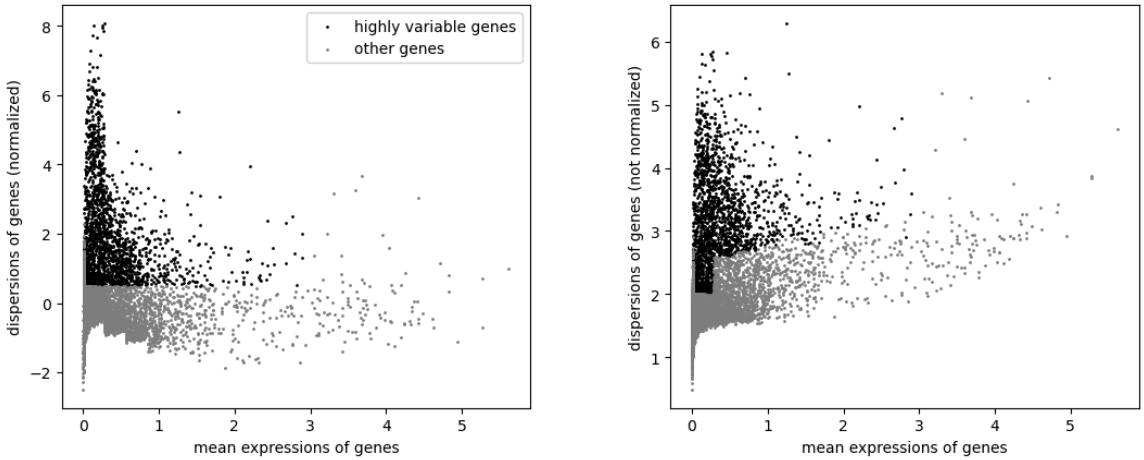


图 8 — 另一侧的 scanpy 选 HVG：标准化离散度对平均表达，选出 1,833 个基因。

两种方法不可互换，这张图就是原因所在：`vst` 对”方差 ~ log 均值”的 loess 拟合做标准化，能提拔均值不高但极端的基因（PF4、PPBP）；scanpy 的 `min_mean 0.0125 / max_mean 3 / min_disp 0.5` 卡的是分箱后标准化数据的离散度，在 13,714 个基因的宇宙里返回 1,833 个。两个数都不错——它们用不同的方差模型回答同一个问题：“哪些基因的变化超出其表达水平所预测的程度”。

---

7. Part 4 —— 标准化与 PCA

`ScaleData(features = rownames(seurat_obj))` 对全部 32,738 个特征做中心化与缩放（SC-01），随后 `RunPCA(features = VariableFeatures(...))` 只用 2,000 个 HVG，返回 50 个主成分。

scale 的特征数	32,738（其中 13,714 非空）
对象体积	0.73 GB
`ScaleData` 耗时	4.2 s
主成分	50
出图	`PCA_VizDimLoadings.png`、`PCA.png`（肘图，20 维）、`PCA_dimplot.png`、`PCA_heatmap_ALL.png`（6 张热图 × 100 细胞）

`PCHeatmap()` 是 `DimHeatmap()` 的废弃别名；Seurat 5.1.0 里仍可用且不报警告，很容易一用多年（SC-07）。肘图呈 PBMC 3k 的经典形状——拐点在 PC 7-10 之间——这正是 `dims = 1:10` 的依据；但肘图画的是 20 维，而正文从未解释为什么取 10。

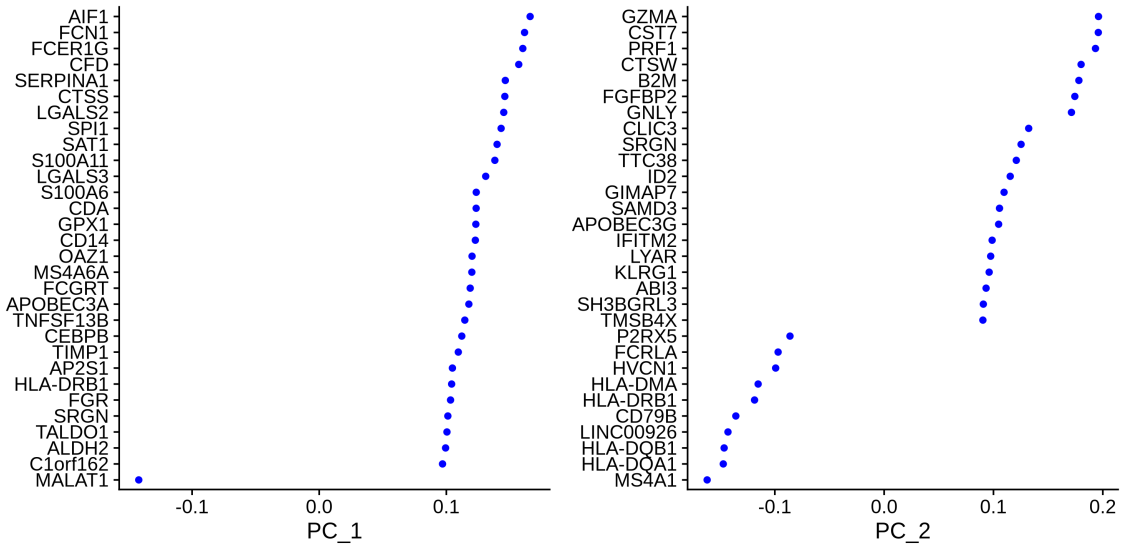


图 9 — `PCA_VizDimLoadings`：PC1 与 PC2 上正负载荷最大的基因。

载荷是 PCA 可解释的那一半。PC1 由单核-淋巴的对比主导（一侧 LYZ、S100A8、S100A9、CD14，另一侧 IL7R、CD3D、LTB），PC2 把 FCGR3A+ 单核与 NK 分开。如果某个主成分拿不出一份连贯的基因清单，那就是”该停止使用它”的信号——这里前几个成分在生物学上可读，这是选 `dims = 1:10` 的一个虽弱但真实的理由。

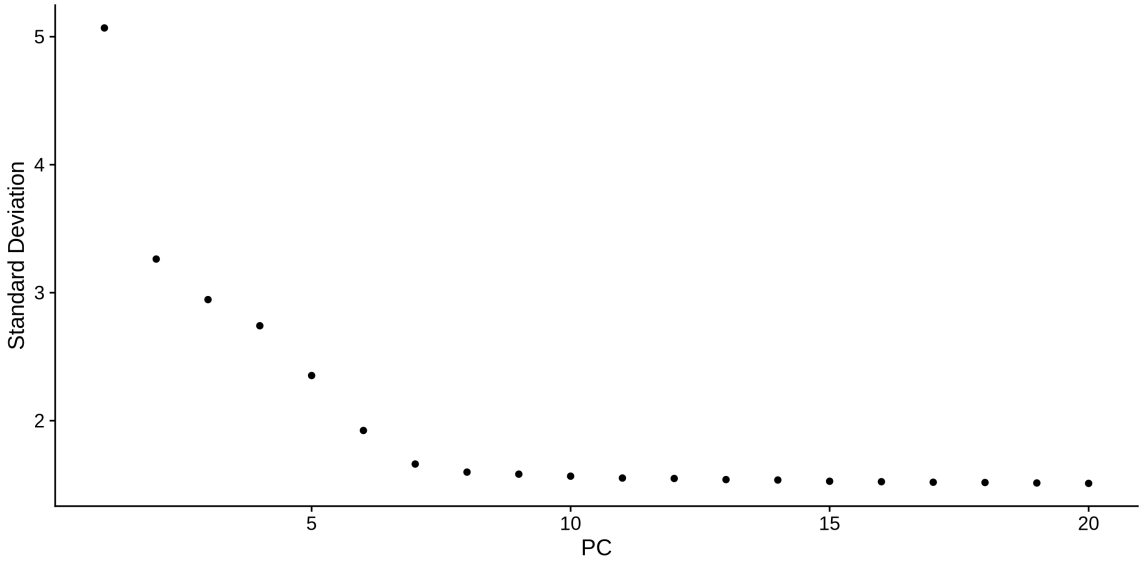


图 10 — `PCA.png`：20 个主成分的标准差肘图。

肘部弯在 PC 7-10 附近然后变平，这就是 `dims = 1:10`（用于 `FindNeighbors`、`FindClusters`、`RunUMAP`）的非正式依据。注意这张图**没有**做什么：它只画 20 维，而 `RunPCA` 算了 50 维；它也不给判据——取 10 是视觉惯例，SC-07 记录的就是教材从未把”画 20”和”用 10”对上。

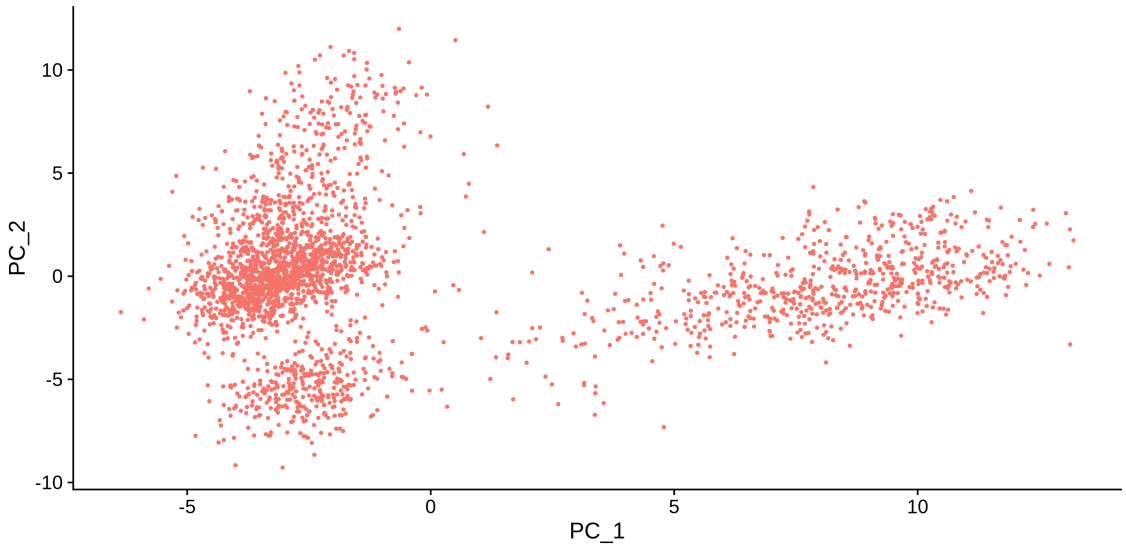


图 11 — `PCA_dimplot`：所有细胞落在 PC1/PC2 平面上。`DimPlot()` 是在 `FindClusters()` **之前**调的，此刻全部细胞仍只有一个身份——单一颜色，`+ NoLegend()` 又把图例去掉了。

不要在这张图里找群：只有一个身份层时颜色不携带任何信息，参考图也是同样的单色（相关 0.9875）。它展示的是聚类**之前**数据的形状——中央一团密实的 T 细胞云、右侧一条独立的臂、左下一个小小的离群瓣——足够得出「不止一个群体」，远不够给任何一个群命名。带颜色的版本要等 `FindClusters()` 之后才有意义，即图 19。

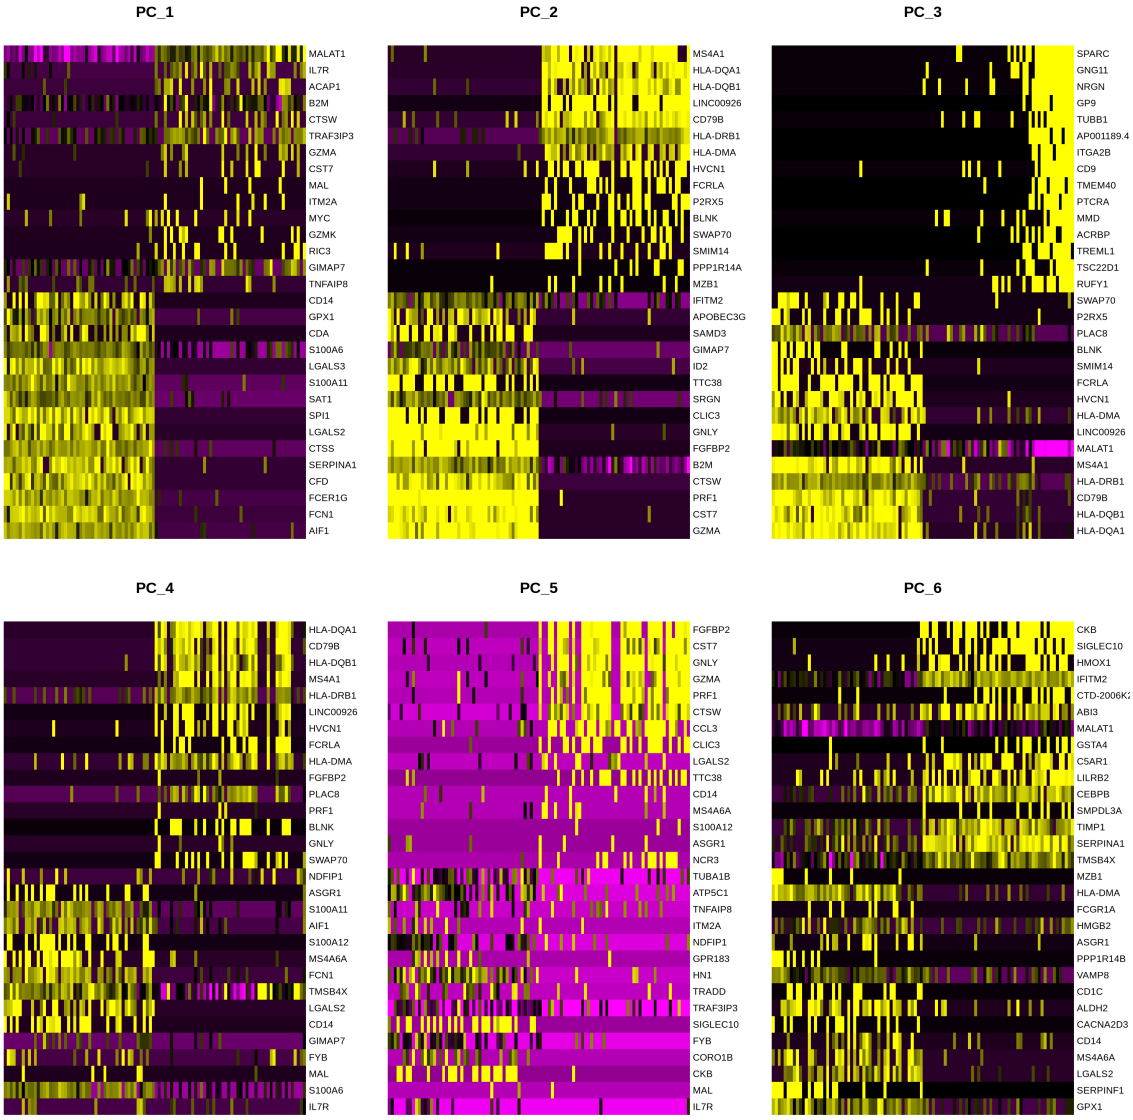


图 12 — `PCA_heatmap_ALL`：前 6 个主成分，每个成分取该成分两端均匀分布的 100 个细胞，右侧印着定义该面板的基因。

每行一个基因、每列一个细胞，面板本身自带解释：PC1 是单核-淋巴的对比轴（CD14、LYZ、S100A8/S100A9、FCN1 对 MALAT1、IL7R、CD3D），PC2 是 B 细胞身份（MS4A1、CD79B、CD74、HLA-DRA/DRB1），PC3 是血小板板块（GP9、ITGA2B、PPBP、SPARC、TREM1）——只有 14 个细胞的血小板群独占一个主成分，这正是它没有在聚类里消失的原因。块状结构就是「好成分」的样子：一组共调控基因在被抽样的细胞里一起亮起来。这张图同时是我们最强的复现证据——与教师参考 PNG 的结构相关为 **1.0000**，即同一份 PCA、同样的平衡抽样、同一条绘图路径，文件几乎逐比特重现。

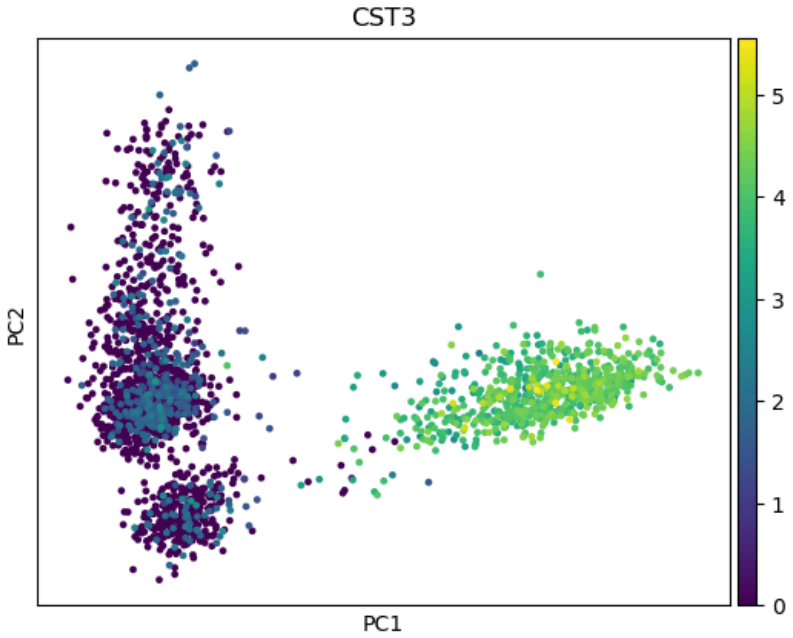


图 13 — scanpy 的 PCA（PC1/PC2，按 CST3 上色），在 1,833 个 HVG 上、`sc.pp.scale(max_value = 10)` 之后计算。

与图 11 对照很有教益：同样的生物学，但轴的朝向与尺度不同——scanpy 在 1,833 个基因上把每个基因标准化到单位方差（截断 10），Seurat 先 scale 32,738 个再投影 2,000 个 HVG。哪个朝向都不是”标准”，主成分本身只定义到符号和旋转——所以两侧 PCA 长得不一样是预期结果，不是 bug。

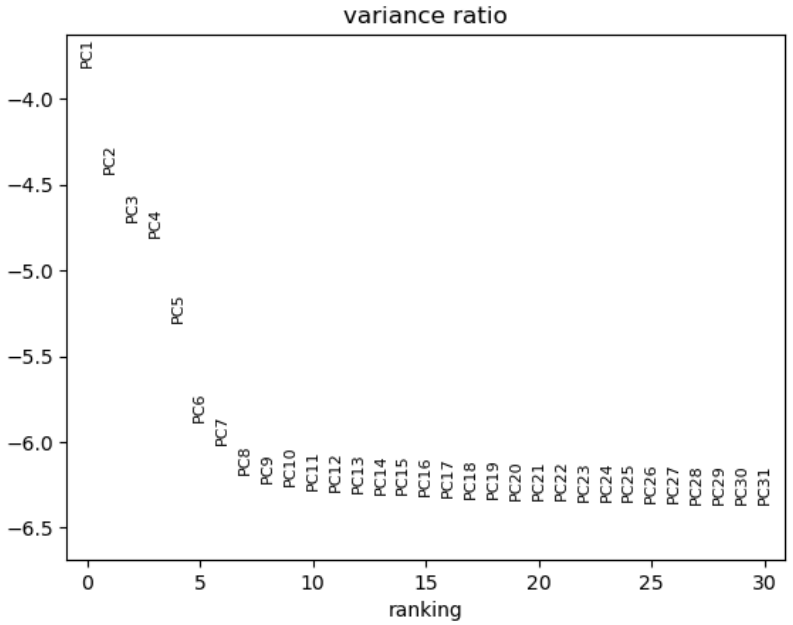


图 14 — `pca_variance_ratio`：教材自己的代码从未画出的那张图。

它在 28 张参考图里缺席的原因很朴素：画它的那个单元带着双逗号（SC-09），而 Python 以整单元格编译，于是 `SyntaxError` 把同一单元格里写着的 PCA、近邻图和 UMAP 一起抹掉了。我们这张来自修正版；累计曲线要到 PC 40 附近才到约 95%，这正是”近邻图用 `n_pcs = 40`“在这份数据上说得通的理由。

`PCA_heatmap_ALL.png` 同时也是”我们的 PCA 与教师完全相同”的证据：结构相关 1.0000。

---

8. Part 5 —— 聚类与 UMAP

```
FindNeighbors(seurat_obj, dims = 1:10)      # 10 个 PC 上的 SNN 图
FindClusters(seurat_obj, resolution = 0.5)  # Louvain
RunUMAP(seurat_obj, dims = 1:10)
```

图	2,638 个节点、95,650 条边
Louvain	模块度 0.8584，**9 个社区**
群大小	657 / 503 / 471 / 339 / 307 / 175 / 144 / 28 / 14
UMAP	`UMAP.png`；关于 uwot 取代 Python UMAP 的警告

群大小本身已经回答了”这是不是真实生物学拆分”：657 与 503 是两个 CD4 腔室，471 单核、339 B、307 CD8、175 FCGR3A+ 单核、144 NK，最后两个小群——28 个树突状细胞、14 个血小板。血小板群只占 0.5%，在 `resolution = 0.5` 下能保留，0.3 就没了。

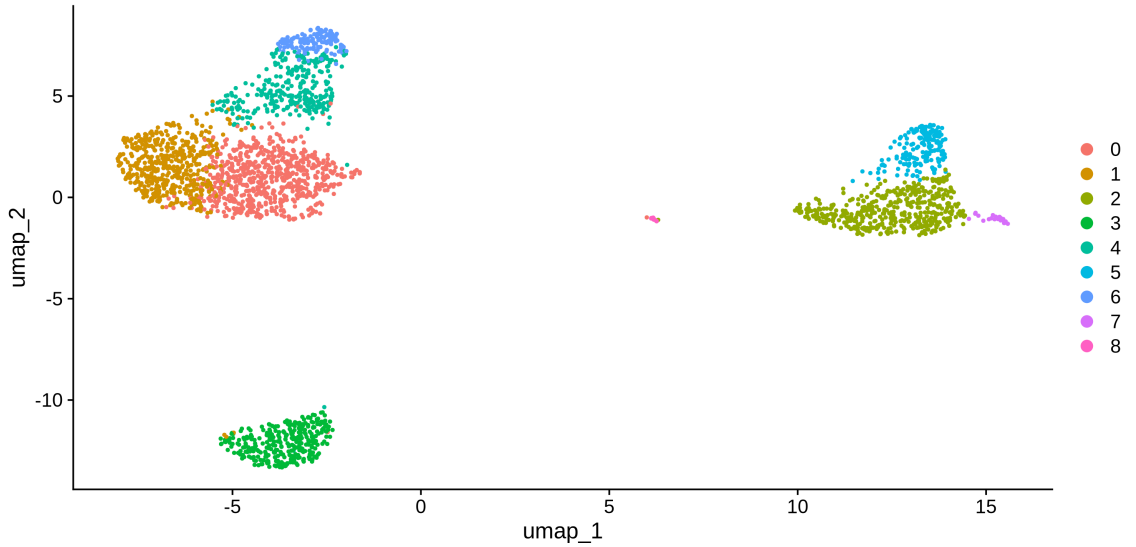


图 15 — 2,638 个细胞的 Seurat 9 群 UMAP（`UMAP.png`）。

拓扑就是 PBMC 3k 的教科书图景：一大片 T 细胞叶（0、1、4），一条被大片空白隔开的单核臂（2、5），一座紧凑的 B 岛（3），加两颗小卫星——NK（6）和最外角上的 DC（7）与血小板（8）。第一件要检查的不是颜色，而是两个小群：2,638 个细胞里的 28 个与 14 个（1.1% 与 0.5%），它们在图上与一切清晰分离，marker 面板（FCER1A/CLEC10A 对 PPBP/PF4）毫不含糊。视觉上的告诫是：UMAP 的群间距离不是定量的，所以”cluster 2 离 cluster 0 很远”绝不能读成”单核与 CD4 T 的差异比 B 细胞更大”。

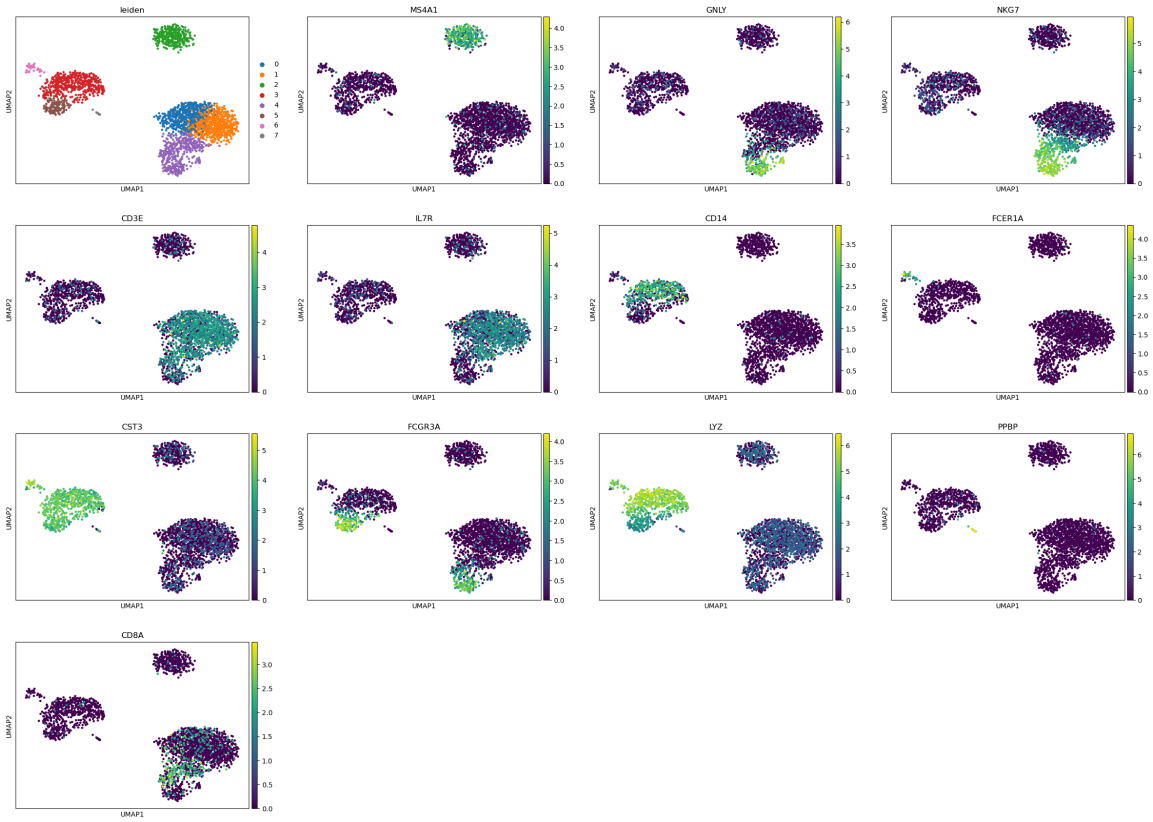


图 16 — 同一份数据的 scanpy 版本：分辨率 0.9 的 leiden 加十二个 marker 面板（`umapscanpy_markers.png`）。

一张顶九张：第一格是 leiden 解（教材阈值下 8 群），其余格是同一嵌入上叠加的 marker 基因。把它当作两个独立工具的一致性检查来读——B 细胞只在某一群里点亮 MS4A1/CD79A，单核点亮 CD14/LYZ/FCGR3A，血小板点亮 PPBP——同时注意它与 Seurat 不一致的地方：NK 的 marker（GNLY、NKG7、KLRF1）在这里跨了两个群，因为 40 维 PC 的近邻图把 CD8 T 与 NK 并成一个邻域，这个分辨率再按另一条边界把它切开。

---

9. Part 6 —— 注释与差异表达

9.1 两份硬编码映射互相矛盾（SC-02）

教材把 cluster → 细胞类型映射写了两遍：

cluster	cell 39 的表	cell 43 的 `new.cluster.ids`	marker 说的是什么
0	Naive CD4 T	Naive CD4 T	CD4（LDHB、IL7R、LTB、CD3D、IL32）
1	**CD14+ Mono**	**Memory CD4 T**	**CD4**（CCR7、NOSIP、LEF1、FHIT、NELL2）
2	**Memory CD4 T**	**CD14+ Mono**	**单核**（LGALS2、S100A8、FCN1、S100A9、CD14）
3	B	B	B（CD79A、MS4A1、CD79B）
4	CD8 T	CD8 T	CD8（GZMK、CCL5、GZMA、CST7）
5	FCGR3A+ Mono	FCGR3A+ Mono	FCGR3A+ 单核（CDKN1C、HES4、MS4A7、FCGR3A）
6	NK	NK	NK（GZMB、FGFBP2、SPON2、PRF1）
7	DC	DC	DC（SERPINF1、FCER1A、CLEC10A）

cluster	cell 39 的表	cell 43 的 `new.cluster.ids`	marker 说的是什么
8	Platelet	Platelet	血小板（GP9、ITGA2B、LY6G6F）

本次运行里**向量对、表错**：把 cell 39 的表抄进 `new.cluster.ids` 的学生，会把 503 个 CD4 T 细胞标成单核、把 471 个单核标成 CD4 T。两份输出都在 `results/04_annotation/cluster_label_audit.csv`，其中”观测到的程序”由 marker 面板（`marker_panel_mean_expression_seurat.csv`）给出。

用同样的方法检查最终对象的标签，9 个全对：

标签	细胞数	证据（log 标准化均值）
Naive CD4 T	657	IL7R 1.70、CCR7 0.58、LEF1 0.57、CD14 0.03
Memory CD4 T	503	IL7R 1.19、CCR7 0.84、CD14 0.03
CD14+ Mono	471	CD14 1.53、LYZ 5.09、S100A8 3.91
B	339	MS4A1 2.17、CD79A 2.80
CD8 T	307	CD8A 1.01、CD8B 0.79、NKG7 3.36
FCGR3A+ Mono	175	FCGR3A 2.75、MS4A7 1.71
NK	144	GNLY 4.17、GZMB 3.68、KLRF1 0.52
DC	28	FCER1A 2.11、CLEC10A 1.28
Platelet	14	PPBP 5.85、PF4 4.93

对得**靠运气**：§13.2 显示，只要 2,000 个 HVG 里变 30 个（1.5%），cluster 1 与 2 就互换编号，同一个固定向量立刻变成 957 个细胞标错。

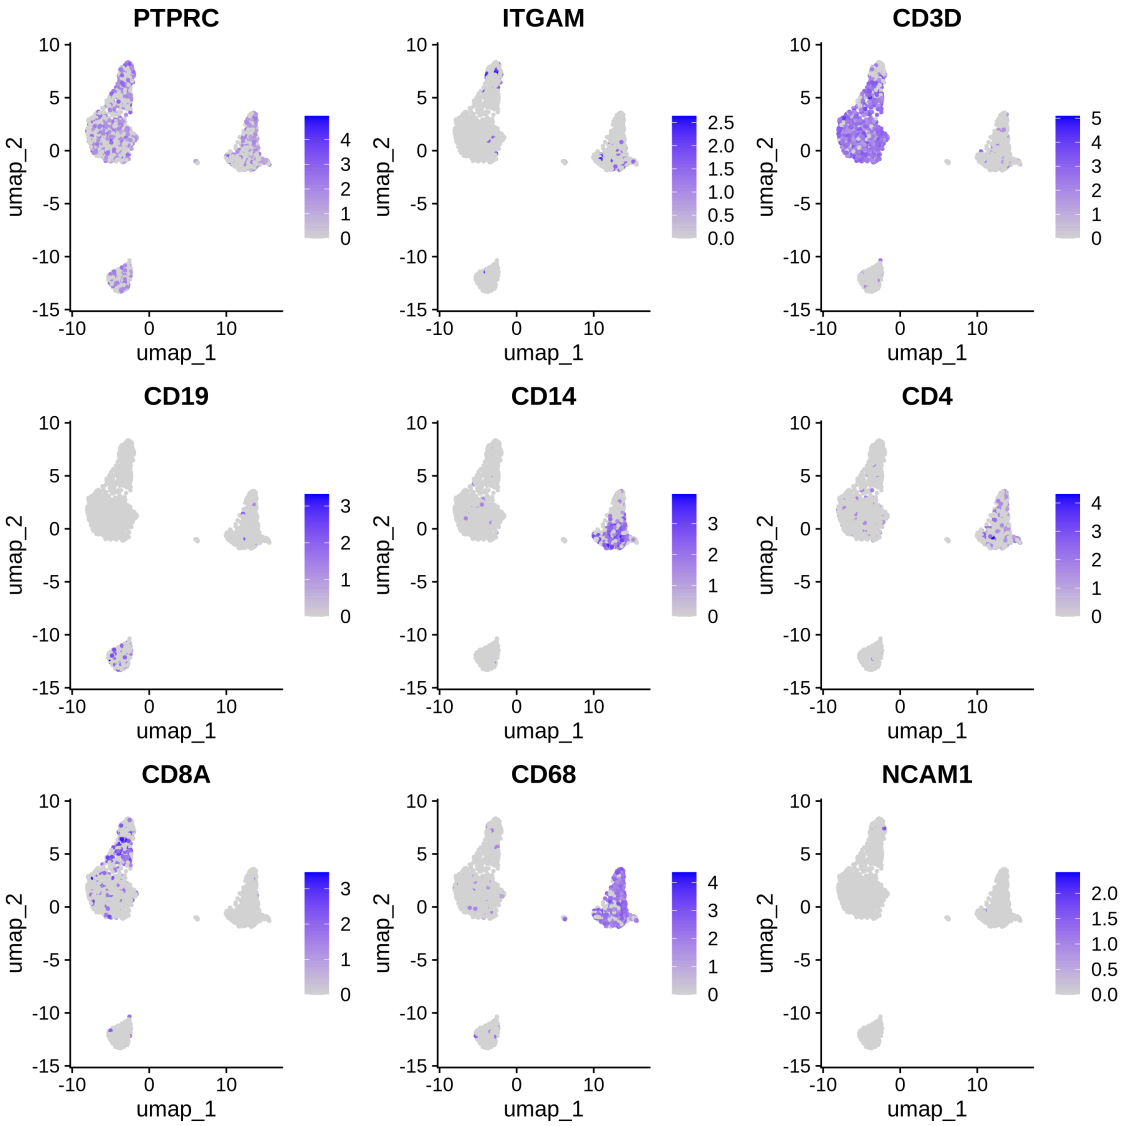


图 17 — `marker_Features`：教材第一个 `FeaturePlot` 调的九个宽谱系 marker——PTPRC、ITGAM、CD3D、CD19、CD14、CD4、CD8A、CD68、NCAM1。

这是粗筛的那一遍，值得逐格读，注意它点亮了哪一群、**哪些群仍然是暗的**。PTPRC（CD45）到处都亮——那是内置的阳性对照，说明留下来的每个细胞确实是白细胞。ITGAM（CD11b）与 CD68 点亮单核臂（cluster 2 与 5）；CD3D 与 CD4 点亮 T 叶（0、1、4）；CD8A 标记该叶的细胞毒边缘（4）以及较弱的 NK；CD19 只点亮一座紧凑的岛——cluster 3，B 细胞；CD14 标经典单核（2）；NCAM1（CD56）标 NK 群（6）。两个局限立刻暴露，也正是需要第二张面板的原因：CD4 对 CD8A 无法区分 cluster 0 与 1（两者都是 CD4 T），而 28 个细胞的 DC 与 14 个细胞的血小板群在这种「通用层级」的 marker 上几乎看不出来。

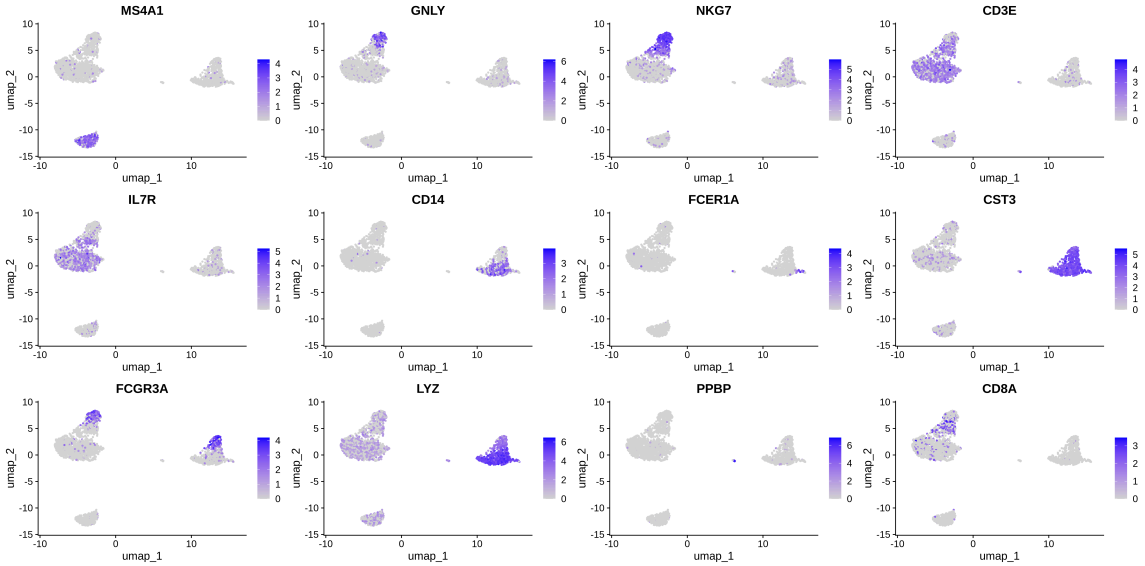


图 18 — `marker_Features_2`：教材第二个 `FeaturePlot` 调的十二个细粒度 marker——MS4A1、GNLY、NKG7、CD3E、IL7R、CD14、FCER1A、CST3、FCGR3A、LYZ、PPBP、CD8A。

这张面板定下了九个群里的七个：MS4A1 单独划出 B 岛，GNLY/NKG7 划出 NK 群，FCER1A/CST3 划出 28 个细胞的 DC 群，PPBP 划出 14 个细胞的血小板群，FCGR3A 把非经典单核（5）与 CD14/LYZ 的经典单核（2）分开，CD8A 标出细胞毒 T 腔室。要点是它**没有**定下什么：cluster 0 与 1 在这十二个 marker 上完全无法区分——IL7R 与 CD3E 在两边都亮，谁也没有 naive 或 memory 专属的 marker。所以教材的 `Naive CD4 T` / `Memory CD4 T` 之分，在教材的任何一张图里都无法验证；它完全依赖 `FindMarkers`（图 23）以及那串固定名字恰好落在哪个编号上（SC-02）。另外这十二个 marker 里有两个是共享而非特异的——LYZ 在 naive CD4 T 里也表达 0.96、在单核里 5.09，CD68 同时染单核与一部分 DC——这就是注释要用 marker **对**的原因。

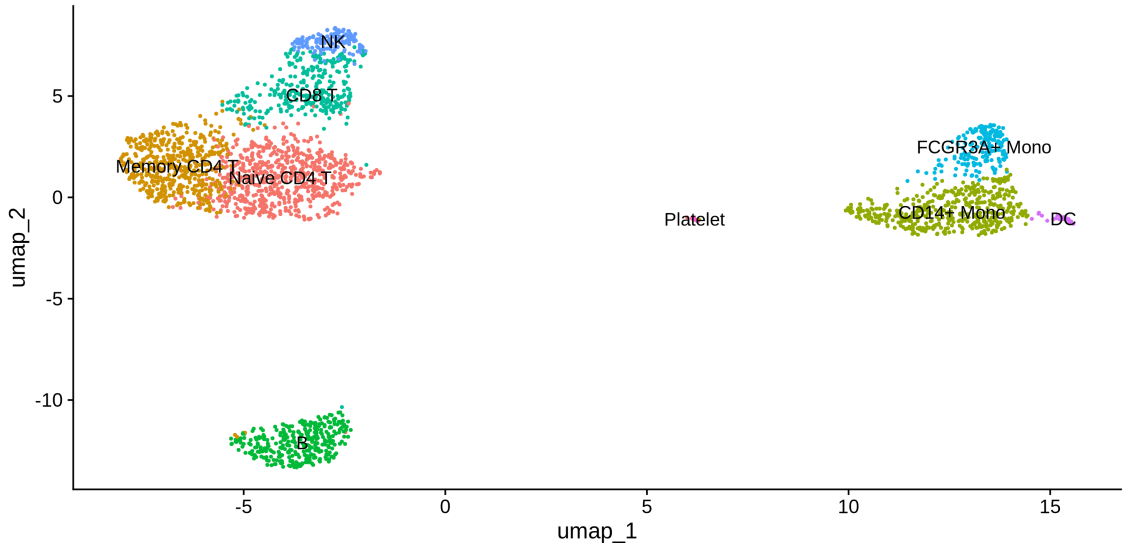


图 19 — Seurat 对象的最终注释 UMAP（`cell annotations.png`）。

九个标签直接画在数据上，与 §9.1 的审计表一一对应。把它当作下游所有论述的对照：单核臂是 `CD14+ Mono`（cluster 2，471 个细胞）与 `FCGR3A+ Mono`（cluster 5，175），上部 T 叶是 `Naive CD4 T`（0，657）加 `Memory CD4`

T（1，503），最远的 cluster 4 是 CD8 T（307）。后文任何涉及某个腔室的说法都可以用这里的颜色核对——这正是为什么 §13.2 里”30 个 HVG 扰动后 cluster 1/2 互换”这种错标在这张图里看起来完全正常。

9.2 Marker 与热图

`FindAllMarkers(only.pos = TRUE)`	9 个群共 11,986 行，330 s（无 presto）
通过 `p_val_adj < 0.05 & avg_log2FC > 1`	3,483 行
进热图	90 个（每群 10 个）
每群显著数	89（cluster 0）… 753（cluster 5）

SC-03：过滤算完就丢，`top10` 来自未过滤表，`slice_max(avg_log2FC)` 完全可以把 `p_val_adj = 0.2` 的基因选进去。修正版先过滤（3,483 行）再每群取 10 个；由此得到的热图与参考图相关 0.9865。

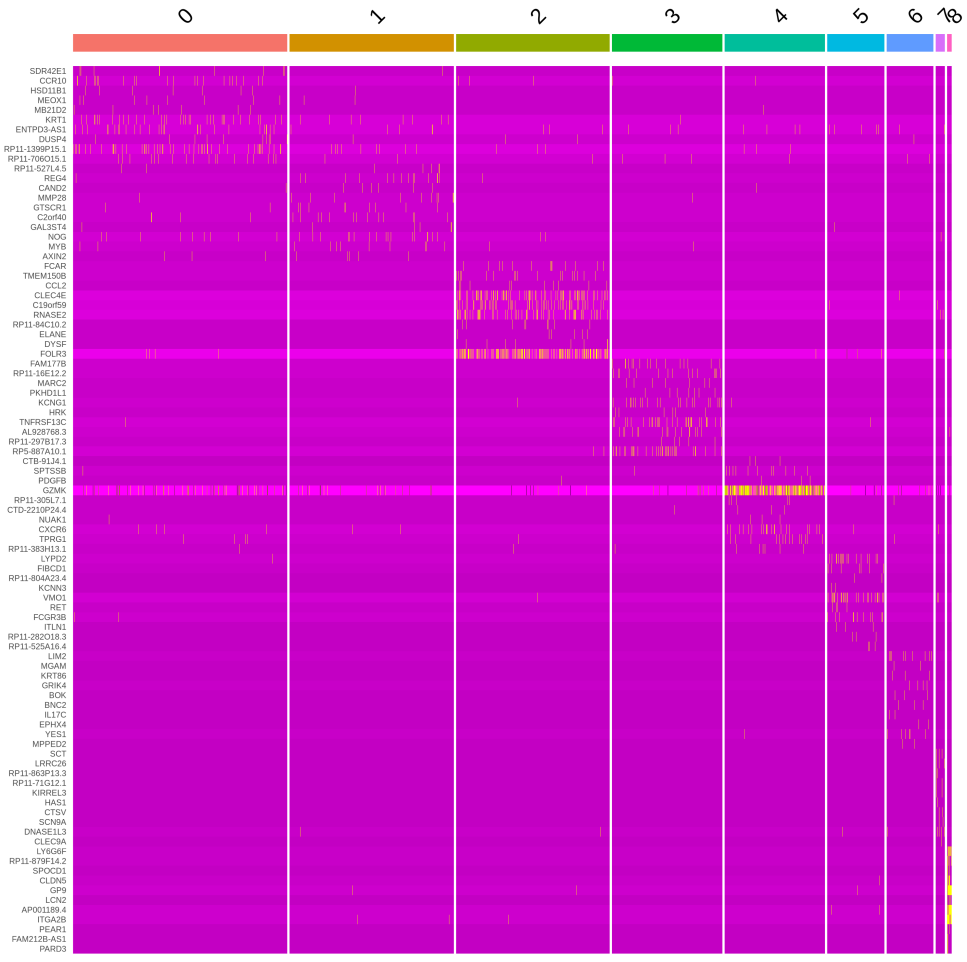


图 20 — 原样的 `Marker_Heatmap.png`：每群按 `avg_log2FC` 取前 10 个基因，取自带**未过滤**的 marker 表。

块状结构看起来令人放心——每群都有一组亮的基因、在别处都暗——但这张图正是 SC-03 的视觉形态。因为过滤算完就丢（`dplyr::filter()` 写在一条没人赋值的管道里），`slice_max(avg_log2FC)` 只按效应量排序，完全可以把 `p_val_adj = 0.2` 的基因与 `p_val_adj = 1e-40` 的基因并排放。读者从颜色上看不出这一点：图里画的是标准化计数，一个不显著的基因只要在少数细胞里高，看起来照样很有说服力。

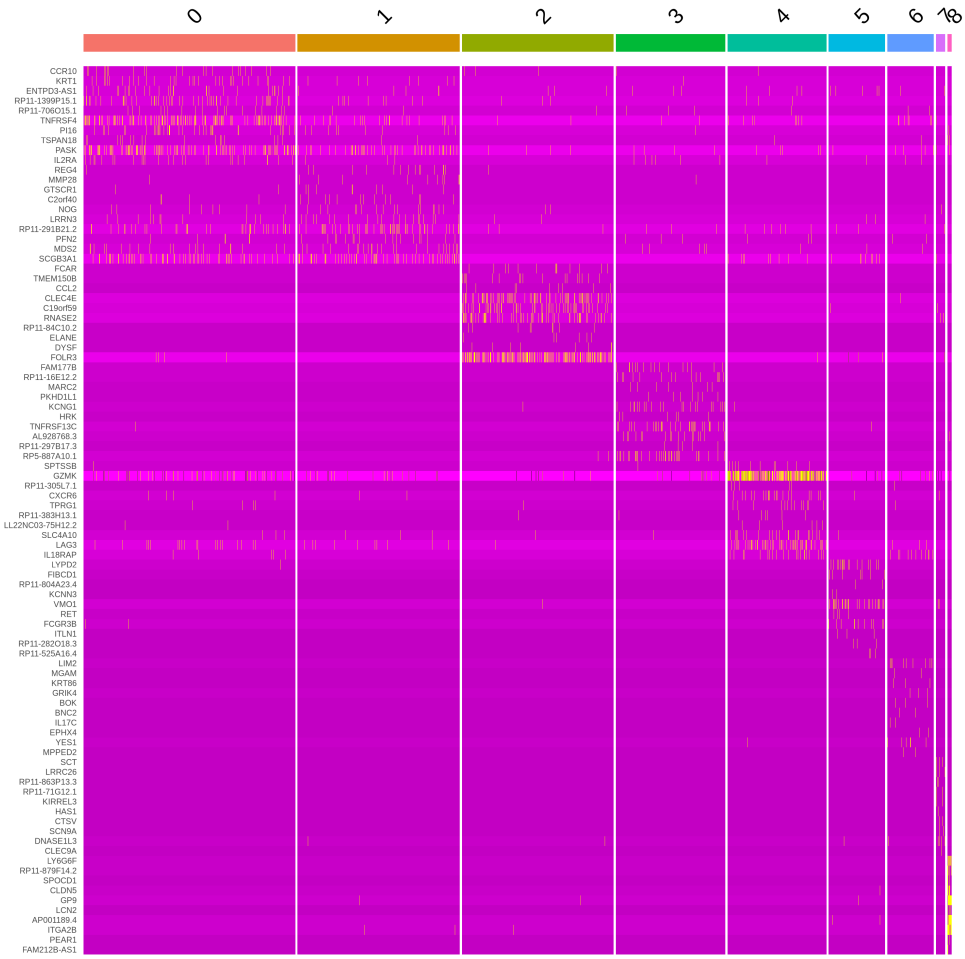


图 21 — 修正版热图：从通过 `p_val_adj < 0.05 & avg_log2FC > 1` 的 3,483 个 marker 里选 90 个。

同样的九个块、同样的颜色、不同的基因清单。有意思的对比是哪些块**保持**清晰：B 细胞（CD79A/MS4A1/TCL1A）、单核（LYZ/S100A8/S100A9）与血小板（PPBP/PF4）在两版里几乎一样，因为它们的效应是压倒性的；变化最大的是 CD4 那两块，因为”naive vs memory”是细微对比（log2FC 2-4 而非 20），这正是显著性过滤的价值所在。对参考图相关 0.7586——可见差距来自被剔掉的基因，而不是聚类变了。

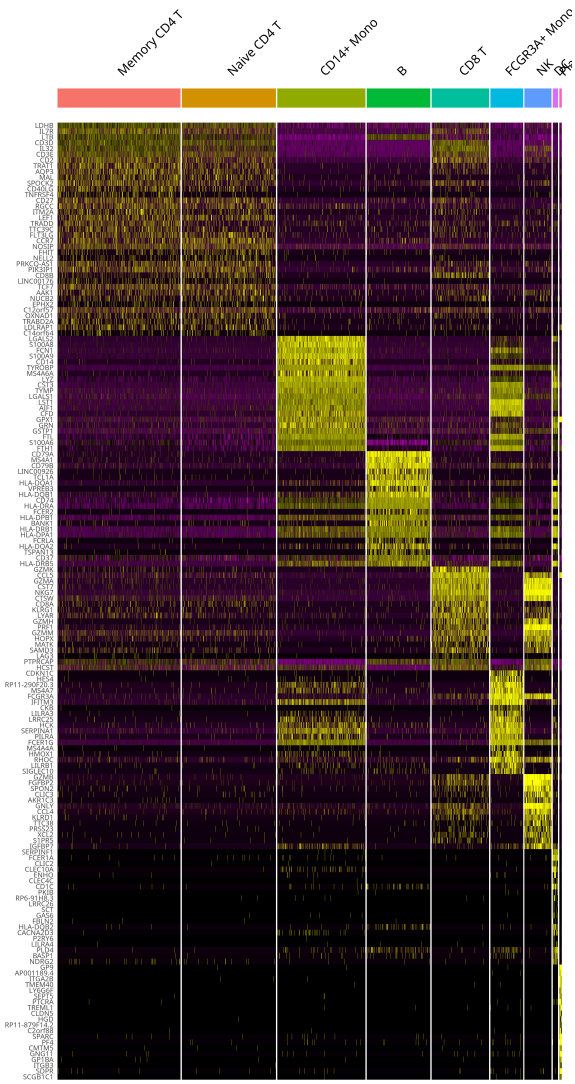


图 22 — 课程随附的参考 `Marker_Heatmap.png`：3,000 × 6,000 px，即 300 dpi 下 10 × 20 英寸。

教材的 `ggsave("Marker_Heatmap.png", width = 10, height = 10)` 只能产出 3,000 × 3,000。参考图高了一倍（SC-19），所以它**不是**教材代码的产物——想必是用了更高的画布给九个块腾地方。这就是为什么它与我们 3,000 × 3,000 输出的比对分数是 0.7250，而本模块其余图都在 0.96 以上：差别在长宽比，不在数据。

9.3 DEG 单元崩了（SC-16）

`geom_text_repel()` 需要 `library(ggrepel)`，而教材只载入了 Seurat、dplyr、ggplot2。于是这个单元在**最贵的部分之后**失败：

`FindMarkers(ident.1 = "Naive CD4 T")`	724 个基因，353 个 `p_val_adj < 0.05`，其中 199 个同时 `|log2FC| > 0.5`
`FindMarkers("Memory CD4 T", "Naive CD4 T")`	650 个基因，129 个 `p_val_adj < 0.05`
报错	`could not find function "geom_text_repel"`
后果	没有 `Naive_Memory_CD4_DEG.png`，**也没有 `pbmc3k_final.rds`**

火山图按 `p_val_adj` 排前五的是 LDHB（1.2e-115）、IL7R（1.8e-102）、LTB（1.9e-97）、CD3D（2.0e-91）、IL32（7.7e-86）——即"naive CD4 T 相对其余细胞"主要是 naive marker 更高、单核/B/NK 基因更低，这正是 `avg_log2FC > 0` 的含义。

SC-04：`-log10(p_val_adj)` 在本数据上是有界值（最小 1.24e-115），但离 `Inf` 只差一次舍入；两个基因列表算完不用；两张表都不落盘。

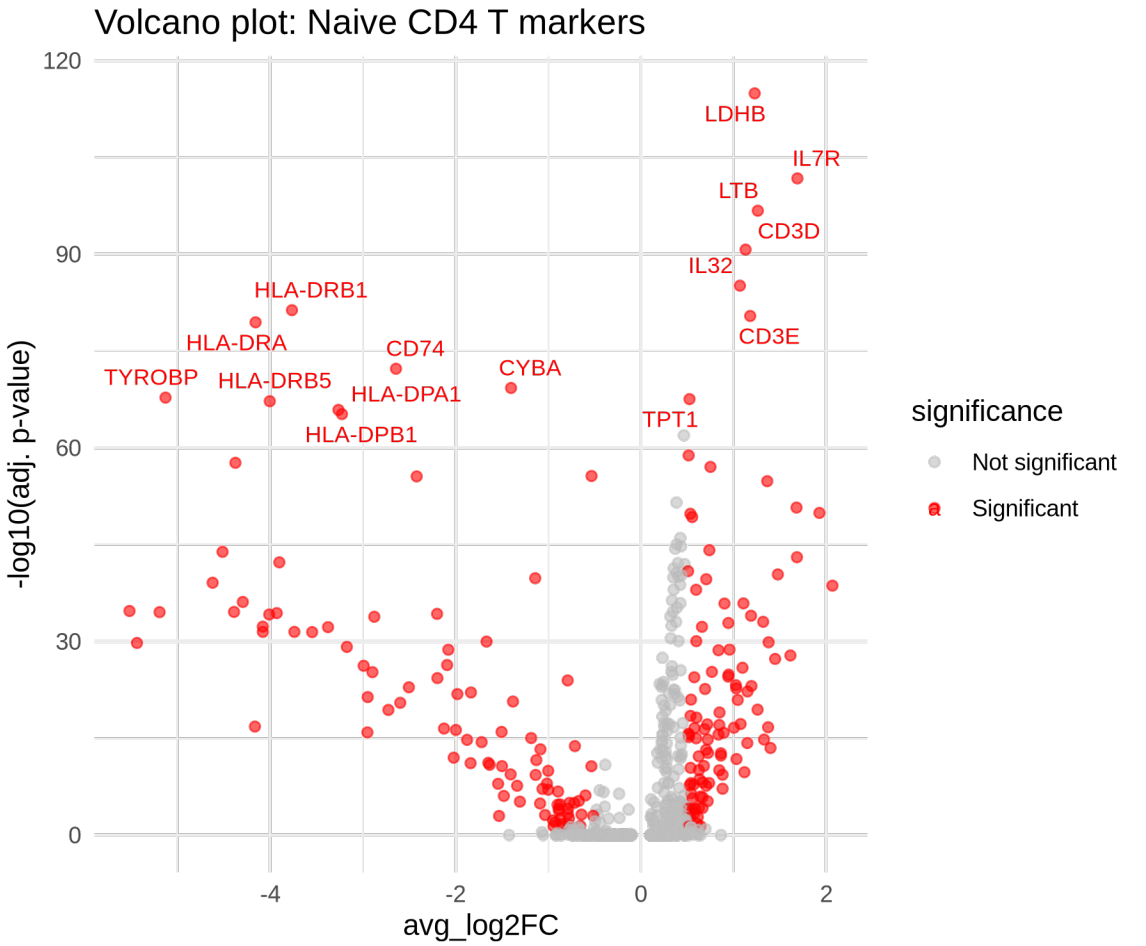


图 23 — `Naive_Memory_CD4_DEG.png`：教材要求画、却从未得到的那张火山图。横轴 `avg_log2FC`（naive CD4 T 对其余全部细胞），纵轴 `-log10(p_val_adj)`，红色是通过代码自身两条标准的基因。

这张图有**两个**峰，两个都要读。高那个（y > 85）在正向——LDHB、IL7R、LTB、CD3D、IL32、CD3E——即 naive CD4 T 由「**有** T 细胞程序」来定义。低一些的第二个峰（y 55-80）在负向，由抗原提呈与髓系基因主导：HLA-DRA、HLA-DRB1、HLA-DRB5、HLA-DPA1、HLA-DPB1、CD74、TYROBP、CYBA。所以 naive 状态同样由「**没有**什么」来定义——没有 MHC-II、没有髓系机器——而这恰恰是教材那张只取正向（`only.pos = TRUE`）的 marker 表永远看不到的。724 个受检基因里 353 个通过 `p_val_adj < 0.05`、199 个同时通过两条标准；红色包络与灰色团之间那道竖向空隙，就是效应量过滤在起作用。两个代码细节：这个单元之所以存在，是因为补了 `library(ggrepel)`（SC-16）；纵轴之所以有界，是因为把 `p_val_adj` 用 `.Machine$double.xmin` 托了底（SC-04）——在约 13k 个基因上，它离 `Inf` 只差一次舍入。

---

10. Part 7 —— 去批次整合

10.1 教材做了什么

载入 `pbmc_stim.RData`，建两个 Seurat 对象，设 `orig.ident`，`merge()`，然后**完全不质控**地 `NormalizeData` → `FindVariableFeatures` → `ScaleData` → `RunPCA` → `RunUMAP(1:10)` → `DimPlot`（SC-06），再 `RunHarmony(group.by.vars = "orig.ident")` → `RunUMAP(reduction = "harmony", dims = 1:10)` → `DimPlot`。

10.2 实测

ctrl / stim 细胞数	13,019 / 12,875（35,635 个特征）
合并后	25,894 个细胞
教材省略的质控	12,932 / 12,779 → **25,711**（−183，−0.7%）
去批次前 UMAP	`UMAP_without_harmony.png`
去批次后 UMAP	`UMAP_with_harmony.png`
harmony 输入	**全部 50 个 PC**（SC-20），UMAP 只用前 10 个

10.3 把”只能看图”的部分量化

修正版补了一个不需要聚类的指标：对每个细胞，取 30 个最近邻，算其中来自**另一样本**的比例（0 = 完全分家，0.5 = 完全混合）。

空间	跨样本近邻比例
PCA（10 个 PC），未去批次	**0.0287**
harmony（10 维）	**0.4051**

再把 harmony 嵌入按分辨率 0.5 聚类：

群数	12
单样本占比 > 90% 的群	**0**
ctrl 占比偏离 0.5 的平均绝对值	0.030

最大的群 6,065 个细胞（3,096 ctrl / 2,969 stim），最小的 92 个（38 / 54）。这就是”harmony 起作用了”的数字版：跨样本近邻比例从 2.9% 升到 40.5%（去批次前，每个细胞的 30 个近邻里有 97% 来自同一样本），而每个群内部两个样本仍然平衡。

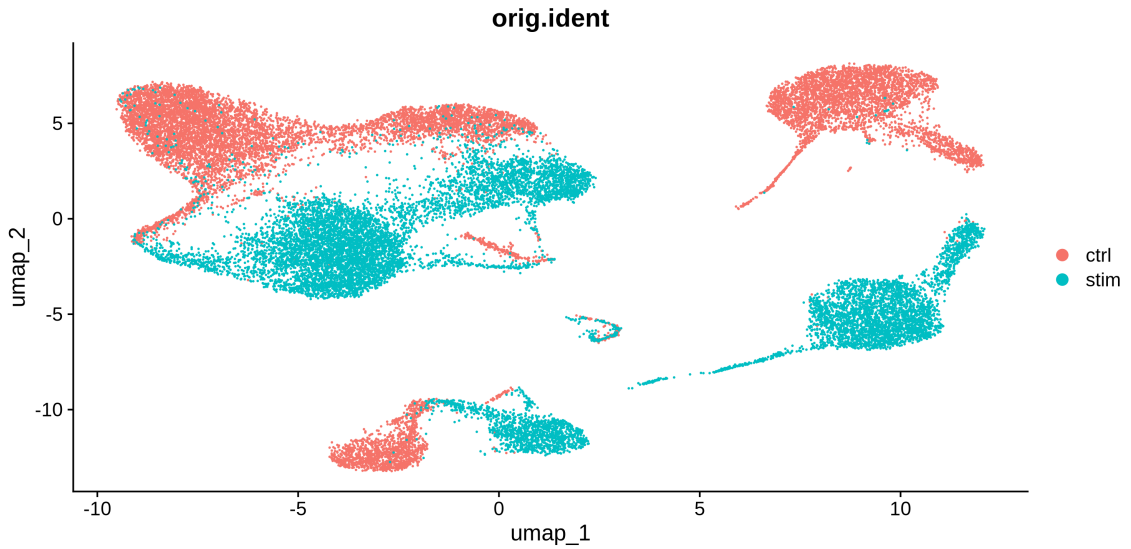


图 24 — `UMAP_without_harmony.png`：合并后的 25,894 个 ctrl+stim 细胞，按 `orig.ident` 上色。

两种颜色、两个瓣：control 与 stimulated 各占一块，只在一条细缝处接触。这是教科书式的批次混淆——刺激既是生物学效应，也是技术漂移（两次 10x 运行、捕获效率不同），未校正的嵌入让技术那部分占了主导。这张图同时也是教材**完全不质控**画出来的（SC-06）：没有线粒体阈值、没有基因数阈值，于是两个瓣各自背着自己的低质量细胞。

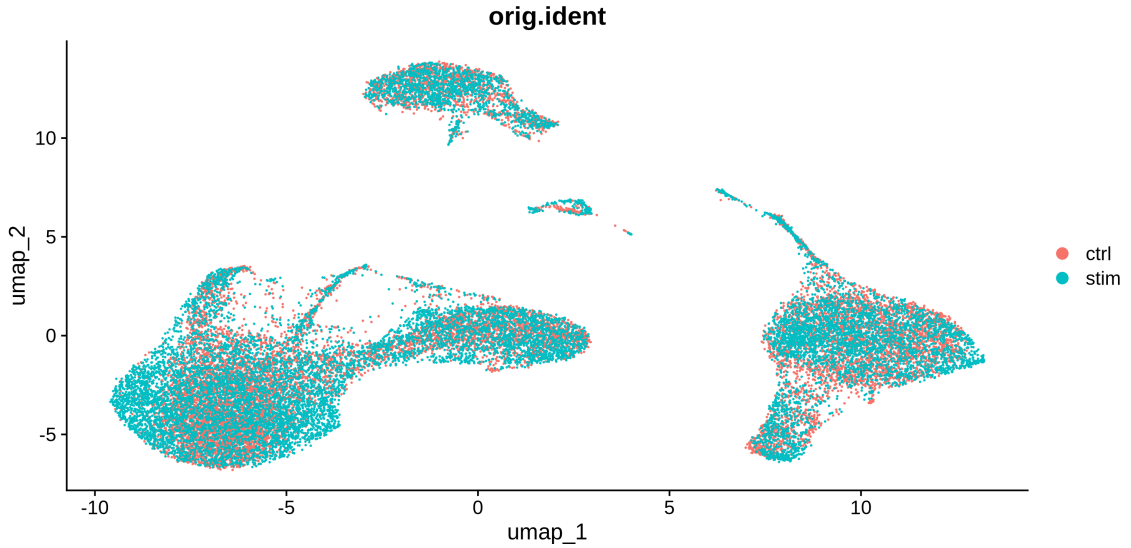


图 25 — `UMAP_with_harmony.png`：同样这批细胞 `RunHarmony(group.by.vars = "orig.ident")` 之后。

颜色在每一座岛上都交错开，这就是”批次被去掉了”的视觉主张。把图当作假设、把上面那张表当作检验：跨样本近邻比例从 PCA 空间的 0.0287 升到 harmony 空间的 0.4051；修正版聚类后得到 12 个群，**没有一个**群的单样本占比超过 90%（ctrl 占比偏离 0.5 的平均绝对值 0.030）。这张图展示不了的两点告诫：harmony 用了全部 50 个 PC 而 UMAP 只用前 10（SC-20）；同一份代码跑两次会给出结构不同的图（我们自己两次之间 0.5631，SC-18）——所以任何关于混合程度的结论都不该建立在像素相似度上。

SC-18：两张 UMAP 不可跨运行复现（同一输入两次运行之间 0.5631 / 0.5676），所以本节比较的是嵌入与群组成，不是像素。

---

11. Part 8 —— scanpy

11.1 哪些活下来、哪些没有

cell 54-64 用 3.8 s 跑完，产出 5 张图。cell 67 里是那个双逗号（SC-09）。由于 Python 以整单元格编译，`SyntaxError` 抹掉了整个单元：PCA 从未计算，`neighbors()` 无法建图，`umap()` 无法运行，cell 70、72、75 连锁失败（`KeyError: 'No "neighbors" in .uns'`、`groupby has to be a valid observation`、`leiden is neither in .obs nor in .var`）。

这也解释了为什么课程参考图里没有 `pca_variance_ratio`：教师自己那一遍撞在同一堵墙上，被缩短的文件名清单也证明只产出了 5 张 scanpy 图。

11.2 Python 侧确实走到的数字

`filter_cells(200)` + `filter_genes(3)` 之后	2,700 × **13,714** 个基因
`n_genes < 2000 & pct_mt < 5` 之后	**2,635** 个细胞
HVG（`min_mean 0.0125, max_mean 3, min_disp 0.5`）	**1,833** 个
PCA	50 个主成分，`arpack`
近邻 / UMAP	10 / 40 个 PC

修正版把剩下的补完：分辨率 0.9 的 8 个 leiden 社区（534 / 643 / 340 / 497 / 432 / 142 / 35 / 12 个细胞）、`rank_genes_groups`（Wilcoxon）、点图，以及 `pbmc3k.h5ad`。

11.3 位置式命名是错的（SC-12）

按教材阈值，8 个名字正好对得上——其中两个落在了错的群上。证据来自 `rank_genes_groups` 与跨工具对账表（§ 12.2）：

scanpy 群	细胞数	分配的名字	主要 marker	Seurat 组成	判定
0	534	CD4 T	RPS12、RPS27、RPL32	70.6% Memory CD4 T、26.2% Naive CD4 T	可接受（确为 CD4 群）
1	643	**CD8 T**	LDHB、LTB、CD3D、IL32、TPT1	**78.1% Naive CD4 T**、18.2% Memory CD4 T	**错**（CD8A 0.14、CD8B 0.24）
2	340	B	CD74、CD79A、HLA-DRA	99.1% B	对
3	497	CD14+ Monocytes	LYZ、S100A9、S100A8	92.4% CD14+ Mono	对
4	432	NK	NKG7、CST7、GZMA、CTSW	**61.8% CD8 T**、33.3% NK	部分错
5	142	FCGR3A+ Monocytes	LST1、FCGR3A、FCER1G	97.2% FCGR3A+ Mono	对
6	35	Dendritic	HLA-DPA1、HLA-DPB1、HLA-DRA	77.1% DC	对
7	12	Platelet	PF4、PPBP、GNG11	100% Platelet	对

`rename_categories()` 按类别顺序（即”Louvain 先编号了哪个社区”）分配名字，与生物学无关。于是 8 个标签里有 2 个实质性错误，其中最大的一个（`CD8 T`，占 24%）正是终版 UMAP 里最大的群。

11.4 修正版怎么做

先断言类别数，再由 `rank_genes_groups` 的主要 marker 反推映射，打印审计表，最后才改名。按教材阈值会得到 8 个类别、改名照常进行；按对齐阈值（§12.3）会得到 9 个，修正版拒绝猜测，保留数字标签并写出 `cluster_label_audit_py.csv` 交给人判断。

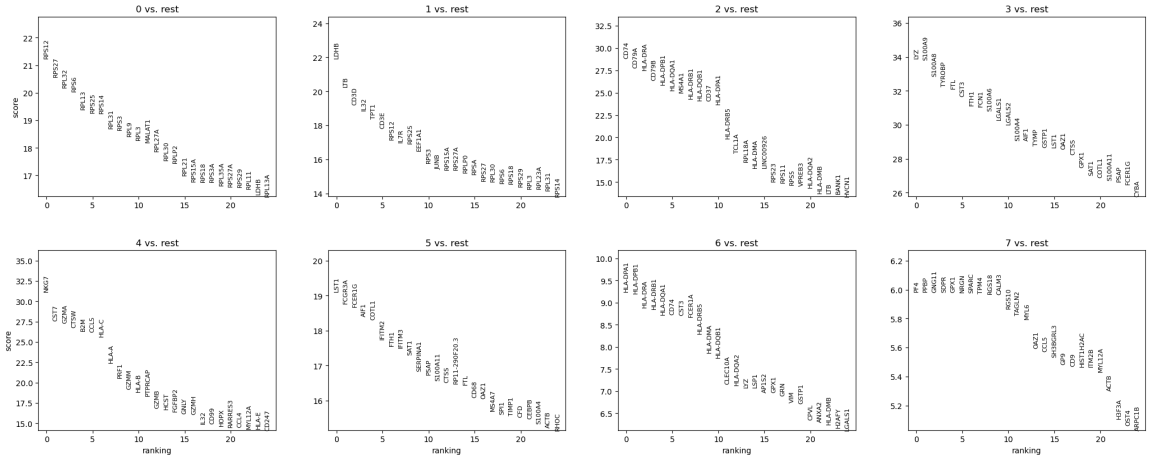


图 26 — `rank_genes_groups`（Wilcoxon）对 8 个 leiden 群、每群 25 个基因。

`FindAllMarkers` 的 Python 对应物，也是教材从不落盘的那张表（SC-13）。每一列是一个群、按得分排的头部基因；自上而下读每一列并问”这份清单连贯吗”——group 0 顶部是 RPS12/RPS27/RPL32，说明这一群很大程度由核糖体含量定义，那是技术轴而非细胞类型。这张图让位置式命名 bug（SC-12）变得可见：group 1 的头部基因（LDHB、LTB、CD3D、IL32、TPT1）是 CD4 T 的基因，而教材把 group 1 命名为 `CD8 T`。

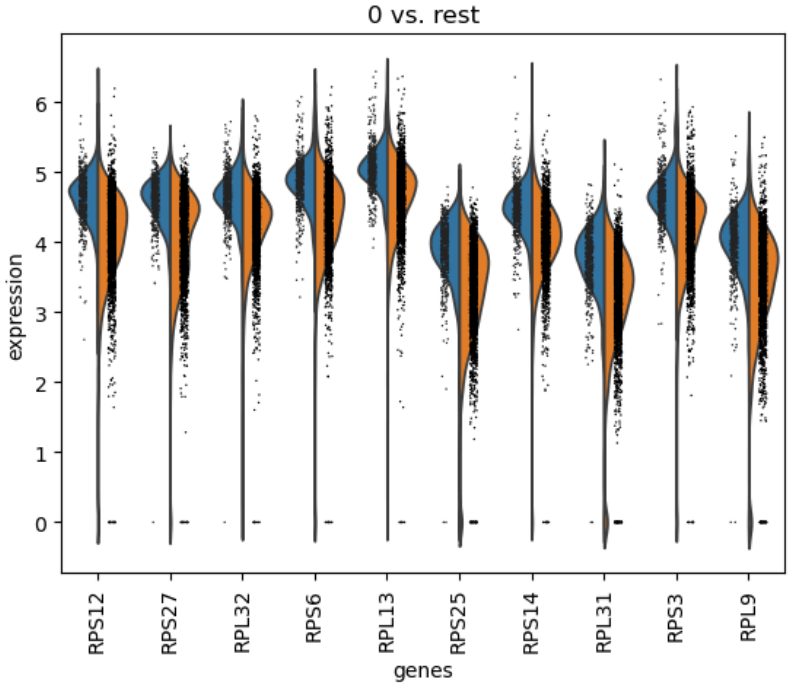


图 27 — `rank_genes_groups_violin`（group 0）：它的前十个基因在各群中的表达分布。

小提琴图回答了排名清单回答不了的问题：这个"marker"是特异的，还是只是更高一点？如果某基因在所有群里都整体右移且长尾，那是类管家式的差异；如果它在某一群里是单个紧峰、在别处贴着地板，那才是真 marker。用这一格去核对图 26 的第一列，再决定是否相信据此推出的标签。

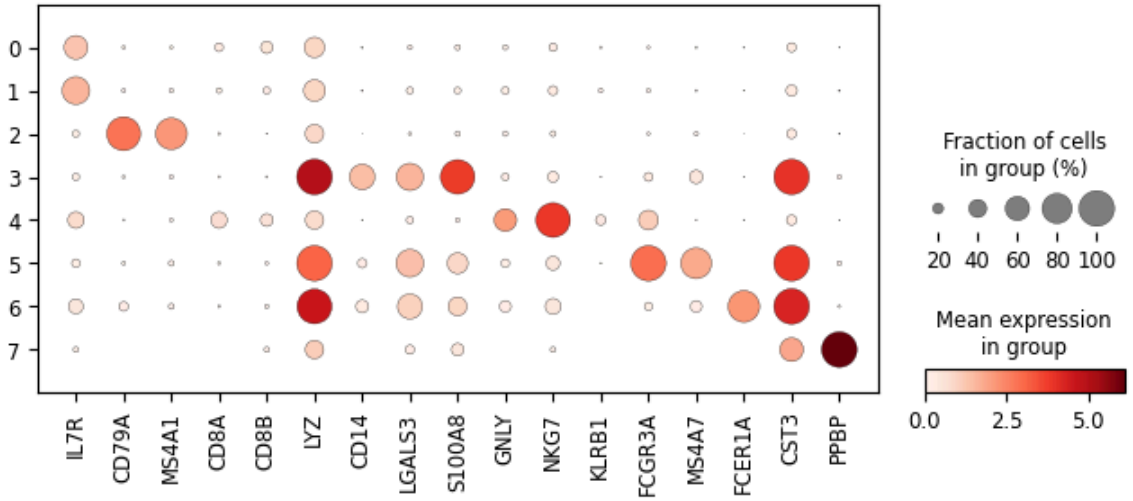


图 28 — `dotplot`：17 个经典 marker × 8 个 leiden 群。颜色 = 平均表达，大小 = 表达细胞比例。

这是 Python 侧信息量最大的注释图，也是教材八个名字里有两个可以当场核对的地方。`CD8 T` 这一列是明确的失败：CD8A/CD8B 只在少量细胞里出现且均值低，而 IL7R 很亮——这是 CD4 的谱型，不是 CD8。`NK` 这一列属于更微妙的情形：它**确实**高水平带着 NKG7/GNLY/GZMB，所以按 marker 叫 NK 说得过去；但它同时表达 CD3E、CD8A、CD8B，而跨工具对账表（§ 12.2）显示这一群里有 61.8% 的细胞是 Seurat 的 CD8 T——一个 NK/CD8 细胞毒混合群，诚实的标签应该是「NK/CD8 细胞毒」而不是任何一个单一名字。**正确**标签的视觉签名是「只出现在一列里」：小而深的点（均值高、细胞少）或大而浅的点（均值中等、细胞多）。两列对同一批 marker 都有响应，就是聚类把两个群体合并了的信号。

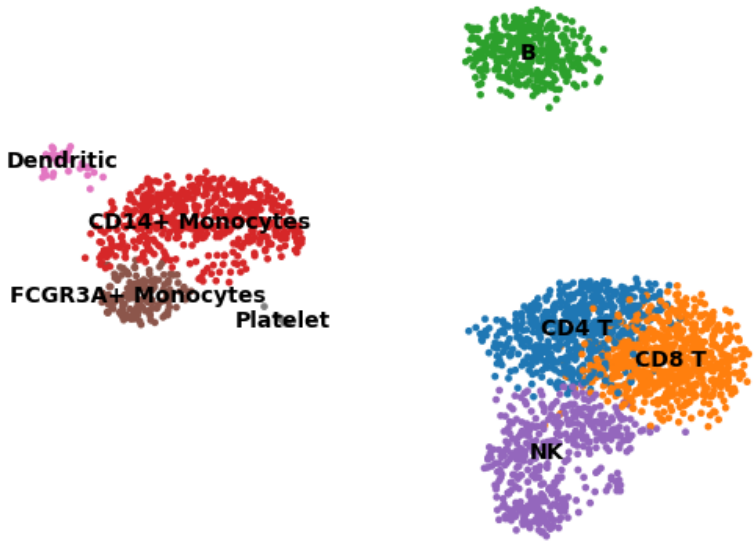


图 29 — scanpy 的最终 UMAP，把教材那八个标签画在数据上。

把它与图 19 并排，两个方法的分歧就从抽象变具体了：这里 T 叶是一个 `CD4 T` 群加一个其实属于 CD4 的 `CD8 T` 群，NK 被折进 CD8，血小板是 12 个细胞的孤岛。这张图内部自洽、而在两个位置生物学上错误——这正是 `results/04_annotation/` 里那些审计表存在的理由。

---

12. 两套工具链对账

12.1 “9 群 vs 8 群”之谜

	Seurat	scanpy（教材）	scanpy（对齐）
细胞数	2,638	2,635	**2,638**
基因数	32,738	13,714	13,714
HVG	2,000（vst）	1,833（离散度）	1,838
使用的主成分	10	40	40
分辨率	0.5（Louvain）	0.9（leiden）	0.9（leiden）
群数	**9**	**8**	**9**

“R 出 9 群、Python 出 8 群”常被解释成”算法不同”。这不是全部：把 Python 侧阈值从 2,000 提到 2,500，得到**与 Seurat 完全相同的细胞数**（2,638）和 **9 个群**。群数主要由质控阈值决定，而不是 Louvain 与 leiden 的差别。

两个 9 群解在组成上仍然不同：Seurat 把 CD4 拆成 naive/memory 并把 NK 与 CD8 分开，而对齐后的 scanpy 解里有一个核糖体基因偏高的 CD4 群和一个合并的 CD8/NK 群。

12.2 跨工具列联表

两侧共享 barcode，可以直接交叉（两个对象共有 2,635 个细胞；`results/04_annotation/cluster_correspondence_counts.csv`）：

Seurat 标签	CD4 T	CD8 T	B	CD14+ Mono	NK	FCGR3A+ Mono	Dendritic	Platelet
Naive CD4 T	140	502	1	0	13	0	0	0
Memory CD4 T	377	117	1	0	8	0	0	0
CD14+ Mono	0	0	0	459	0	4	8	0
B	1	1	337	0	0	0	0	0
CD8 T	16	23	1	0	267	0	0	0
FCGR3A+ Mono	0	0	0	37	0	138	0	0
NK	0	0	0	0	144	0	0	0
DC	0	0	0	0	0	0	27	0
Platelet	0	0	0	1	0	0	0	12

列是教材命名后的 scanpy 群。B、单核、DC、血小板近乎对角，两个大的 T 腔室则完全错位：scanpy 的”CD8 T”列里 78% 是 Seurat 的 naive CD4 T。

12.3 哪些能比、哪些不能比

能比、且本模块比了：质控后细胞数、群数、按 marker 面板给出的群组成、marker 排名、DEG 数量、整合指标。

不能比：群的**编号**（两种方法各有自己的编号规则）、基因全集（HVG 之前 32,738 vs 13,714）、分辨率参数（0.5 Louvain 不等于 0.9 leiden——这里恰好给出 9 与 8，是巧合而非标定）。

让两侧真正对齐有两个开关：`CreateSeuratObject(min.cells = 3)`（13,714 个基因，但见 SC-17）与 scanpy 侧 `n_genes < 2500`（2,638 个细胞、9 个群）。两个都做，两侧就是 2,638 个细胞；本模块没有这么做，因为教材的图是按它自己的取值标定的，而且 SC-17 证明改动基因全集并不免费。

---

13. 修正版

13.1 改了什么，就只改了什么

`results/scripts/scRNA_seq_R_cells_corrected.R` 与 `..._py_cells_corrected.py` 就是教材原文，每处改动都标 `# --- FIX ... (SC-xx)`、每处新增都标 `# --- ADD ...`。真正影响产出的改动：

改动	效果
`library(ggrepel)`（SC-16）	DEG 单元跑通：火山图、DEG 表、`pbmc3k_final.rds`
比值图那一个逗号（SC-09）	PCA/近邻/UMAP 得以运行；生成 `scanpy_PCA_ratio.png`（参考图里没有这一张）
`pmax(p_val_adj, .Machine$double.xmin)`（SC-04）	火山图纵轴构造上有界
过滤后的 marker 表赋值（SC-03）	热图用 90 个显著基因，而不是”只看 log2FC 的前 10”
群数守卫 + 审计表（SC-02、SC-12）	映射由 marker 反推并打印；编号漂移变成警告，而不是静默错标
整合前质控 + harmony 显式 `dims` + 之后聚类（SC-06、SC-20）	25,711 个细胞、12 个群、混合度指标
`load()` 载入私有环境（SC-05）	不再污染全局环境
导出表格（SC-13）	10 个 CSV，教材只留在内存里

修正版 R 运行**精确复现**原样数字：2,638 个细胞、9 个群、11,986 行 marker、724 与 650 行 DEG、合并 25,894 个细胞、模块度 0.8584。两者共有的 13 张图里有 9 张**逐字节相同**（`results/08_figure_comparison/compare_`

aswritten_vs_corrected.tsv）；不同的 4 张是两处有意改动（VariableFeaturePlot 单联、Marker_Heatmap 加了显著性过滤）与 Part 7 的两张 UMAP（SC-18 的不可复现性）。

13.2 基因全集的对照实验（SC-17）

同一份修正脚本改用 MIN_CELLS=3（即 scanpy 的基因全集），细胞数不变，但：

	MIN_CELLS = 0（教材）	MIN_CELLS = 3
特征数	32,738	13,714
与另一设置共享的 HVG	—	2,000 个里的 1,970 个（98.5%）
Louvain 模块度	0.8584	0.8728
群大小	657/503/471/339/307/175/144/28/14	684/481/476/344/291/162/155/32/13
marker 行数	11,986	11,629
naive-CD4 DEG 行数	724	733
memory-vs-naive DEG 行数	650	887
最终标签	正确	**cluster 1 与 2 互换**

最后一行是关键。MIN_CELLS = 3 时 Louvain 把单核社区编号为 1、memory-CD4 编号为 2；教材那个固定 new.cluster.ids 于是把 “Memory CD4 T” 贴到 CD14 1.51 / LYZ 5.07 / IL7R 0.19 的群上，把 “CD14+ Mono” 贴到 CD14 0.03 / IL7R 1.69 的群上——**957 个细胞（占 36%）标签错误，而所有图看起来都正常**。只有审计表能抓到这件事。

13.3 修正版 Python 补了什么

细胞数 / 基因数	2,635 / 13,714（教材阈值）；2,638（对齐阈值，附录）
HVG	1,833 / 1,838
群数	8（教材阈值）/ 9（对齐阈值）
出图	12 张（参考集的 11 张 + pca_variance_ratio）
表格	8 个 clusterN_markers.csv、cluster_label_audit_py.csv、pbmc3k_obs.csv
对象	pbmc3k.h5ad（2,635 个细胞，19.5 MiB，gzip）

13.4 有意不做的修正

- **不给 Louvain/UMAP/harmony 设种子。**教材没有种子、参考图也没有，设种子只会让我们的图更难对齐。
- **不统一分辨率。**0.5 Louvain 与 0.9 leiden 就是教材的取值；把它们”等价化”既不可能，也会掩盖 §12 的结论。
- **不安装 presto。**FindAllMarkers() 无 presto 要 330 s；装上能降到秒级，但会改变 Seurat 的数值路径，因此这里记录代价而不改变计算。
- **不改写交付的 Seurat 对象标签。**它的标签是对的（§9.1），改写只会破坏与参考图的可比性。

---

14. 教材范围之外的参考图

28 张参考 PNG 里有 3 张不是教材任何代码的产物，因此本模块没有尝试重画：

- UMAP_noPCA.png 与 UMAP_PCA_vs_noPCA.png——教师 2025 幻灯片里”有没有 PCA”的对比；
- UMAP_three_stages.png——讲义里用来说明流程三阶段的三联示意图；
- immune_markers.png——CST 免疫 marker 速查表，属于外部参考图，不是分析产物。

教师 2025 目录里还有 HIV/EBV 病毒定量素材（virus_star_ref/、ebv.fasta、HIV.fasta、virus.fa/gtf）。教材完全未涉及，故不在本模块范围。

另有一处不一致只记录、不修正：参考图 `Marker_Heatmap.png` 是 3,000 × 6,000 px，而教材 `ggsave()` 要求 10 × 10 英寸、300 dpi，只能得到 3,000 × 3,000（SC-19）。

---

15. 复现本模块

```
# 0. 环境（教师共享环境，无需新建）
source /lustre1/share/miniconda3/etc/profile.d/conda.sh
E=/lustre1/share/miniconda3/envs/scRNA_seq

# 1. 按教材 cell 7 的指令准备数据
RUN=/lustre1/user/$USER/scrna_run
mkdir -p $RUN/{rr,py,logs,scripts}
rsync -r /lustre1/share/scRNA_seq/hg19 $RUN/
rsync /lustre1/share/qinbowen/pbmc_stim.RData $RUN/

# 2. 原样运行（25 张图里的 18 张，两个单元致命）
cp results/scripts/*.R results/scripts/*.py $RUN/scripts/
cd $RUN/rr && $E/bin/Rscript $RUN/scripts/run_cells.R \
    $RUN/scripts/scRNA_seq_R_cells_aswritten.R $RUN/logs R_aswritten
cd $RUN/py && MPLBACKEND=Agg $E/bin/python $RUN/scripts/run_cells.py \
    $RUN/scripts/scRNA_seq_py_cells_aswritten.py $RUN/logs Py_aswritten

# 3. 修正运行（25/25 张图 + 两个对象）
mkdir -p $RUN/rr_fixed && cd $RUN/rr_fixed && MIN_CELLS=0 $E/bin/Rscript \
    $RUN/scripts/run_cells.R $RUN/scripts/scRNA_seq_R_cells_corrected.R $RUN/logs R_corrected
mkdir -p $RUN/py_fixed && cd $RUN/py_fixed && N_GENES_MAX=2000 MPLBACKEND=Agg \
    $E/bin/python $RUN/scripts/run_cells.py \
    $RUN/scripts/scRNA_seq_py_cells_corrected.py $RUN/logs Py_corrected

# 4. 附录运行（基因全集与阈值对齐）
mkdir -p $RUN/rr_mincells3 && cd $RUN/rr_mincells3 && MIN_CELLS=3 $E/bin/Rscript \
    $RUN/scripts/run_cells.R $RUN/scripts/scRNA_seq_R_cells_corrected.R $RUN/logs R_mincells3
mkdir -p $RUN/py_align2500 && cd $RUN/py_align2500 && N_GENES_MAX=2500 MPLBACKEND=Agg \
    $E/bin/python $RUN/scripts/run_cells.py \
    $RUN/scripts/scRNA_seq_py_cells_corrected.py $RUN/logs Py_align2500

# 5. 表格与图像比对
cd $RUN && $E/bin/Rscript scripts/table_qc_clusters.R $RUN ../class/scRNA-seq/results
$E/bin/python scripts/compare_figs.py $RUN ../class/scRNA-seq \
    results/08_figure_comparison/compare_corrected_vs_reference.tsv rr_fixed py_fixed
```

教材自己的占位符（`data_dir <- "yourfolder/hg19"`、`load("pbmc_stim.RData")`、`read_10x_mtx("yourfolder/hg19")`）是原样版单元文件里唯一的改动，每个文件头部都用 `#@@NOTE` 标注。其余部分逐字照抄，包括那个双逗号。

---

16. 文件清单

路径	内容
`ref/scRNA_seq_analyze_corrected.md`	本文档（英文）
`ref/scRNA_seq_analyze_corrected_zh.md`	中文版
`ref/scRNA_seq_analyze_results_guide.md`	`results/` 导读 + 练习
`results/scripts/scRNA_seq_R_cells_aswritten.R`	教材 R 单元，除两处路径外逐字照抄
`results/scripts/scRNA_seq_py_cells_aswritten.py`	教材 Python 单元，逐字照抄（含 `SyntaxError`）
`results/scripts/scRNA_seq_R_cells_corrected.R`	修正版 R 单元，每处改动有标注

路径	内容
`results/scripts/scRNA_seq_py_cells_corrected.py`	修正版 Python 单元，每处改动有标注
`results/scripts/run_cells.R、run_cells.py`	notebook 语义驱动器（单会话、逐单元状态）
`results/scripts/table_qc_clusters.R`	质控账目与群大小表
`results/scripts/marker_panel_audit.{R,py}`	两侧的 marker 面板逐群均值
`results/scripts/annotation_audit.R`	两份硬编码映射 vs 观测程序
`results/scripts/cluster_correspondence.{R,py}`	跨工具列联表
`results/scripts/compare_figs.py`	与 28 张参考图的图像比对
`results/09_run_logs/*_cell_log.txt`	逐单元的代码、标准输出、警告、报错、对象状态
`results/09_run_logs/*_cell_summary.tsv`	每个单元一行：状态、秒数、警告/报错数
`results/08_figure_comparison/*.tsv`	三张机器可读比对表
`results/08_figure_comparison/figure_comparison.md`	同一批数据的书面比对与解读
`results/07_objects/pbmc3k.h5ad`	Part 8 的交付对象（19.5 MiB）
`results/07_objects/pbmc3k_obs.csv`	逐细胞元数据：分群、质控指标