TBCR 组库分析结果讲解

Contents

TBCR 分析结果讲解 1
1. 怎么读这个目录 1
2. 逐类导读 1
3. 手把手练习 10
4. 一句话总结 12

TBCR 分析结果讲解

本文件导读 `TBCR-analysis/results/` 下的全部产物，并给出可以亲手复现的练习。配套的矫正增强版文档在 `ref/TBCR_analysis_corrected.md`（英文）与 `ref/TBCR_analysis_corrected_zh.md`（中文）。

1. 怎么读这个目录

```
results/
├── 01_clonotype/   Part 1 原样产出：BCR consensus assembly 频率直方图
├── 02_gene_usage/  Part 2 原样产出：IGHV / IGHJ top10 柱状图、V-J 热图
├── 03_cdr3_length/ Part 3 原样产出：CDR3 核苷酸 / 氨基酸长度分布
├── 04_diversity/   Part 4 原样产出：375 样本多样性 CSV + 三张相关图
└── 05_corrected/   修正版产出：同四项指标在 L1/L2 过滤下的结果 + 对拍图
```

每个步骤目录里都有 `scripts/`（教材原文代码，文件头登记偏差）与 `log_*.txt`（完整运行日志，含 `[diag]` 诊断行）。所有脚本都会 `setwd()` 到自己的目录，所以直接 `Rscript scripts/xxx.R` 即可重跑。

2. 逐类导读

2.1 `01_clonotype/`

- `BCR_consensus_frequency_distribution.png`：横轴是某个 consensus assembly 在样本里出现的次数（`Freq`），纵轴是有多少个 assembly 具有该次数。演示样本 745 个 BCR assembly 中 659 个只出现一次，最高的一个出现 18 次——长尾单例为主、少数扩增克隆。
- 读这张图要记住：`Freq` 是**行数**（报告条目数），不是读段数；若要按读段加权，用 `cdr3.out` 的 `read_fragment_count` 列。

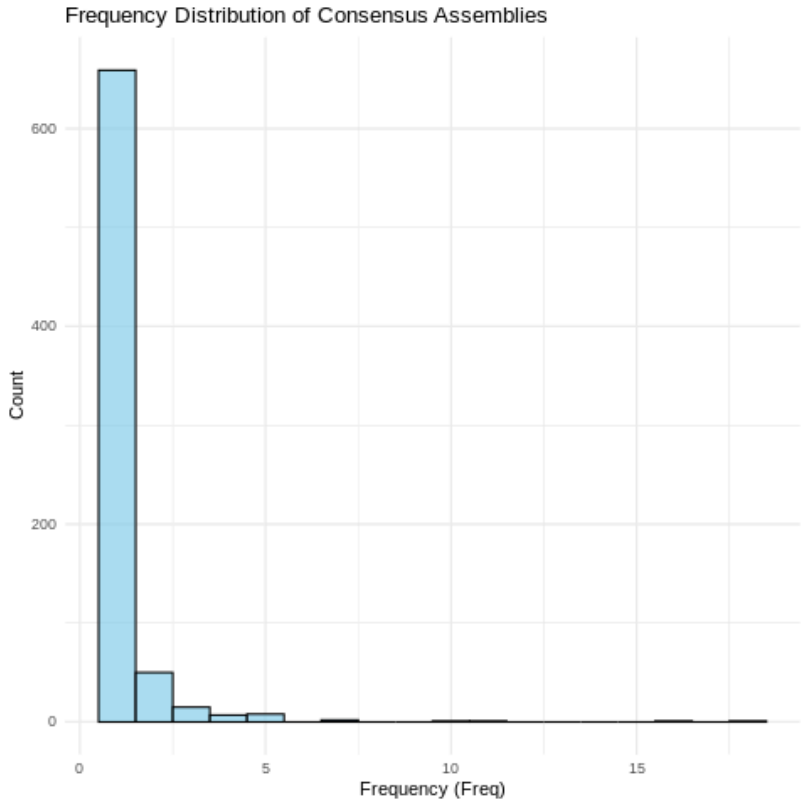


图 1 — `BCR_consensus_frequency_distribution.png`：consensus assembly 的出现次数分布。

看两件事：单例柱有多高（745 个 BCR assembly 里 659 个只出现一次——库以单例为主，是正常的长尾），以及尾巴伸到多远（最高 18 次——少数扩增克隆）。如果第一根柱子之外几乎是空的，那更像”没扩增”而不是”数据干净”；如果尾巴在 50 次以上，要考虑是不是肿瘤内一个优势克隆被过度组装。

2.2 `02_gene_usage/`

- `top10_IGHV_genes.png`：IGHV 使用率前 10。演示样本首位 `IGHV3-15*01`，占 IGH 读段 0.1560。
- `top10_IGHJ_genes.png`：IGHJ 使用率前 10。首位 `IGHJ5*02`，占 0.3551。
- `heatmap_VJ.png`：V（横）× J（纵）配对计数热图，颜色越深读段越多。173 个不同配对，最强的是 `IGHV3-15*01` + `IGHJ5*02`（288 读段，占 0.1362）。
- 注意热图里会出现 `*` 行/列：那是”未检出 D/J”的占位符，不是一个基因（详见矫正文档 TBCR-07）。修正版已剔除。

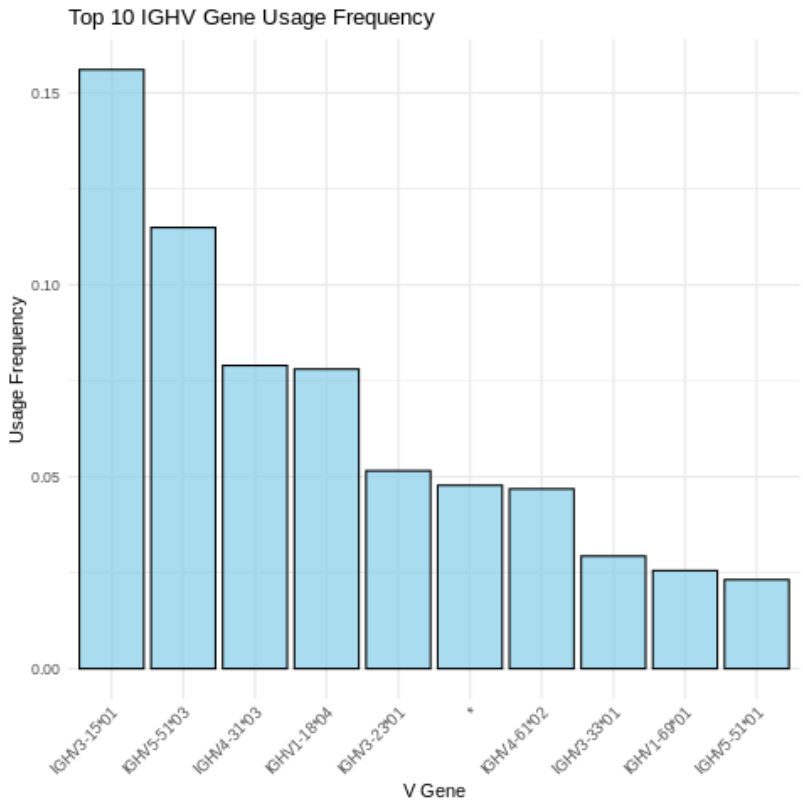


图 2 — `top10_IGHV_genes.png` 与 `top10_IGHJ_genes.png`：重链 V 与 J 的使用率前 10。

V 侧榜首先 `IGHV3-15*01`（0.1560），J 侧 `IGHJ5*02` 一条就占 0.3551——J 的集中度远高于 V，原因是 V 有约 80 个等位在用、J 只有约 12 个。两张图都按**等位**出图，所以”前 10”是等位级而非基因级。

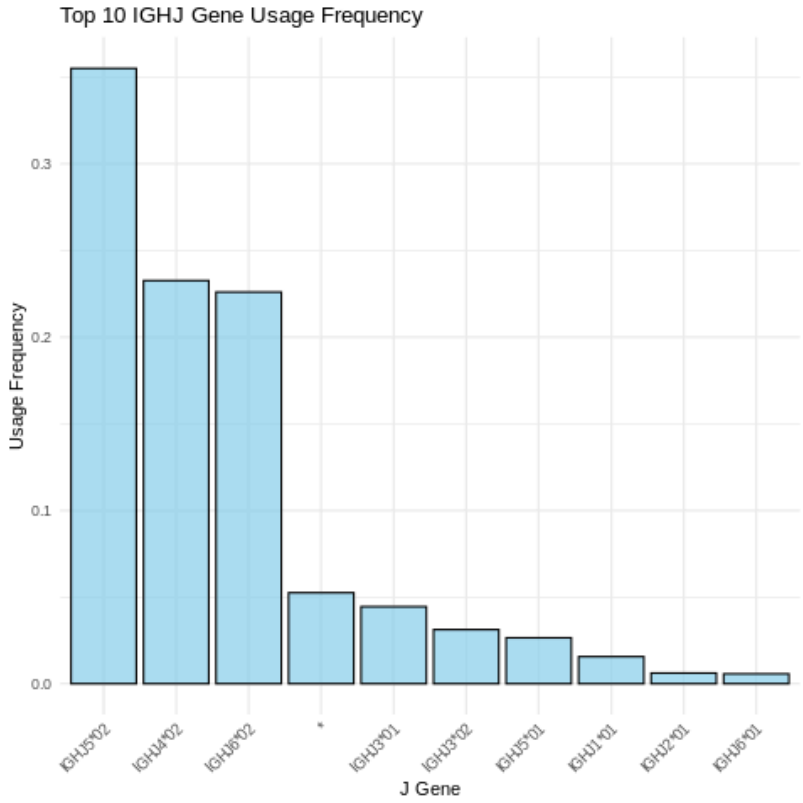


图 3 — `top10_IGHJ_genes.png`。

对照图 2 一起读：V 的前三名加起来约 35%，而 J 的前三名加起来 81%。这也解释了为什么 J 的柱状图信息量有限（就是六个数字的排名），而 V-J 配对热图才值得看。

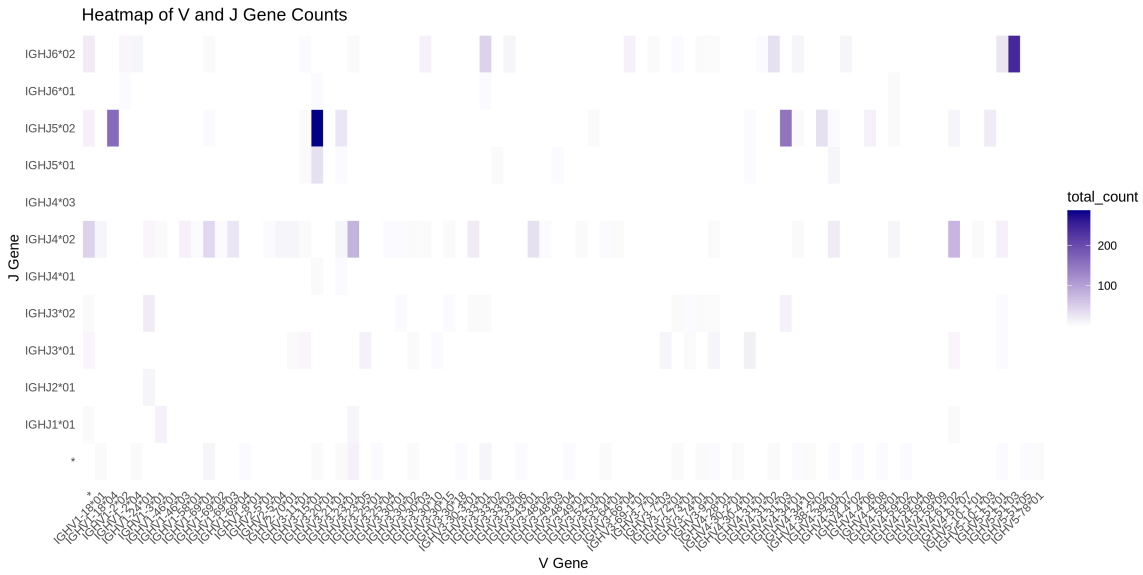


图 4 — `heatmap_VJ.png`：V（横）× J（纵）配对计数。

最强的格子是 IGHV3-15*01 + IGHJ5*02（288 读段，占 IGH 质量的 0.1362）。但这张图同时是本模块”技术上对、实际上读不动”的例子：80 个等位级的 V 标签斜排后叠成灰带，173 个配对填不满 12×80 个格子，* 那一行一列还摆在坐标轴上。想让它可用，把等位折叠到基因层、去掉 *，再画。

2.3 03_cdr3_length/

- CDR3_nt_length_distribution.png / CDR3_aa_length_distribution.png：按读段数加权的长度分布。演示样本众数 66 nt / 22 aa（各 477 读段）。
- 核苷酸长度图上会出现两根不在 3 倍数上的孤立柱（46 与 71 nt）：那是 out_of_frame 序列，教材的 != "partial" 过滤没拦住它们（TBCR-03）。修正版的 corrected_CDR3_nt_length_distribution.png 里这两根柱消失。

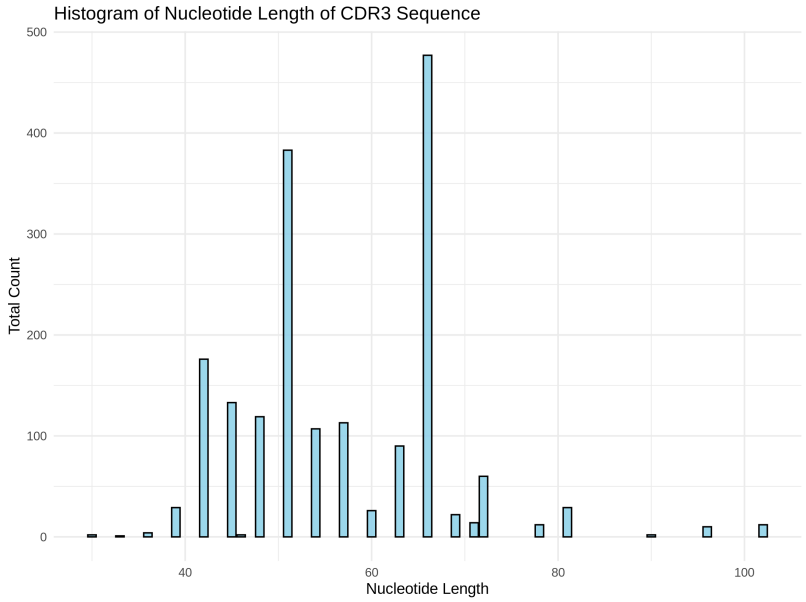


图 5 — CDR3_nt_length_distribution.png：按读段加权的核苷酸长度分布。

钟形在众数 66 nt 附近（477 读段），范围 30-102。要在图上找的是**不在 3 倍数上的孤立柱**：46 nt 与 71 nt 那两根，就是没被 != "partial" 拦住的 out_of_frame 序列。它们的读段数不高，所以不影响众数，但会让”长度分布是否合规”这个判断题变成错的。

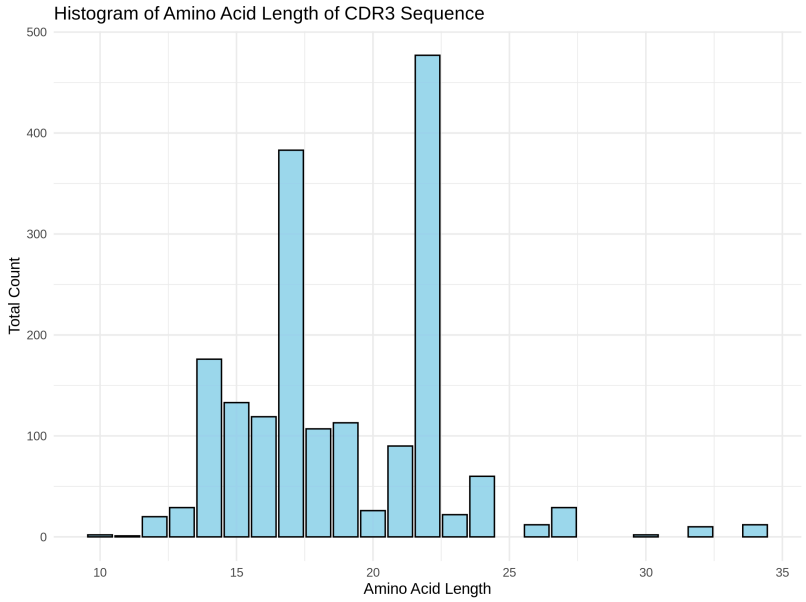


图 6 — `CDR3_aa_length_distribution.png`：氨基酸长度分布。

从另一侧暴露同样的问题：`nchar()` 把插补序列里的 `?/_` 当残基计数，八个序列因此各长了一两位。生物学上 10-34 aa、众数 22 aa 是人 BCR CDR3 的经典环长。把这张图和”过滤决定”一起看——图本身分不清尾巴是生物学还是记账。

2.4 `04_diversity/`

- `OV_bcr_diversity.csv`：375 个 TCGA-OV 样本 × 5 个指数（`diversity`、`CPK`、`entropy`、`clonality`、`gini`），第一列是样本名（去掉 `_report.tsv` 后缀）。`TCGA-23-1113` 的 `clonality` 是 `NA`——该样本只有 1 条 IGH 行，公式在此处 0/0。
- `diveristy_cor_entropy.png`（文件名拼写照教材保留）：diversity 对 entropy，Spearman rho 0.7957。
- `CPK_cor_entropy.png`：CPK 对 entropy，rho −0.2470。
- `CPK_cor_clonality.png`：CPK 对 clonality，rho -0.8790（预期中的强负相关）。
- 三张图里都会看到一条提示”Removed 1 rows containing non-finite values”——就是那个 `NaN` 样本，属预期。

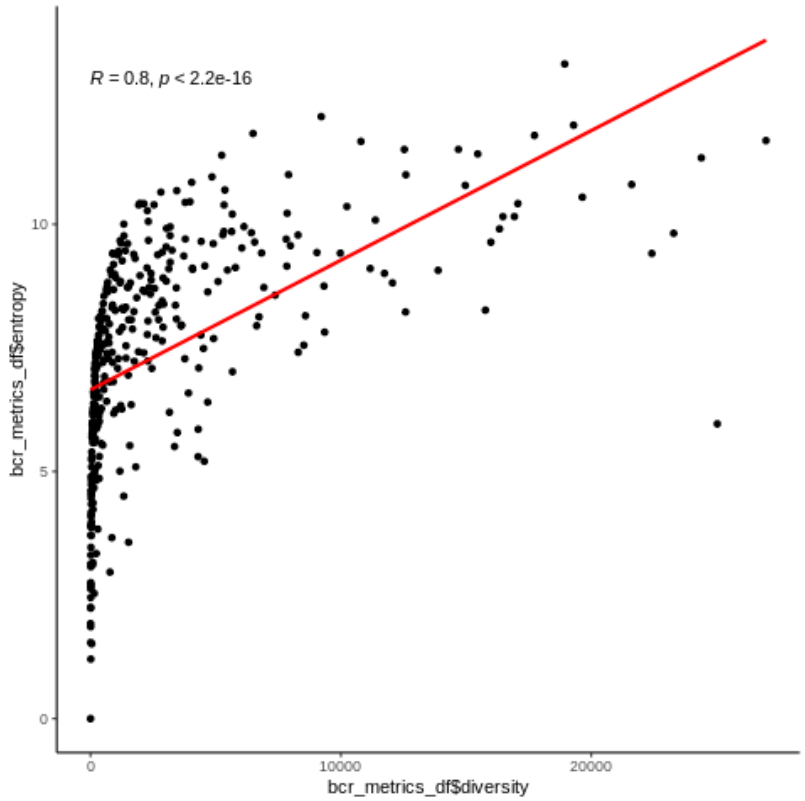


图 7 — `diveristy_cor_entropy.png`：diversity 对 entropy（rho 0.7957）。

两者都量丰富度，所以紧密单调是必然的、属于一致性检查。真正有信息的是线下的散点：落在下方的样本 singleton 多（丰富度高、均匀度低），通常意味着库由低支持度序列拼成。

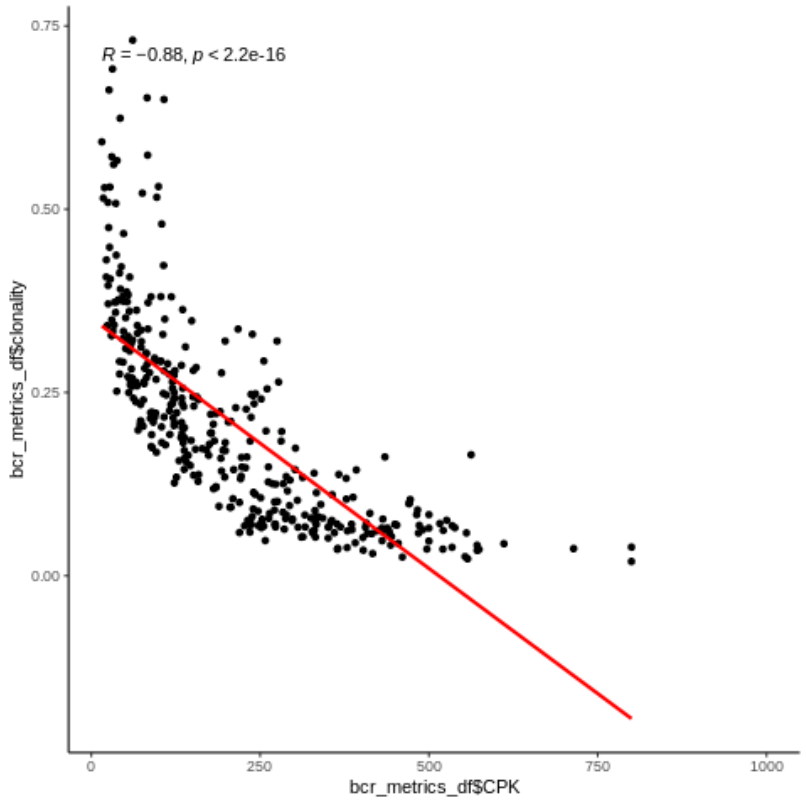


图 8 — `CPK_cor_entropy.png`（rho −0.2470）与 `CPK_cor_clonality.png`（rho −0.8790）。

两图对照着看最清楚：CPK 与熵几乎无关，而 CPK 与 clonality 强负相关。原因是 CPK 按读段归一、熵按克隆频率归一——同一个 CPK 值可以是”测得深但均匀”，也可以是”测得浅但克隆化”。注意右端红色拟合线外推到**零以下**，而 `1 − H/log(n)` 不可能为负：线性模型描述趋势可以，预测单点不行。

2.5 `05_corrected/`

- `corrected_summary.txt`：修正版全部关键数字的纯文本汇总，写文档时直接引用它。
- `OV_bcr_diversity_corrected.csv`：逐样本同时给出 raw / L1 / L2 三套指标，外加 `rows_IGH`、`reads`、`n_partial`、`n_oof`、`n_imputed`、`n_valid` 六个审计列。想核对任何差异，从这张表开始。
- `OV_trb_diversity_corrected.csv`：TCR beta 链的同一套指标（教材只做 BCR 重链，这是扩展）。
- `raw_vs_corrected_diversity.png`：raw 对 L1 的 diversity 散点（双对数），虚线是 y = x；点整体落在虚线下方，说明 raw 系统性高估，但斜率接近 1，说明排序基本不变。
- 三张 `corrected_*_cor_*.png`：修正后的相关图（entropy 用 nat，与公式一致）。
- 两张 `corrected_CDR3_*_length_distribution.png`：L2 过滤后的长度分布（无非 3 倍数柱）。
- 两张 `corrected_top10_IGH*.png`：剔除 * 后的使用率前 10。

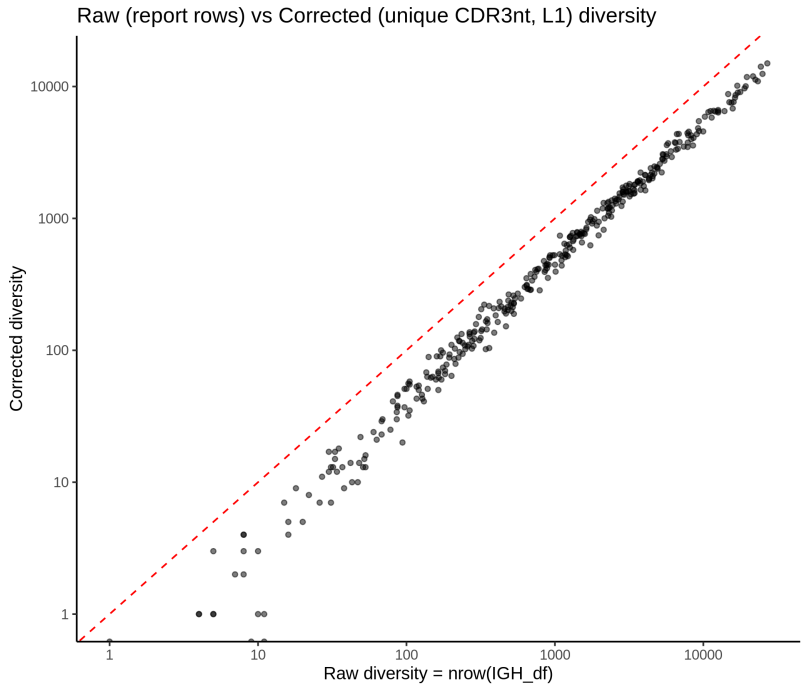


图 9 — `raw_vs_corrected_diversity.png`：raw 对 L1 diversity，双对数，虚线 y = x。

本模块最重要的一张图：375 个点**全部**在等值线下方，说明 raw 是系统性偏高的计数（TRUST 会把一个 CDR3 按 V 等位/恒定区拆成多行）。偏差在低多样性处比例最大（约 2 倍），高多样性处压到约 1.2 倍——恰好扭曲了”下克隆性结论”的那批样本。贴着底边（修正值 = 1）的点就是折叠后只剩一个克隆、clonality 未定义的那几个。

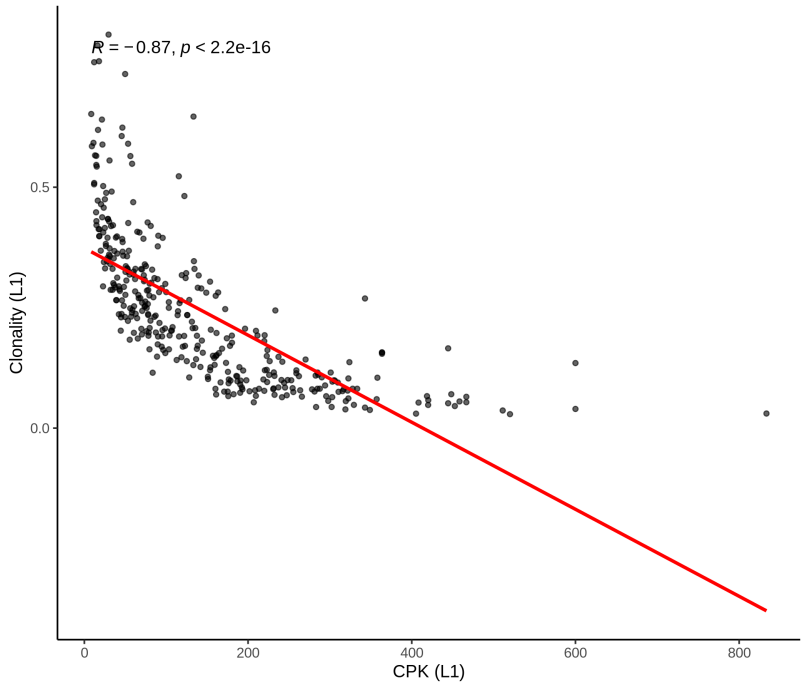


图 10 — `corrected_CPK_cor_clonality.png`：修正后 CPK 对 clonality（rho −0.8729）。

与图 8 相比：相关几乎没变，但云团上移了（clonality 中位 0.1843 → 0.2196）——去掉重复行后每个样本看起来更克隆化，因为折叠把质量集中了。这就是”尺度修正”的典型样子：绝对数变、排序基本不变。

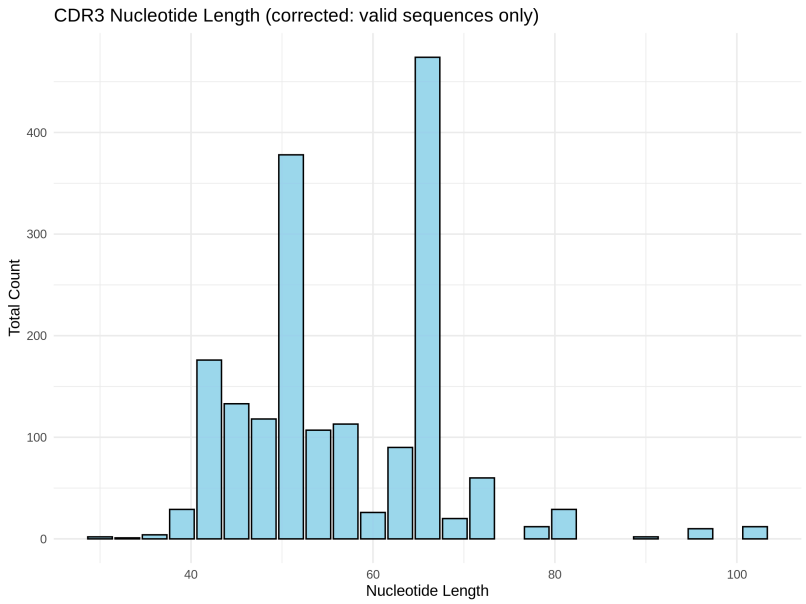


图 11 — `corrected_CDR3_nt_length_distribution.png`：L2 过滤后的长度分布。

不可能的柱子消失，众数仍是 66 nt / 474 读段，范围仍是 30-102 nt——说明修正恰好只去掉了两个 `out_of_frame` 行。判断一个过滤”是否只做了它声称的事”，就该这么看：钟形不动、异常消失。

3. 手把手练习

练习 1 —— 复现”表头行靠注释符跳过”这件事

```
cd /gpfs1/home/bjx131_pkuhpc/class/TBCR-analysis/results
source /lustre1/share/miniconda3/etc/profile.d/conda.sh && conda activate airr
Rscript -e '
f <- "/lustre1/share/airr/data/TRUST_output/TCGA-02-0055-01A-01R-1849-01_report.tsv"
a <- read.table(f, sep="\t")                          # 默认 comment.char="#"
b <- read.table(f, sep="\t", comment.char="")         # 关掉注释
cat("默认:", nrow(a), "行；关注释:", nrow(b), "行\n")
cat("关注释后首行 count =", as.character(b$V1[1]), "\n")'
```

预期：默认 930 行，关注释 931 行，首行 `count` 是 `#count`。这就是 TBCR-01。

练习 2 —— 亲手验证 diversity 的两种口径

```
Rscript -e '
suppressMessages(library(dplyr))
a <- read.table("/lustre1/share/airr/data/TRUST_output/TCGA-02-0055-01A-01R-1849-01_report.tsv",
sep="\t")
colnames(a) <- c("count","frequency","CDR3nt","CDR3aa","V","D","J","C")
ig <- a %>% filter(grepl("^IGHV",V)|grepl("^IGHD",D)|grepl("^IGHJ",J)|grepl("^IGHC",C))
cat("nrow(IGH)          =", nrow(ig), "\n")
cat("唯一 CDR3nt        =", length(unique(ig$CDR3nt)), "\n")
cat("唯一 CDR3aa        =", length(unique(ig$CDR3aa)), "\n")
cat("partial 行         =", sum(ig$CDR3aa=="partial"), "\n")
cat("out_of_frame 行    =", sum(ig$CDR3aa=="out_of_frame"), "\n")
cat("含 ?/_ 插补行      =", sum(grepl("[?_]", ig$CDR3aa)), "\n")
cat("保持 3 倍数?       =", all(nchar(ig$CDR3nt[ig$CDR3aa!="partial"]) %% 3 == 0), "\n")'
```

预期：354 / 345 / 173 / 169 / 2 / 8 / FALSE。最后一行 FALSE 正是 TBCR-03：`!= "partial"` 之后仍有非 3 倍数序列。

练习 3 —— 从 CSV 里找出所有未定义样本

```
cd /gpfs1/home/bjx131_pkuhpc/class/TBCR-analysis/results/05_corrected
Rscript -e '
m <- read.csv("OV_bcr_diversity_corrected.csv")
cat("样本数:", nrow(m), "\n")
cat("L1 clonality 为 NA:", sum(is.na(m$L1_clonality)), "\n")
cat("无有效克隆(L1 diversity==0):", sum(m$L1_diversity==0), "\n")
print(m[is.na(m$L1_clonality),
c("sample","rows_IGH","n_partial","n_oof","n_imputed","n_valid","L1_diversity")])'
```

预期：375 样本、9 个 NA、3 个零有效克隆，名单与文档 §7.4 一致。

练习 4 —— 量化 raw 与修正版的关系

```
Rscript -e '
m <- read.csv("OV_bcr_diversity_corrected.csv")
cat("diversity  spearman =", round(cor(m$raw_diversity, m$L1_diversity, method="spearman"),4),
"\n")
cat("L1/raw 中位比       =", round(median(m$L1_diversity/m$raw_diversity, na.rm=TRUE),4), "\n")
cat("clonality spearman  =", round(cor(m$raw_clonality, m$L1_clonality, method="spearman",
use="complete.obs"),4), "\n")'
```

预期：0.9975 / 0.484 / 0.969。解读：绝对值缩了一半，排序几乎不变——这是本文档最重要的结论。

练习 5 —— 看 * 占位符如何进入使用率表

```
Rscript -e '
suppressMessages(library(dplyr))
a <- read.table("/lustre1/share/airr/data/TRUST_output/TCGA-02-0055-01A-01R-1849-01_report.tsv",
sep="\t")
colnames(a) <- c("count","frequency","CDR3nt","CDR3aa","V","D","J","C")
ig <- a %>% filter(grepl("^IGHV",V)|grepl("^IGHD",D)|grepl("^IGHJ",J)|grepl("^IGHC",C))
u <- ig %>% group_by(J) %>% summarise(n=sum(count)) %>% mutate(f=n/sum(n)) %>% arrange(desc(f))
print(as.data.frame(u))'
```

预期：* 排第四（111 读段，占 0.0525；前三是 751 / 492 / 478），证明它不是基因却被当作基因计数。剔除后前三名不变。

练习 6 —— 复核训练集的长度分布众数

```
Rscript -e '
m <- read.table("/lustre1/share/airr/data/TRUST_output/TCGA-02-0055-01A-01R-1849-01_report.tsv",
sep="\t")
colnames(m) <- c("count","frequency","CDR3nt","CDR3aa","V","D","J","C")
ig <- m[grepl("^IGHV",m$V)|grepl("^IGHD",m$D)|grepl("^IGHJ",m$J)|grepl("^IGHC",m$C),]
ig <- ig[grepl("^[ACDEFGHIKLMNPQRSTVWY]+$", ig$CDR3aa),]
nt <- nchar(ig$CDR3nt)
cat("L2 行数:", nrow(ig), " 众数 nt:", as.integer(names(which.max(table(nt)))), "\n")
cat("全部 3 的倍数:", all(nt %% 3 == 0), "\n")'
```

预期：175 行、众数 66、全部为 3 的倍数。与修正版 `corrected_summary.txt` 的 “L2 rows: 175 / nt mode: 66” 对上。

练习 7 —— 用 TRB 扩展数据看 TCR 侧

```
cd /gpfs1/home/bjx131_pkuhpc/class/TBCR-analysis/results/05_corrected
Rscript -e '
t <- read.csv("OV_trb_diversity_corrected.csv")
cat("有有效 TRB 克隆的样本:", sum(t$diversity>0), "/", nrow(t), "\n")
```

```
cat("TRB diversity 中位数(非零):", median(t$diversity[t$diversity>0]), "\n")
cat("TRB diversity 范围:", range(t$diversity), "\n")'
```

预期：369/375、38、0-529。

4. 一句话总结

第四节课用约一分钟的纯 R 分析，把 TRUST3 的组装产物变成克隆型频率、基因使用、CDR3 长度和五个多样性指数；教材的薄弱点不在命令而在定义——`nrow()` 冒充唯一 CDR3、`partial` 黑名单漏掉 `out_of_frame`、队列循环跳过质量过滤——修正后多样性中位数从 918 降到 446，而样本排序保持（Spearman 0.9975），因此相对比较可信、绝对数值不可直接引用。