WES 结果讲解

两轮实跑产物的逐文件导读——怎么看、为什么是这些数、动手验证

目录

关于本指南 · About this guide 1
目录结构 · What is where 1
逐类讲解 · How to read each artifact 2
1. fastp 报告（0_fastq/，步骤 2） 2
2. flagstat（1_alignment/*flagstat.txt，步骤 3.4） 2
3. MarkDuplicates 指标（1_alignment/*markdup_metrics.txt，步骤 4） 3
4. BQSR recal 表（1_alignment/*.recal_data.table，步骤 5） 3
5. 胚系变异集 VCF（2_variant_call/，步骤 6–7） 3
6. VQSR recal + tranches（2_variant_call/*.recal、*.tranches，步骤 7） 4
7. ANNOVAR 输出（3_annotation/，步骤 8） 4
8. 体细胞 VCF（5_somatic_tmb/，步骤 9） 4
9. CNVkit 输出（4_cnv/，步骤 10） 4
10. HsMetrics（full/qc/*.hs_metrics.txt，矫正补充步骤） 7
11. 日志与脚本（log/、scripts/） 7
两轮对比总表 · The two rounds at a glance 8
未入库的大文件 · What stayed on the cluster 8
动手练习 · Exercises you can do right here 8

关于本指南 · About this guide

本目录收录的是**我们自己的两轮实跑分析结果**（demo 轮 + 全量轮），不含任何原始数据——FASTQ、BAM/SAM、GVCF 一律未入库（体积与数据政策，见 §5）。每个文件都是真实管线在集群上 跑出来的产物，**未做任何人工修改**；讲解文档（本文件）教你逐类怎么读。

三份文档的分工：

文档	回答的问题
学生版路线图（WES/ref/WES_roadmap_to_students.*）	命令怎么打
矫正增强版（WES/ref/WES_roadmap_corrected*，中英双语）	命令哪里对哪里错、为什么、实测证据是什么
本指南 + 本目录的文件	证据本体——每个结果文件长什么样、怎么读、你能亲手验证什么

两轮运行：

轮次	数据	集群运行目录（大文件仍在此）	SLURM 作业
demo	data_new（0.5× 降采样）	/lustre1/user/bjx131_pkuhpc/wes_run_cluster_20260914	3048
full	OC_WES_all（全量）	/lustre1/user/bjx131_pkuhpc/wes_run_full_20260920	3049–3061（8 个，依赖链）

目录结构 · What is where

目录名与路线图步骤编号一致（0_fastq → 5_somatic_tmb），可直接对照：

```
WES/results/
├── demo/                       # 0.5× demo 轮（摘录）
│   ├── 0_fastq/                #   fastp 报告（OC / PBMC 各一套 html+json）
│   ├── 1_alignment/            #   flagstat · markdup 指标 · BQSR recal 表（每样本 3 件）
│   ├── 2_variant_call/         #   联合 VCF(14,782) + SNP/INDEL 两个 VQSR 输出 + 合并产物(29,564!) +
recal/tranches
│   ├── 3_annotation/           #   ANNOVAR multianno(29,602 行=翻倍传播) + avinput 日志
│   ├── 4_cnv/cnvkit_out/       #   cns/call.cns +【31 字节的空 antitarget 文件】+ scatter/diagram
│   ├── 5_somatic_tmb/          #   raw/filtered/pass VCF——全部 0 条变异（这本身就是结果）
│   ├── scripts/                #   wes_demo_steps3to10.sbatch
│   └── log/                    #   deviations.log · summary · 3047(set -u 崩溃证据) · 3048 全程日志
├── full/                       # 全量轮（摘录）
│   ├── 0_fastq/  1_alignment/ #   同 demo 构（每样本 flagstat/指标/recal）
│   ├── 2_variant_call/         #   联合 VCF(55,123) + 顺序 VQSR 矫正产物(55,123, 0 孪生) + recal/
tranches
│   ├── 3_annotation/           #   avinput 日志 + invalid_input（大 multianno 未入库，见 §5）
│   ├── 4_cnv/cnvkit_out/       #   原样 amplicon 模式：cns/call.cns + 空 antitarget + scatter
│   ├── 4_cnv/cnvkit_out_hybrid/#  矫正 hybrid 模式：cns/call.cns + 2.2MB 真实 antitarget + scatter
│   ├── 5_somatic_tmb/          #   raw(2,949) → filtered → pass(108) + filteringStats
│   ├── qc/                     #   4 份 HsMetrics + demo 联合 VCF 的 bcftools stats
│   ├── scripts/                #   8 个 sbatch 脚本（全部实跑脚本）
│   └── log/                    #   deviations · 7 份 summary · 全部作业的 .out/.err
├── README.md
└── WES_results_guide.{md,html,pdf}   # 本文档
```

逐类讲解 · How to read each artifact

1. fastp 报告（`0_fastq/`，步骤 2）

是什么： 每样本一份自包含 HTML（浏览器直接打开，含全部图表）+ 一份机器可读 JSON。

三处必看：

看什么	demo 实测	全量实测	判断标准
Q30 比例（修剪后）	OC 97.0% / PBMC 97.8%	OC 97.0% / PBMC 97.8%	≥90–95% 健康；两轮一致=同一文库抽样
接头残留	~0	~0	应为 0 或接近 0
插入片段峰值	**150 bp**	**150 bp**	应显著大于读长 137 bp——**此处偏短**

插入峰 150 bp 是全套数据最重要的"隐性事实"：2×137 bp 的读段大量互相重叠，重叠碱基在覆盖度统计里只算一次（全量轮实测 **25.6%** 的可用碱基耗于此，见 HsMetrics 一节）——这是"理论 ~172× 实测只有 54.6×"的三大去向之一。

2. flagstat（`1_alignment/*flagstat.txt`，步骤 3.4）

是什么： 比对质量的 13 行汇总。三问：

问题	OC（肿瘤）	PBMC（正常）	解读
比对率?	100%（全量轮 79.6M 读段仅 311 条未比对）	100%	本数据集发布前已剔除未比对读段；新鲜实验室数据 96–99% 才正常
properly paired?	demo 83.29% / 全量 83.22%	99.4–99.5%	**OC 两轮完全一致——真实肿瘤属性**：15.8% 读段对配到不同染色体（PBMC 0.43%），重度重排基因组（HGSOC）的签名

问题	OC（肿瘤）	PBMC（正常）	解读
secondary 比对?	9.1%	0.18%	重复序列含量差异，几个百分点属正常

3. MarkDuplicates 指标（`1_alignment/*markdup_metrics.txt`，步骤 4）

是什么： 每样本的 PCR/光学重复统计表。关键行是 `LIBRARY` 数据行和 `PERCENT_DUPLICATION`。

样本	检查读段对	重复率	光学重复占比	文库复杂度估计
demo OC / PBMC	—	**0.033% / 0.06%**	—	抽样必然≈0（$0.48\%^2$ ≈ 0.002% 的对子双双存活）
full OC	36,468,418	**7.08%**	71.8%	809,511,121
full PBMC	51,634,767	**10.77%**	57.4%	478,822,815
老师 `analysis_full`（对照）	—	7.39% / 11.01%	—	—

与老师参考差 0.4 个百分点以内——这是我们的 prep 链忠实复现参考 prep 的最强单点验证。 **71.8% 是光学重复**说明重复主要来自 patterned flowcell 相邻簇，不是 PCR 过度扩增。

4. BQSR recal 表（`1_alignment/*.recal_data.table`，步骤 5）

是什么： 机器可读的经验质量模型（ReadGroupTable / QualityScoreTable / 各协变量表）。 人读时看 `RecalTable0` 的 `EstimatedQ` vs `EmpiricalQuality`：系统性差 1–5 个 Q 属正常且 值得校准。要可视化就跑 `gatk AnalyzeCovariates`。两轮的表尺寸几乎一样（108–110 KB）—— 模型形状相同，只是全量轮每格计数更密；0.5× 下这些计数薄得校准基本是噪声。

5. 胚系变异集 VCF（`2_variant_call/`，步骤 6–7）

是什么： HaplotypeCaller GVCF 流程的最终产出。本目录收录的每一份都有教学点：

文件	记录数	为什么收录
`demo/OC_blood_variants.vcf`	14,782（13,632 SNP + 1,151 indel）	原始联合变异集；配套 `qc/demo_joint_stats.txt`（bcftools stats 全景）
`demo/OC_blood.snps.VQSR.vcf`	14,782	ApplyVQSR **SNP 模式的输出——注意它不是只有 SNP**，indel 全部透传（FILTER=.）
`demo/OC_blood.indel.VQSR.vcf`	14,782	INDEL 模式同理——这四份文件是理解翻倍 bug 的全套材料
`demo/OC_blood.all.VQSR.vcf`	**29,564 = 2 × 14,782**	**路线图 §7.3 的 bug 本体**——每条变异两条记录
`full/OC_blood_variants.vcf`	55,123	全量轮原始联合集（双样本、靶区内）
`full/OC_blood.all.sequentialVQSR.vcf`	55,123（PASS 53,988）	矫正产物：顺序套用 ApplyVQSR，零未过滤孪生，过滤率 2.1%

翻倍 bug 亲手验证（三条命令，§6 练习 1 会用到）：

```
grep -vc '^#' demo/2_variant_call/OC_blood_variants.vcf                    # 14782
grep -vc '^#' demo/2_variant_call/OC_blood.all.VQSR.vcf                    # 29564
grep -v '^#' demo/2_variant_call/OC_blood.all.VQSR.vcf | cut -f1,2 \
  | sort | uniq -c | awk '{print $1}' | sort | uniq -c                      # "14782 2" → 每位点恰好 2 条
```

关于 “55,123 vs 老师 204,178”： 这两个数**不可直接比**。老师的参考 VCF 是 ①单样本 （blood 的 RG `SM` 标签误写成 `OC`，CombineGVCFs 把两样本塌缩）②全基因组（无 `-L`，72% 位点在靶区外）③被 §7.3 bug 翻倍前的原始数。比 callset 前先读 VCF 头的 `##GATKCommandLine` 与 `#CHROM` 行。

6. VQSR recal + tranches（`2_variant_call/*.recal、*.tranches`，步骤 7）

是什么： `*.recal` 是训练出的高斯混合模型（gzip 格式）；`*.tranches` 只有 ~550 字节， 是**质量仪表盘**——每行一个敏感度档（90 / 99 / 99.9 / 100%），列 `novelTiTv` / `minVQSLod`。

三组对照（demo / 我们全量 / 老师全量）——**这是”模型可信度”最浓缩的一张表**：

证据	demo（14.8k）	全量（55.1k）	老师（204k）	健康的样子
truth 位点（hapmap+omni ∩ callset）	7,388	28,324	85,159	随队列增长
minVQSLod（100% tranche）	**−5889.9**	−1111.4	−25.5	−10 ~ −30 的有界尾部
novel Ti/Tv（90% tranche）	2.46（贴着 known 2.71）	2.50（known 2.63）	1.69（known 2.34）	novel 明显低于 known

怎么读： demo 的 −5889 意味着模型在尾部毫无判别力（噪声里分离噪声）；novel Ti/Tv 贴着 known 更致命——健康 callset 的 novel 变异富集 artifacts，Ti/Tv 必须**显著低于** known（老师 那组 1.69 vs 2.34 才是标准样子）。“跑完” ≠ “能用”，这是 VQSR 教学的核心一课（矫正版 §7.2）。

7. ANNOVAR 输出（`3_annotation/`，步骤 8）

是什么： `multianno.txt` 每行一个（变异 × 转录本），列含 `Func` / `ExonicFunc` / `AAChange`。demo 收录的 `OC_blood_anno.hg38_multianno.txt` 有 **29,602 行**——对 14,782 个真实变异——因为输入正是上面那份翻倍 VCF（§7.3 bug 向下游传播的实证）。全量轮的富注释 （55,165 行 × 146 列，含 gnomAD AF / REVEL / CADD / AlphaMissense）体积 27 MB 未入库， 在集群 `wes_run_full_20260920/3_annotation/`。

`invalid_input` 是 convert2annovar 拒收的行（多为复杂重排区），`.log` 里有原因——真实数据 永远有这一项，不是错误。

8. 体细胞 VCF（`5_somatic_tmb/`，步骤 9）

是什么： Mutect2 配对检出的 raw → filtered → pass 三级，加 `filteringStats.tsv`（每个 过滤器的期望 FDR/FN——比如 `orientation` 行的 FDR 0.02 就是方向偏好模型在量化 FFPE 类 artifact）。

轮次	raw	filtered	PASS	TMB
demo	0	0	**0**	0.00/Mb —— 0.5× 下无统计功效，**0 是诚实的结果不是失败**
full	2,949	2,949	**108**	**108 / 60.5079 Mb = 1.78 mut/Mb** —— 正中 HGSOC 的 1–3 区间

PASS 变异的肿瘤 AF 从 0.056 到 0.48（中位 ~0.4，与高纯度肿瘤的杂合克隆突变一致）。被滤 掉的 2,841 条里，`normal_artifact`（胚系位点等位分数倾斜）和 `weak_evidence`（54.6× 可用 深度仍是灵敏度天花板）是大头。

9. CNVkit 输出（`4_cnv/`，步骤 10）

是什么： `.cnr`=每 bin log2；`.cns`=分割后；`.call.cns`=整数化拷贝数（`cn` 列 0/1/2/3，`weight`=bin 支持度）。本目录最大的看点是**同一批 BAM、两种模式的四组对照文件**：

对照	amplicon（路线图原样）	hybrid（矫正）
antitargetcoverage.cnn	**31 字节（只剩表头）**	**2.2 MB（真实抗靶区 bin）**

对照	amplicon（路线图原样）	hybrid（矫正）
call.cns	290 段，臂级事件全哑火	357 段，高权重臂级事件
scatter.png	事件权重低	事件清晰

hybrid 版 `call.cns` 里的高权重事件（`awk '$NF>1000'` 可直接筛出）：**chr9:78–138 Mb cn=1（9q 单拷贝缺失，weight 7,416）**、**chr8 增益 cn=3 含 8q24/MYC （weight 7,172）**、chr5/20/21 增益、**chrY 缺失（与女性患者一致）**——一个核型自洽的 HGSOC 图景。demo 轮的 `call.cns` 则是反面教材：cn 值 324/1601/6345——参考为空时的数学 伪象，0.5× 数据 + amplicon 模式的双重噪声。

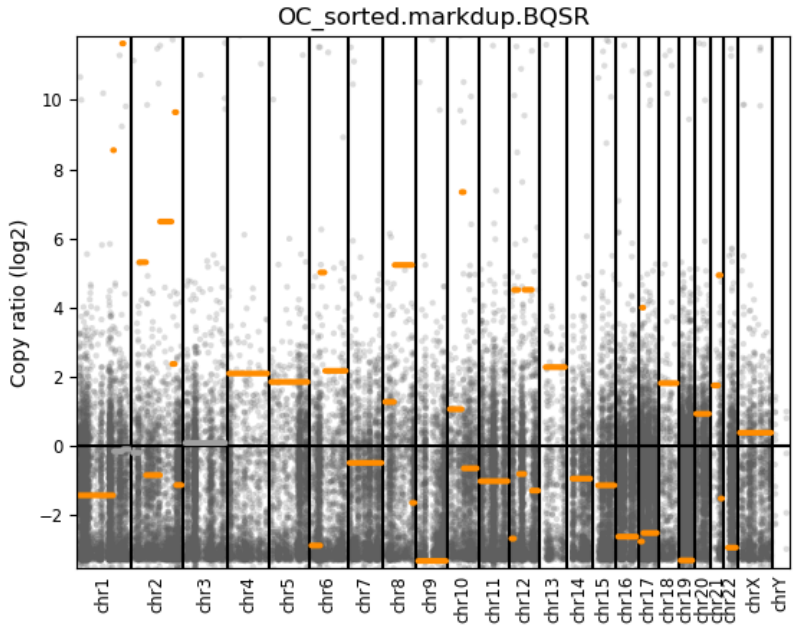


图 1 — `demo/4_cnv/cnvkit_out/OC_sorted.markdup.BQSR-scatter.png`：demo 轮（`-m amplicon`，0.5×）的散点。灰点云宽达 ±1.5 log2，橙色分段只是沿噪声连线；对应的 `call.cns` 里 `cn` 到了 324/1601/6345——二倍体不可能的取值。看到这张图就该停下：参考里没有 bin，方差估计无意义，“每个 bin 都显著”。

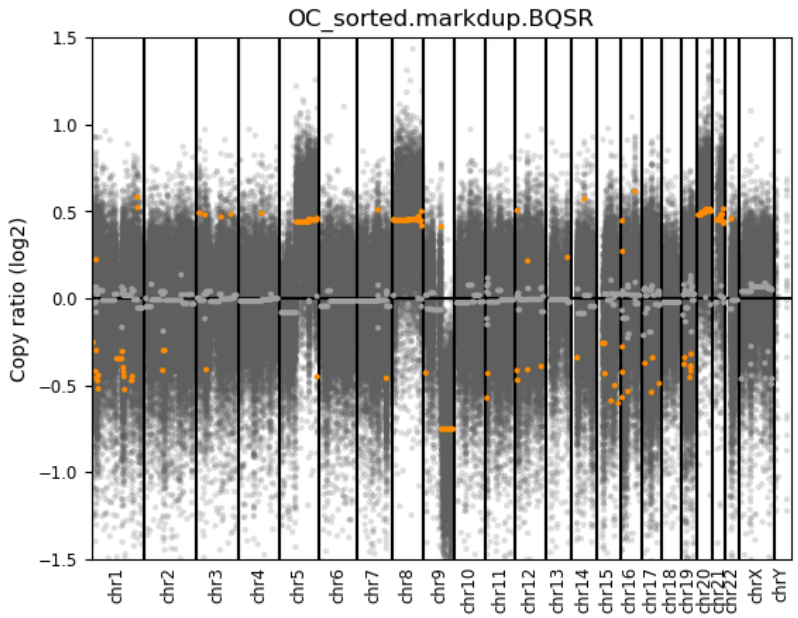


图 2 — `full/4_cnv/cnvkit_out/OC_sorted.markdup.BQSR-scatter.png`：全量轮按原样（`-m amplicon`，作业 3053）。

更危险的那种：图好看了，但一切只来自靶区 bin（`antitargetcoverage.cnn` 31 字节 = 空表头）。臂级事件都在，却被压扁——chr9 约 −0.5（矫正版 −0.76）、chr8 约 +0.45（矫正版 +0.49），且图里完全没有脱靶 bin 的密度层。

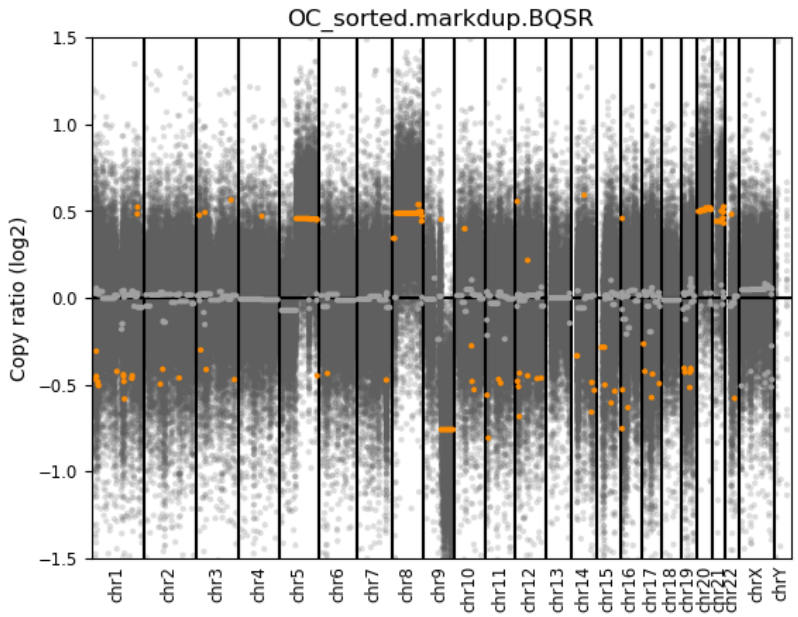


图 3 — `full/4_cnv/cnvkit_out_hybrid/OC_sorted.markdup.BQSR-scatter.png`：全量轮矫正版（`-m hybrid` + access，作业 3055）。

同一批 BAM，只改一个旗标。点云收紧到 ±0.5 内、全基因组都能看到脱靶底部，橙色分段落在真实臂级位移上。把图 2 与图 3 的 chr9 区块并排看，就是”一个 flag 的实测代价”。

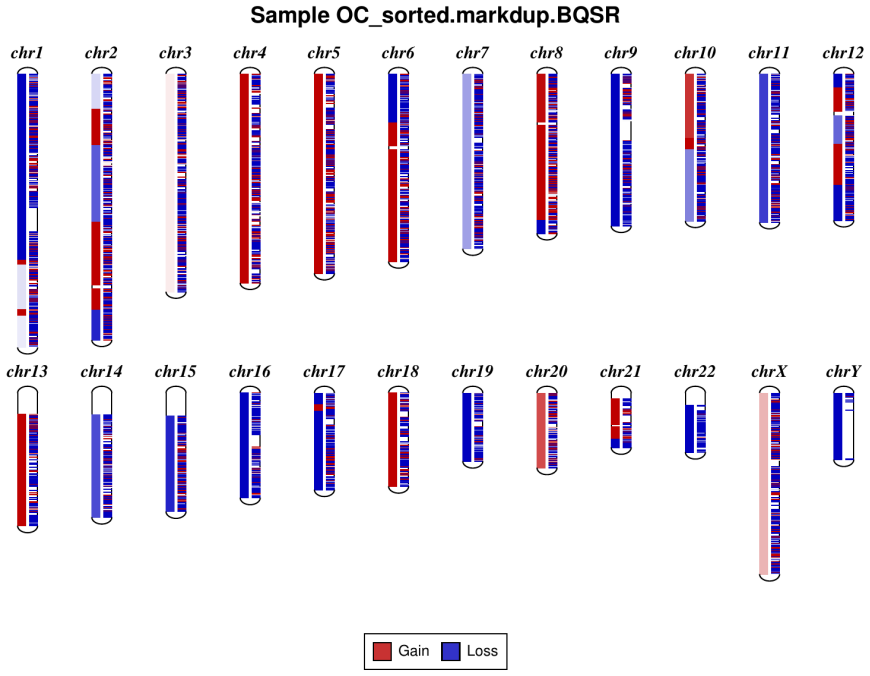


图 4 — `full/4_cnv/cnvkit_out_hybrid/OC_sorted.markdup.BQSR-diagram.pdf`（转 PNG）：全基因组核型视图。

红=增益、蓝=缺失。整条 chr9 蓝（9q 单拷贝缺失）、chr8 与 chr20-21 大块红（chr8 那块含 8q24/MYC）、chrX 淡、chrY 几乎空（女性）。适合一眼看”这个基因组长什么样”，不适合看单个 bin；基因名缺失是因为 3 列 BED 没有 `gene` 列。

10. HsMetrics（`full/qc/*.hs_metrics.txt`，矫正补充步骤）

是什么： CollectHsMetrics 的靶区覆盖度报告——**整条原版路线图唯一缺失的指标**，也是”深度够不够”这个检查清单问题的唯一量化答案。每份 ~60 列；最要紧的几列：

样本	MEAN_TARGET_COV	≥30X	ZERO_CVG	EXC_DUPE	EXC_OVERLAP	PCT_SELECTED
demo OC / PBMC	0.3× / 0.5×（中位 **0**）	0%	59.4% / 46.6%	~0.03%	26.8% / 24.9%	79.9% / 90.8%
full OC	**54.6×**（中位 57）	87.4%	8.4%	7.3%	25.6%	79.9%
full PBMC	**91.3×**（中位 96）	89.6%	8.1%	11.0%	23.0%	90.7%

深度去向账本（full OC）：理论 ~172× → 脱靶（~20%）→ 重复（7.3%）→ 双端重叠（25.6%）→ **可用 54.6×**。“付了 172× 的钱，拿到 54.6× 的深度”——测序预算的实务课。`qc/demo_joint_stats.txt` 是 demo 联合 VCF 的 bcftools stats 全景（记录数/ SNP/indel/ multiallelic/TiTv/HetHom 一应俱全），供练习用。

11. 日志与脚本（`log/`、`scripts/`）

- `deviations.log`：每个预期失败与既定偏差的时间戳记录——两轮运行忠实度的直接证据。
- `summary_*.log`：每步的数字汇总（本指南引用的所有数字的原始出处）。

- `*.out/.err`：SLURM 作业全程日志。**教学彩蛋**：demo/`log/wes_demo_3047.err`（124 字节） 是 `set -u` 撞上 conda 激活的崩溃现场；full/`log/full_hsmetrics_3058.err` 记录了 CollectHsMetrics 的参数排障（`--INTERVALS`→`--TARGET_INTERVALS`、BED 转 interval_list）。
- `scripts/*.sbatch`：**全部实跑脚本**（demo 1 份 + full 8 份）——路线图命令原文 + 最小 SLURM 包装，复现的入口。

两轮对比总表 · The two rounds at a glance

维度	demo（0.5×）	full（可用 54.6×/91.3×）
目的	流程机制	真实生物学
联合变异集	14,782	**55,123**（双样本、靶区内）
§7.3 翻倍 bug	29,564 = 2×14,782（本目录可亲手验证）	110,246 = 2×55,123（30 MB VCF 未入库）
VQSR 可信度	truth 7,388，尾 −5889，novel 贴 known	truth 28,324，tranches 正常，顺序矫正滤 2.1%
ANNOVAR	基础协议 29,602 行（翻倍传播）；富协议挂（库名不存在）	矫正库名 55,165 行 × 146 列（集群）
体细胞 / TMB	0（无统计功效）	**108 PASS / TMB 1.78 mut/Mb**
CNVkit	cn=6345 荒谬值	hybrid 矫正：9q 缺失、chr8 含 MYC 增益、chrY 缺失
靶区深度	0.3×/0.5×，中位 0	**54.6×/91.3×**
墙钟	~25 分钟	最长链 3h42m（8 作业依赖串联）

两轮的价值：**数据问题**（0、噪声、荒谬 cn）与**流程问题**（翻倍 bug、库名、模式）被彻底 分开——前者换全量数据自然消失，后者换什么数据都在，连老师的参考产物里都有。

未入库的大文件 · What stayed on the cluster

原始数据与超大产物不入库（本目录只放分析结果）；集群路径与去向：

文件	尺寸	在哪
原始/clean FASTQ	3–24 GB/文件	`$RUN/0_fastq/`
各级 BAM（sorted/markdup/BQSR）	4–9.4 GB/文件	`$RUN/1_alignment/`
demo 的 SAM（原版逐字链产物）	165–225 MB	demo 运行目录
GVCF（OC 218 MB / combined 285 MB）	—	`$RUN/2_variant_call/`、`1_alignment/`
full 翻倍 VCF（30 MB）、step1/分型中间 VCF	14–30 MB	`$RUN/2_variant_call/`
ANNOVAR 富注释 multianno（146 列）	27 MB	`$RUN/3_annotation/`
CNVkit .cnr（每 bin）、coverage .cnn、reference.cnn	11–20 MB	`$RUN/4_cnv/`
diagram PDF（两模式）	6–7 MB	`$RUN/4_cnv/cnvkit_out*/`
f1r2 / orientation 模型（二进制）	2 MB	`$RUN/5_somatic_tmb/`
targets.interval_list / targets.bed	6–7 MB	`$RUN/qc/`、`4_cnv/`（参考区文件，共享区有原件）

（`$RUN` = 上表两轮目录。）这些文件都可以用 `scripts/` 里的脚本在集群上重新生成。

动手练习 · Exercises you can do right here

不需要集群，只需要本目录 + bcftools/samtools/grep/awk：

1. **验证 §7.3 翻倍 bug**（§4 的三条命令）：确认 29,564 = 2 × 14,782、每个位点恰好两条、且两条的 FILTER 不同（一条带模型裁决、一条是 .）。
2. **读 tranches**：打开 demo 与 full 的 `OC_blood.snps.tranches`，各找 `novelTiTv` 随档位（90→99→99.9→100%）的变化方向；再对比 `minVQSLod` 列的 −5889.9 vs −1111。
3. **数 Ti/Tv 和 Het/Hom**：`qc/demo_joint_stats.txt` 的 TSTV/与 PES 段——demo 的 het/hom ≈ 0.14（0.5× 基因型崩坏）vs 全量 1.45（健康），数字就在文件里。
4. **找最高 AF 的体细胞变异**：`bcftools query -f '%CHROM\t%POS\t[%AF]\n' full/5_somatic_tmb/somatic.pass.vcf.gz | sort -k3 -g | tail`；再用 `grep -v '^#' full/5_somatic_tmb/somatic.filtered.vcf.gz | grep -c PASS` 复算 TMB 的分子。
5. **CNV 对比**：对两份 `call.cns` 各跑 `awk -F'\t' '$NF>1000' ... | head`——hybrid 有臂级 大事件、amplicon 没有；再对 demo 的 `call.cns` 找 cn>10 的荒谬段。
6. **算深度去向账**：用 fastp JSON 里的总碱基 ÷ 60.51 Mb 得理论深度（full OC ~172×），对照 `qc/full_OC.hs_metrics.txt` 的 54.6×，把差额拆进 PCT_EXC_* 三个口袋。

本指南与矫正增强版路线图（*WES/ref/WES_roadmap_corrected**）配套阅读效果最佳；全部数字的 原始出处是两轮运行目录的 *log/summary_*.log*（本目录已收录副本）。