

WES 分析结果讲解 • Results Guide

两轮实跑产物的逐文件导读——怎么看、为什么是这些数、动手验证

目录

关于本指南 • About this guide	1
目录结构 • What is where	2
逐类讲解 • How to read each artifact	2
1. fastp 报告 (0_fastq/, 步骤 2)	2
2. flagstat (1_alignment/*flagstat.txt, 步骤 3.4)	2
3. MarkDuplicates 指标 (1_alignment/*markdup_metrics.txt, 步骤 4)	3
4. BQSR recal 表 (1_alignment/*.recal_data.table, 步骤 5)	3
5. 胚系变异集 VCF (2_variant_call/, 步骤 6-7)	3
6. VQSR recal + tranches (2_variant_call/*.recal、*.tranches, 步骤 7)	4
7. ANNOVAR 输出 (3_annotation/, 步骤 8)	4
8. 体细胞 VCF (5_somatic_tmb/, 步骤 9)	4
9. CNVkit 输出 (4_cnv/, 步骤 10)	5
10. HsMetrics (full/qc/*.hs_metrics.txt, 矫正补充步骤)	5
11. 日志与脚本 (log/、scripts/)	5
两轮对比总表 • The two rounds at a glance	5
未入库的大文件 • What stayed on the cluster	6
动手练习 • Exercises you can do right here	6

关于本指南 • About this guide

本目录收录的是**我们自己的两轮实跑分析结果**(demo 轮 + 全量轮), 不含任何原始数据——FASTQ、BAM/SAM、GVCF 一律未入库(体积与数据政策, 见 § 5)。每个文件都是真实管线在集群上跑出来的产物, **未做任何人工修改**; 讲解文档(本文件)教你逐类怎么读。

三份文档的分工:

文档	回答的问题
学生版路线图 (WES/ref/WES_roadmap_to_students.*)	命令怎么打
矫正增强版 (WES/ref/WES_roadmap_corrected*, 中英双语)	命令哪里对哪里错、为什么、实测证据是什么
本指南 + 本目录的文件	证据本体——每个结果文件长什么样、怎么读、你能亲手验证什么

)

两轮运行:

轮次	数据	集群运行目录 (大文件仍在 SLURM 作业此)
demo	data_new (0.5× 降采样)	/lustre1/user/bjx131_pkuhpc/wes_run_cluster_20260914 3048
full	0C_WES_all (全量)	/lustre1/user/bjx131_pkuhpc/wes_run_full_20260920 3049-3061 (8 个, 依赖链)

)

目录结构 • What is where

目录名与路线图步骤编号一致 (0_fastq → 5_somatic_tmb), 可直接对照:

```
WES/results/
├─ demo/                                # 0.5× demo 轮 (摘录)
│   ├── 0_fastq/                        # fastp 报告 (OC / PBMC 各一套 html+json)
│   ├── 1_alignment/                    # flagstat · markdup 指标 · BQSR recal 表 (每样本 3 件)
│   └── 2_variant_call/                  # 联合 VCF(14,782) + SNP/INDEL 两个 VQSR 输出 + 合并产物(29,564!) +
recal/tranches
│   ├── 3_annotation/                    # ANNOVAR multianno(29,602 行=翻倍传播) + avinput 日志
│   ├── 4_cnv/cnvkit_out/                # cns/call.cns + [31 字节的空 antitarget 文件] + scatter/diagram
│   ├── 5_somatic_tmb/                  # raw/filtered/pass VCF—全部 0 条变异 (这本身就是结果)
│   ├── scripts/                         # wes_demo_steps3to10.sbatch
│   └── log/                             # deviations.log · summary · 3047(set -u 崩溃证据) · 3048 全程日志
├─ full/                                # 全量轮 (摘录)
│   ├── 0_fastq/ 1_alignment/            # 同 demo 构 (每样本 flagstat/指标/recal)
│   └── 2_variant_call/                  # 联合 VCF(55,123) + 顺序 VQSR 矫正产物(55,123, 0 孪生) + recal/
tranches
│   ├── 3_annotation/                    # avinput 日志 + invalid_input (大 multianno 未入库, 见 $5)
│   ├── 4_cnv/cnvkit_out/                # 原样 amplicon 模式: cns/call.cns + 空 antitarget + scatter
│   ├── 4_cnv/cnvkit_out_hybrid/#        # 矫正 hybrid 模式: cns/call.cns + 2.2MB 真实 antitarget + scatter
│   ├── 5_somatic_tmb/                  # raw(2,949) → filtered → pass(108) + filteringStats
│   ├── qc/                             # 4 份 HsMetrics + demo 联合 VCF 的 bcftools stats
│   ├── scripts/                         # 8 个 sbatch 脚本 (全部实跑脚本)
│   └── log/                             # deviations · 7 份 summary · 全部作业的 .out/.err
├─ README.md
└─ WES_results_guide.{md,html,pdf}      # 本文档
```

逐类讲解 • How to read each artifact

1. fastp 报告 (0_fastq/, 步骤 2)

是什么: 每样本一份自包含 HTML (浏览器直接打开, 含全部图表) + 一份机器可读 JSON。

三处必看:

看什么	demo 实测	全量实测	判断标准
Q30 比例 (修剪后)	OC 97.0% / PBMC 97.8%	OC 97.0% / PBMC 97.8%	≥90-95% 健康; 两轮一致=同一文库抽样
接头残留	~0	~0	应为 0 或接近 0
插入片段峰值	150 bp	150 bp	应显著大于读长 137 bp——此处偏短

)

插入峰 150 bp 是全套数据最重要的”隐性事实”: 2×137 bp 的读段大量互相重叠, 重叠碱基在覆盖度统计里只算一次 (全量轮实测 **25.6%** 的可用碱基耗于此, 见 HsMetrics 一节) —— 这是 “理论~172× 实测只有 54.6×” 的三大去向之一。

2. flagstat (1_alignment/*flagstat.txt, 步骤 3.4)

是什么: 比对质量的 13 行汇总。三问:

问题	OC (肿瘤)	PBMC (正常)	解读
比对率?	100% (全量轮 79.6M 读段仅 311 条未比对)	100%	本数据集发布前已剔除未比对读段; 新鲜实验室数据 96-99% 才正常

问题	OC (肿瘤)	PBMC (正常)	解读
properly paired?	demo 83.29% / 全量 83.22%	99.4-99.5%	OC 两轮完全一致——真实肿瘤属性 ：15.8% 读段对配到不同染色体 (PBMC 0.43%)，重度重排基因组 (HGSOC) 的签名
secondary 比对?	9.1%	0.18%	重复序列含量差异, 几个百分点属正常

)

3. MarkDuplicates 指标 (1_alignment/*markdup_metrics.txt, 步骤 4)

是什么： 每样本的 PCR/光学重复统计表。关键行是 LIBRARY 数据行和 PERCENT_DUPLICATION。

样本	检查读段对	重复率	光学重复占比	文库复杂度估计
demo OC / PBMC	—	0.033% / 0.06%	—	抽样必然 ≈ 0 ($0.48\%^2 \approx 0.002\%$ 的对子双双存活)
full OC	36,468,418	7.08%	71.8%	809,511,121
full PBMC	51,634,767	10.77%	57.4%	478,822,815
老师 analysis_full (对照)	—	7.39% / 11.01%	—	—

)

与老师参考差 0.4 个百分点以内——这是我们的 prep 链忠实复现参考 prep 的最强单点验证。 **71.8% 是光学重复**说明重复主要来自 patterned flowcell 相邻簇，不是 PCR 过度扩增。

4. BQSR recal 表 (1_alignment/*.recal_data.table, 步骤 5)

是什么： 机器可读的经验质量模型 (ReadGroupTable / QualityScoreTable / 各协变量表)。人读时看 RecalTable0 的 EstimatedQ VS EmpiricalQuality: 系统性差 1-5 个 Q 属正常且值得校准。要可视化就跑 gatk AnalyzeCovariates。两轮的表尺寸几乎一样 (108-110 KB)——模型形状相同，只是全量轮每格计数更密；0.5×下这些计数薄得校准基本是噪声。

5. 胚系变异集 VCF (2_variant_call/, 步骤 6-7)

是什么： HaplotypeCaller GVCF 流程的最终产出。本目录收录的每一份都有教学点：

文件	记录数	为什么收录
demo/OC_blood_variants.vcf	14,782 (13,632 SNP + 1,151 indel)	原始联合变异集；配套 qc/demo_joint_stats.txt (bcftools stats 全景)
demo/OC_blood.snps.VQSR.vcf	14,782	ApplyVQSR SNP 模式 的输出—— 注意它不是只有 SNP ，indel 全部透传 (FILTER=.)
demo/OC_blood.indel.VQSR.vcf	14,782	INDEL 模式同理——这四份文件是理解翻倍 bug 的全套材料
demo/OC_blood.all.VQSR.vcf	29,564 = 2 × 14,782	路线图 § 7.3 的 bug 本体 ——每条变异两条记录
full/OC_blood_variants.vcf	55,123	全量轮原始联合集 (双样本、靶区内)
full/OC_blood.all.sequentialVQSR.vcf	55,123 (PASS 53,988)	矫正产物：顺序套用 ApplyVQSR，零未过滤孪生，过滤率 2.1%

)

翻倍 bug 亲手验证（三条命令，§ 6 练习 1 会用到）：

```
grep -vc '^#' demo/2_variant_call/0C_blood_variants.vcf # 14782
grep -vc '^#' demo/2_variant_call/0C_blood.all.VQSR.vcf # 29564
grep -v '^#' demo/2_variant_call/0C_blood.all.VQSR.vcf | cut -f1,2 \
| sort | uniq -c | awk '{print $1}' | sort | uniq -c # "14782 2" → 每位点恰好
2 条
```

关于“55,123 vs 老师 204,178”：这两个数不可直接比。老师的参考 VCF 是 ①单样本（blood 的 RG SM 标签误写成 0c，CombineGVCFs 把两样本塌缩）②全基因组（无 -L，72% 位点在靶区外）③被 § 7.3 bug 翻倍前的原始数。比 callset 前先读 VCF 头的 ##GATKCommandLine 与 #CHROM 行。

6. VQSR recal + tranches (2_variant_call/*.recal、*.tranches，步骤 7)

是什么：*.recal 是训练出的高斯混合模型（gzip 格式）；*.tranches 只有 ~550 字节，是质量仪表盘——每行一个敏感度档（90 / 99 / 99.9 / 100%），列 novelTiTv / minVQSLod。

三组对照（demo / 我们全量 / 老师全量）——这是“模型可信度”最浓缩的一张表：

证据	demo (14.8k)	全量 (55.1k)	老师 (204k)	健康的样子
truth 位点 (hapmap+omni ∩ callset)	7,388	28,324	85,159	随队列增长
minVQSLod (100% tranche)	-5889.9	-1111.4	-25.5	-10 ~ -30 的有界尾部
novel Ti/Tv (90% tranche)	2.46 (贴着 known 2.71)	2.50 (known 2.63)	1.69 (known 2.34)	novel 明显低于 known

怎么读：demo 的 -5889 意味着模型在尾部毫无判别力（噪声里分离噪声）；novel Ti/Tv 贴着 known 更致命——健康 callset 的 novel 变异富集 artifacts，Ti/Tv 必须显著低于 known（老师那组 1.69 vs 2.34 才是标准样子）。“跑完” ≠ “能用”，这是 VQSR 教学的核心一课（矫正版 § 7.2）。

7. ANNOVAR 输出 (3_annotation/, 步骤 8)

是什么：multianno.txt 每行一个（变异 × 转录本），列含 Func / ExonicFunc / AACChange。demo 收录的 0C_blood_anno.hg38_multianno.txt 有 29,602 行——对 14,782 个真实变异——因为输入正是上面那份翻倍 VCF（§ 7.3 bug 向下游传播的实证）。全量轮的富注释（55,165 行 × 146 列，含 gnomAD AF / REVEL / CADD / AlphaMissense）体积 27 MB 未入库，在集群 wes_run_full_20260920/3_annotation/。

invalid_input 是 convert2annovar 拒收的行（多为复杂重排区），.log 里有原因——真实数据永远有这一项，不是错误。

8. 体细胞 VCF (5_somatic_tmb/, 步骤 9)

是什么：Mutect2 配对检出的 raw → filtered → pass 三级，加 filteringStats.tsv（每个过滤器的期望 FDR / FN——比如 orientation 行的 FDR 0.02 就是方向偏好模型在量化 FFPE 类 artifact）。

轮次	raw	filtered	PASS	TMB
demo	0	0	0	0.00/Mb —— 0.5× 下 无统计功效，0 是诚实 的结果不是失败
full	2,949	2,949	108	108 / 60.5079 Mb = 1.78 mut/Mb —— 正 中 HGSOc 的 1-3 区间

PASS 变异的肿瘤 AF 从 0.056 到 0.48 (中位 ~0.4, 与高纯度肿瘤的杂合克隆突变一致)。被滤掉的 2,841 条里, normal_artifact (胚系位点等位分数倾斜) 和 weak_evidence (54.6× 可用 深度仍是灵敏度天花板) 是大头。

9. CNVkit 输出 (4_cnv/, 步骤 10)

是什么: .cnr=每 bin log2; .cns=分割后; .call.cns=整数化拷贝数 (cn 列 0/1/2/3, weight=bin 支持度)。本目录最大的看点是同一批 BAM、两种模式的四组对照文件:

对照	amplicon (路线图原样)	hybrid (矫正)
antitargetcoverage.cnn	31 字节 (只剩表头)	2.2 MB (真实靶区 bin)
call.cns	290 段, 臂级事件全哑火	357 段, 高权重臂级事件
scatter.png	事件权重低	事件清晰

)

hybrid 版 call.cns 里的高权重事件 (awk ' \$NF>1000 ' 可直接筛出): chr9:78–138 Mb cn=1 (9q 单拷贝缺失, weight 7,416)、chr8 增益 cn=3 含 8q24/MYC (weight 7,172)、chr5/20/21 增益、chrY 缺失 (与女性患者一致) ——一个核型自治的 HGSOC 图景。demo 轮的 call.cns 则是反面教材: cn 值 324/1601/6345——参考为空时的数学伪象, 0.5× 数据 + amplicon 模式的双重噪声。

10. HsMetrics (full/qc/*.hs_metrics.txt, 矫正补充步骤)

是什么: CollectHsMetrics 的靶区覆盖度报告——整条原版路线图唯一缺失的指标, 也是”深度够不够”这个检查清单问题的唯一量化答案。每份 ~60 列; 最要紧的几列:

样本	MEAN_	≥30X	ZERO_CVG	EXC_DUPE	EXC_OVERLAP	PCT_
	TARGET_COV					SELECTED
demo OC / PBMC	0.3× / 0.5× (中位 0)	0%	59.4% / 46.6%	~0.03%	26.8% / 24.9%	79.9% / 90.8%
full OC	54.6× (中位 57)	87.4%	8.4%	7.3%	25.6%	79.9%
full PBMC	91.3× (中位 96)	89.6%	8.1%	11.0%	23.0%	90.7%

)

深度去向账本 (full OC): 理论 ~172× → 脱靶 (~20%) → 重复 (7.3%) → 双端重叠 (25.6%) → 可用 54.6×。“付了 172× 的钱, 拿到 54.6× 的深度”——测序预算的实务课。qc/demo_joint_stats.txt 是 demo 联合 VCF 的 bcftools stats 全景 (记录数/ SNP/indel/ multiallelic/TiTv/HetHom 一应俱全), 供练习用。

11. 日志与脚本 (log/, scripts/)

- deviations.log: 每个预期失败与既定偏差的时间戳记录——两轮运行忠实度的直接证据。
- summary_*.log: 每步的数字汇总 (本指南引用的所有数字的原始出处)。
- *.out/.err: SLURM 作业全程日志。教学彩蛋: demo/log/wes_demo_3047.err (124 字节) 是 set -u 撞上 conda 激活的崩溃现场; full/log/full_hsmetrics_3058.err 记录了 CollectHsMetrics 的参数排障 (--INTERVALS→--TARGET_INTERVALS、BED 转 interval_list)。
- scripts/*.sbatch: 全部实跑脚本 (demo 1 份 + full 8 份) ——路线图命令原文 + 最小 SLURM 包装, 复现的入口。

两轮对比总表 • The two rounds at a glance

维度	demo (0.5×)	full (可用 54.6×/91.3×)
目的	流程机制	真实生物学
联合变异集	14,782	55,123 (双样本、靶区内)

维度	demo (0.5×)	full (可用 54.6×/91.3×)
§ 7.3 翻倍 bug	29,564 = 2×14,782 (本目录可亲手验证)	110,246 = 2×55,123 (30 MB VCF 未入库)
VQSR 可信度	truth 7,388, 尾 -5889, novel 贴 known	truth 28,324, tranches 正常, 顺序矫正滤 2.1%
ANNOVAR	基础协议 29,602 行 (翻倍传播); 富协议挂 (库名不存在)	矫正库名 55,165 行 × 146 列 (集群)
体细胞 / TMB	0 (无统计功效)	108 PASS / TMB 1.78 mut/Mb
CNVkit	cn=6345 荒谬值	hybrid 矫正: 9q 缺失、chr8 含 MYC 增益、chrY 缺失
靶区深度	0.3×/0.5×, 中位 0	54.6×/91.3×
墙钟	~25 分钟	最长链 3h42m (8 作业依赖串联)

)

两轮的价值：**数据问题** (0、噪声、荒谬 cn) 与**流程问题** (翻倍 bug、库名、模式) 被彻底分开——前者换全量数据自然消失，后者换什么数据都在，连老师的参考产物里都有。

未入库的大文件 • What stayed on the cluster

原始数据与超大产物不入库 (本目录只放分析结果); 集群路径与去向:

文件	尺寸	在哪
原始/clean FASTQ	3–24 GB/文件	\$RUN/0_fastq/
各级 BAM (sorted/markdup/BQSR)	4–9.4 GB/文件	\$RUN/1_alignment/
demo 的 SAM (原版逐字链产物)	165–225 MB	demo 运行目录
GVCF (OC 218 MB / combined 285 MB)	—	\$RUN/2_variant_call/、1_alignment/
full 翻倍 VCF (30 MB)、step1/分型中间 VCF	14–30 MB	\$RUN/2_variant_call/
ANNOVAR 富注释 multianno (146 列)	27 MB	\$RUN/3_annotation/
CNVkit .cnr (每 bin)、coverage .cnv、reference.cnn	11–20 MB	\$RUN/4_cnv/
diagram PDF (两模式)	6–7 MB	\$RUN/4_cnv/cnvkit_out*/
f1r2 / orientation 模型 (二进制)	2 MB	\$RUN/5_somatic_tmb/
targets.interval_list / targets.bed	6–7 MB	\$RUN/qc/、4_cnv/ (参考区文件, 共享区有原件)

)

(\$RUN = 上表两轮目录。) 这些文件都可以用 scripts/ 里的脚本在集群上重新生成。

动手练习 • Exercises you can do right here

不需要集群, 只需要本目录 + bcftools/samtools/grep/awk:

1. 验证 § 7.3 翻倍 bug (§ 4 的三条命令): 确认 29,564 = 2 × 14,782、每个位点恰好两条、且两条的 FILTER 不同 (一条带模型裁决、一条是 .)。
2. 读 tranches: 打开 demo 与 full 的 OC_blood.snps.tranches, 各找 novelTiTv 随档位 (90→99→99.9→100%) 的变化方向; 再对比 minVQSLod 列的 -5889.9 vs -1111。
3. 数 Ti/Tv 和 Het/Hom: qc/demo_joint_stats.txt 的 TSTV/与 PES 段——demo 的 het/hom ≈ 0.14 (0.5× 基因型崩坏) vs 全量 1.45 (健康), 数字就在文件里。

4. **找最高 AF 的体细胞变异**: `bcftools query -f '%CHROM\t%POS\t[%AF]\n' full/5_somatic_tmb/somatic.pass.vcf.gz | sort -k3 -g | tail`; 再用 `grep -v '^#' full/5_somatic_tmb/somatic.filtered.vcf.gz | grep -c PASS` 复算 TMB 的分子。
5. **CNV 对比**: 对两份 `call.cns` 各跑 `awk -F'\t' '$NF>1000' ... | head`——hybrid 有臂级大事件、amplicon 没有; 再对 demo 的 `call.cns` 找 `cn>10` 的荒谬段。
6. **算深度去向账**: 用 fastp JSON 里的总碱基 $\div$ 60.51 Mb 得理论深度 (full OC $\sim 172\times$), 对照 `qc/full_OC.hs_metrics.txt` 的 54.6 $\times$, 把差额拆进 `PCT_EXC_*` 三个口袋。

本指南与矫正增强版路线图 (*WES/ref/WES_roadmap_corrected**) 配套阅读效果最佳; 全部数字的原始出处是两轮运行目录的 `log/summary_*.log` (本目录已收录副本)。